Apprentissage profond en imagerie médicale

CM1 – Introduction : problèmes et types de données

Master de SNS, département de mathématiques

V. Monbet, Université de Rennes

Organisation du cours

1. **Introduction : problèmes et types de données** (aujourd'hui)
2. Segmentation et détection
3. Problèmes inverses et reconstruction
4. Peu d'annotations, décalage de domaine, transformers
5. **Incertitudes** : estimation, calibration, prédiction conforme
6. Évaluation, fiabilité, ouverture

Prérequis supposés

MLP, CNN, introduction aux transformers, optimisation stochastique, probabilités de base.

Plan de la séance

Pourquoi l'imagerie médicale ?

Modalités d'acquisition

Types de données

Tâches et formalisation

Les difficultés spécifiques

Synthèse et TP

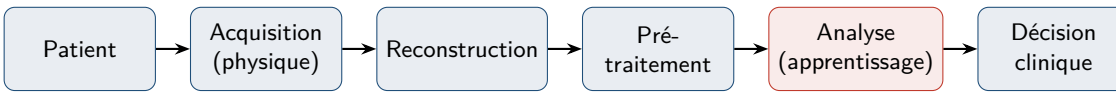
Un domaine d'application à part

- L'imagerie est au cur du parcours de soin : diagnostic, planification thérapeutique, suivi, chirurgie guidée
- Volume de données considérable et en croissance, pour un nombre limité de spécialistes
- Les enjeux : gain de temps, reproductibilité, détection précoce, quantification

Mais

Une erreur a un coût humain. La performance moyenne ne suffit pas : fiabilité, robustesse et incertitude sont des exigences de premier rang.

De l'acquisition à la décision



- L'apprentissage intervient à plusieurs étapes : reconstruction, prétraitement, analyse
- Chaque étape a son propre modèle d'erreur ; les erreurs se propagent

Ce que l'on cherche à faire : vue d'ensemble

Tâches d'analyse

- Classification, diagnostic
- Détection de lésions
- Segmentation d'organes ou de lésions
- Pronostic, survie

Tâches ń image vers image ż

- Reconstruction
- Débruitage, super-résolution
- Recalage
- Synthèse inter-modalités

Nous formaliserons chacune de ces tâches plus loin.

Radiographie et tomodensitométrie (CT)

La radiographie et la tomodensitométrie (ou scanner) sont deux techniques d'imagerie médicale utilisant les rayons X, mais elles présentent des différences majeures en termes de technologie, de rendu visuel et d'indications cliniques.

- Radiographie (Radio) :
  - Principe : crée une image fixe en deux dimensions (2D) par projection, où les structures traversées se superposent.
  - Utilisation : idéale en première intention pour l'examen des os (fractures) et des poumons (infections basiques).
  - Avantages : rapide, accessible, économique et faible exposition aux radiations.
- Tomodensitométrie (TDM / Scanner) :
  - Principe : associe les rayons X à un système informatique rotatif pour produire des coupes transversales détaillées, assemblées ensuite en images tridimensionnelles (3D).
  - Utilisation : permet d'explorer en profondeur les organes mous, les vaisseaux sanguins, le cerveau ou de détecter de petites tumeurs.
  - Avantages : précision anatomique supérieure et absence de superposition des tissus.

Radiographie et tomodensitométrie (CT) : le modèle physique

Atténuation des rayons X (loi de Beer–Lambert) le long d'une droite L :

$$I = I_0 \exp\Big(-\int_L \mu(x)\,dx\Big) \quad \Longrightarrow \quad -\log\frac{I}{I_0} = \int_L \mu(x)\,dx.$$

où I_0 est l'intensite initiale, I est l'intensité finale mesurée par le détecteur après avoir traversé le patient le long de la droite L et μ mesure la fraction de rayonnement absorbée ou diffusée par unité de longueur traversée à cet endroit [1].

- **Radiographie** : projection 2D de μ (superposition des structures : si un os et un poumon sont alignés sur la droite L, leurs atténuations s'additionnent.)
- **CT** : on mesure ces intégrales de ligne pour de nombreux angles, puis on reconstruit μ en 3D

Transformée de Radon (2D)

$\mathcal{R}\mu(\theta, s) = \int_{\mathbb{R}} \mu(s\cos\theta - t\sin\theta,\ s\sin\theta + t\cos\theta)\,dt$; les données brutes forment un *sinogramme* où s représente la position du détecteur.

1. μ dépend de la densité du tissu et de sa composition atomique, ainsi que de l'énergie des photons X. Les tissus denses, comme l'os, atténuent fortement. L'air atténue très peu, les tissus mous et l'eau sont intermédiaires.

CT : reconstruction et échelle de Hounsfield

- **Théorème de la tranche de Fourier** : la transformée de Fourier 1D de $\mathcal{R}\mu(\theta, \cdot)$ donne la transformée de Fourier 2D de μ le long de la direction θ
- **Rétroprojection filtrée** : inversion analytique ; l'inversion est mal conditionnée (filtre rampe qui amplifie le bruit)
- Méthodes itératives et régularisées lorsque la dose est réduite ou les angles sont peu nombreux

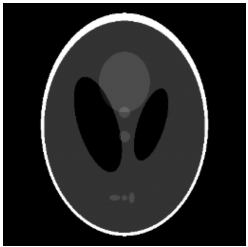
$$\mu(x,y) \xrightarrow{\mathcal{R}} \text{sinogramme } (\theta, s) \xrightarrow{\mathcal{F}_1 \text{ en } s} \widehat{\mu}(\sigma\, \mathbf{e}_\theta) \xrightarrow{\text{rééchantillonnage}} \widehat{\mu}(k_x, k_y) \xrightarrow{\mathcal{F}_2^{-1}} \mu(x,y).$$

Unités de Hounsfield (HU)

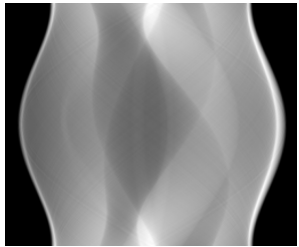
$$\mathrm{HU} = 1000\, \frac{\mu - \mu_{\text{eau}}}{\mu_{\text{eau}} - \mu_{\text{air}}}$$

Air ≈ -1000, eau $= 0$, os de plusieurs centaines. Échelle *calibrée* : les valeurs ont une signification physique (contrairement à l'IRM).

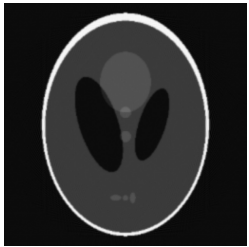
Le sinogramme : exemple du fantôme de Shepp–Logan



coupe $\mu(x, y)$



sinogramme $\mathcal{R}\mu(\theta, s)$
(θ en ordonnée, s en abscisse)



rétroprojection filtrée

- Chaque ligne du sinogramme est une projection de la coupe pour un angle θ ; un point de l'objet situé en (r, φ) y laisse la sinusoïde $s(\theta) = r\cos(\theta - \varphi)$
- Les défauts d'acquisition se lisent directement dessus : lignes manquantes (vues parcimonieuses), bande manquante (angle limité), troncature (objet hors champ)
- Reconstruire = inverser $\mathcal{R}$; ici 360 angles sur 180° et un filtre rampe

Modèle mathématique de la tomodensitométrie (CT)

Problème direct (hyp : après linéarisation log et bruit blanc gaussien additif [2])

$$y_i = \sum_{j=1}^{J} A_{i,j}\, x_j + \varepsilon_i, \qquad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

soit $y = \mathcal{A}x + \varepsilon$ avec $\mathcal{A} = \mathcal{M}\mathcal{R}$ linéaire (opérateur de projection de Radon, masque d'échantillonnage)

- $x = (x_1, \ldots, x_J)^T \in \mathbb{R}^J$ coefficients d'atténuation linéaire **inconnus** dans chaque voxel j (Unités Hounsfield), ie l'image à reconstruire
- $y = (y_i) \in \mathbb{R}^I$ mesures d'atténuation cumulées $-\log(I/I_0)$ **observées** sur la ligne de réponse i définissant le sinogramme
- $A_{i,j}$: longueur d'intersection (ou contribution géométrique) du rayon i traversant le voxel j. La matrice système $\mathcal{R} = (A_{i,j})$ discrétise la transformée de Radon en 2D/3D
- $\mathcal{M}$: sélection des I droites effectivement acquises par les détecteurs (dépend de la trajectoire du tube : hélicoïdale, circulaire, ou sous-échantillonnée)
- L'image affichée est directement x_j convertie en échelle de gris.

Le Problème Inverse : échantillonnage complet : rétroprojection filtrée (FBP) par inversion de Fourier analytique ; sous-échantillonnage (sparse-view CT, réduction de dose) : problème mal posé, reconstruction régularisée.

2. Le bruit initial suit une loi de Poisson (comptage de photons), mais la transformée logarithmique permet de l'approcher le bruit résiduel par une loi de Gauss pour des doses standards.

IRM : principe

En IRM, on n'acquiert pas directement une image de l'espace réel, mais ses fréquences spatiales.

- Le corps contient des protons dans la graisse, les muscles, les sucres et l'eau (atomes H^+ avec un pole negatif et un pole positif).
- L'IRM génère un champ magnetique B_0 qui tend a aligner les protons dans la direction du champ. En plus du champ magnetique, les protons ont leur propre rotation : précession. Ils ne sont pas en phase.
- Une impulsion transverse (perpendiculaire au champ B_0), synchronise les phases et créé un champ magnetique transverse. Mais les protons se desynchronisent rapidement et le champ magnetique tend a se réaligner sur B_0. Ceci génère un signal électrique capté par les appareils. Les caractéristiques du signal électrique reçu sont directement proportionnelles à la densité de protons.
- Lors du réalignement on appelle $T1$ (resp. $T2$) le temps auquel l'alignement longitudinal (resp. transverse) est à 63% de son maximum. Ces temps dépendent du type des tissus traversés par le champs magnétique.

IRM : principe et lien avec Fourier

- Protons soumis à un champ B_0 [3] : précession à la fréquence de Larmor $\omega = \gamma B_0$
- Impulsions radiofréquence et gradients de champ : le signal acquis est un échantillon de la transformée de Fourier de l'aimantation transverse m :

$$s(k) = \int m(x)\, e^{-2i\pi\, k\cdot x}\, dx + \varepsilon(k), \qquad \varepsilon \text{ bruit gaussien complexe}$$

- L'espace des k s'appelle le *k-space*. C'est l'espace des frequences spatiales. L'image s'obtient par transformée de Fourier inverse de s (le bruit reste gaussien complexe).
- Image en module : le bruit suit une loi de Rice (somme de lois de Rayleigh) et tend vers une loi de Gauss dans les zones de forte intensité

Point clé pour la suite

Acquérir tout le k-space prend du temps. Sous-échantillonner puis reconstruire est un problème inverse (CM3).

3. `https://www.youtube.com/watch?v=jLnuPKhKXVM`

IRM : séquences et contrastes

- Une *séquence* choisit les temps (TR, TE)[4] et donc la pondération du contraste ; en effet un temps TR court a tendance a attenuer le bruit dû aux mollécules d'eau car les tissus avec un temps T_1 long (comme l'eau) n'ont pas le temps de récupérer leur aimantation longitudinale.
- Contrastes usuels : **T1**, **T2**, **FLAIR**, diffusion (DWI), avec ou sans produit de contraste
- Une même anatomie donne des images d'aspect très différent selon la séquence
- Les intensités sont en unités arbitraires : deux examens du même patient ne sont pas directement comparables

Conséquence pour l'apprentissage

Les séquences disponibles varient d'un protocole à l'autre : le nombre et la nature des canaux d'entrée ne sont pas fixes. Les intensités doivent être normalisées.

4. TR : intervalle de temps qui sépare le début de deux impulsions de radiofréquence, TE : intervalle de temps entre l'application de l'impulsion RF initiale et le moment où l'antenne de la machine écoute et enregistre le signal électrique

IRM : séquences et contrastes

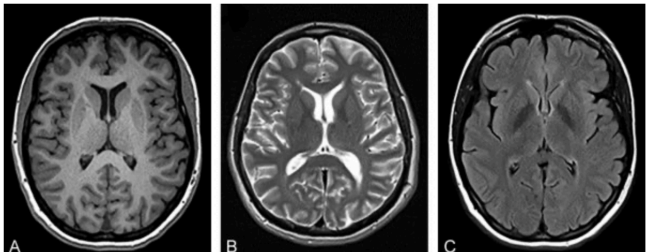


Figure 21.1

Coupes axiales encéphaliques T1 (A) T2 (B), FLAIR (C).
FLAIR : fluid-attenuated inversion recovery.

source : `https://www.cen-neurologie.fr/premier-cycle/les-fondamentaux-de-la-pathologie-neurologique/explorations-paracliniques-en-neurologie/chapitre-21-imagerie-par-resonance-magnetique`

Modèle mathématique de l'IRM

Problème direct (hyp : bruit gaussien complexe indépendant sur chaque mesure)

$$y_{c,i} = \sum_{j=1}^{J} S_{c,j}\, x_j\, e^{-2i\pi\, k_i \cdot r_j} + \varepsilon_{c,i}, \qquad \varepsilon_{c,i} \sim \mathcal{CN}(0, \sigma^2)$$

soit $y = \mathcal{A}x + \varepsilon$ avec $\mathcal{A} = \mathcal{M}\,\mathcal{F}\,\mathcal{S}$ linéaire (sensibilités, transformée de Fourier, masque d'échantillonnage)

- $x = (x_1, \ldots, x_J)^T \in \mathbb{C}^J$ aimantation transverse **inconnue** dans chaque voxel j, ie l'image à reconstruire
- $y = (y_{c,i}) \in \mathbb{C}^{N_c \times I}$ échantillons du k-space **observés** pour la bobine c à la position fréquentielle k_i
- r_j : position du voxel j ; $k_i = \frac{\gamma}{2\pi} \int_0^{t_i} G(u)\, du$: position dans l'espace de Fourier, imposée par les gradients G (γ : rapport gyromagnétique)
- $S_{c,j}$: sensibilité de la bobine c au voxel j (imagerie parallèle, $S \equiv 1$ pour une bobine)
- $\mathcal{M}$: sélection des I positions k_i effectivement acquises (sous-échantillonnage, facteur d'accélération R)
- L'image affichée est le module $|x_j|$: un bruit gaussien sur x devient un bruit de Rice sur $|x|$

Le Problème Inverse : échantillonnage complet : transformée de Fourier inverse ; sous-échantillonnage : problème mal posé, reconstruction régularisée (SENSE, compressed sensing, réseaux déroulés)

Échographie

- Ondes ultrasonores réfléchies aux interfaces entre tissus ; image *B-mode* reconstruite à partir des échos
  Le problème inverse consiste à reconstruire les propriétés physiques et structurelles internes d'un tissu (comme la carte de réflectivité acoustique) à partir des signaux électriques (échos) enregistrés par la sonde au cours du temps. Il s'agit d'un problème inverse linéaire ou bilinéaire, mal posé au sens de Hadamard [5], fortement corrompu par un bruit multiplicatif (le speckle).
- Non ionisante, peu coûteuse, temps réel (2D+t, parfois 3D)
- Bruit de speckle : multiplicatif, de nature interférentielle, structuré
  En échographie, le bruit de speckle est le résultat des interférences constructives et destructrices générées par un grand nombre d'ondes diffractées (ou diffusées) par les micro-structures du milieu.
- Forte dépendance à l'opérateur et à l'appareil : cadrage, pression de la sonde, réglages

Difficultés : ombres acoustiques, faible contraste, reproductibilité, grande variabilité des vues.

5. spectre avec valeurs propres proches de 0

Modèle mathématique de l'échographie

Problème direct (hyp : approximation de Born – diffusion simple, sans atténuation ni diffusion multiple)

$$y_i = \sum_{j=1}^{J} H_{ij}\, x_j + n_i, \qquad n_i \sim \mathcal{N}(0, \sigma^2)$$

Cas 1D le long d'une ligne de tir : $y(t) = \int h\big(t - \frac{2z}{c}\big)\, x(z)\, dz + n(t)$

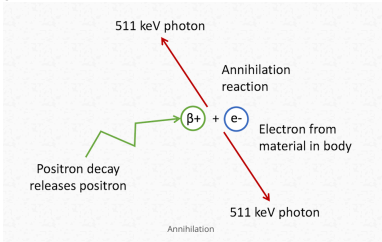
- $x = (x_1, \ldots, x_J)^T$ réflectivité acoustique (variations d'impédance) **inconnue** en chaque point j du milieu, ie l'image à reconstruire
- $y = (y_1, \ldots, y_I)^T$ signal radiofréquence (RF) **observé** : échantillons temporels t_i reçus par les éléments de la sonde

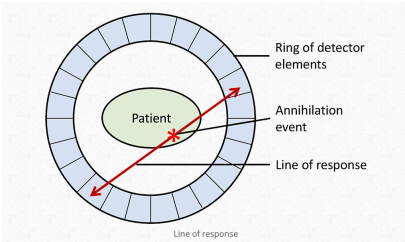
- $H_{ij} = h(t_i - \tau_{ij})$: l'impulsion émise h retardée par le temps de vol $\tau_{ij} = \big(\|r_j - e_{\text{émission}}\| + \|r_j - e_{\text{réception}}\|\big)/c$, $c \approx 1540$ m/s dans les tissus mous
- **Speckle** : si la cellule de résolution contient de nombreux diffuseurs non résolus, x est localement quasi gaussien et l'enveloppe $|y|$ suit une loi de Rayleigh
- Image B-mode : formation de voies (somme avec retards, *delay-and-sum*), enveloppe (transformée de Hilbert), compression logarithmique

Le Problème Inverse : formation de voies puis enveloppe ; ou déconvolution/reconstruction régularisée de x à partir de y

Médecine nucléaire : Positron Emission Tomography (PET) et Single-Photon Emission Computed Tomography (SPECT)

- Injection d'un traceur radioactif (par exemple FDG pour le métabolisme du glucose) qui emet des photons.
- PET : détection de coïncidences [6], reconstruction tomographique à partir de comptages de particules





source : `https://www.radiologycafe.com/frcr-physics-notes/molecular-imaging/pet-imaging/`

6. Une coïncidence définit une droite dans l'espace reliant les deux détecteurs, appelée Ligne de Réponse (LOR), qui enregistre un atome radioactif.

Modèle mathématique du PET

Problème direct (hyp : independance sur chaque LOR)

$$y_i \sim \mathcal{P}(\bar{y}_i)$$

L'espérance du nombre de coups $\bar{y}_i$ reçus sur la ligne i est liée linéairement à l'activité des voxels par la matrice de projection A (la matrice système) :

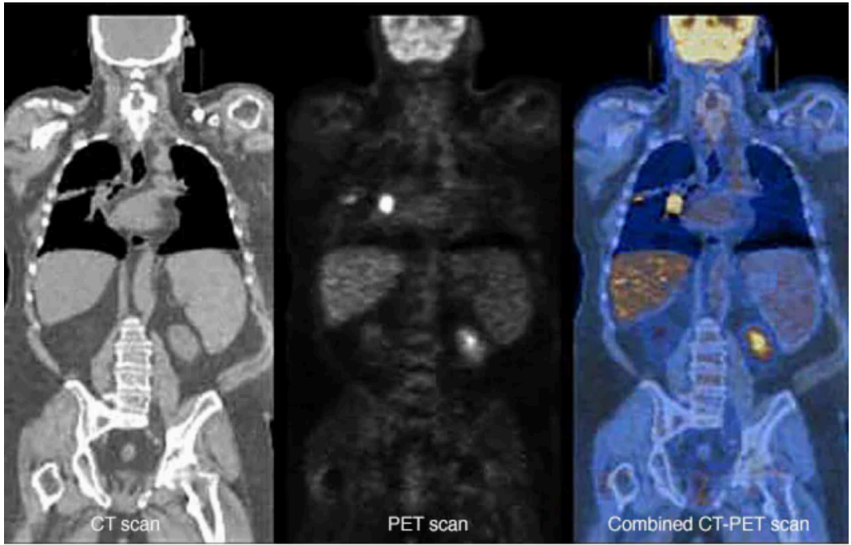
$$\bar{y}_i = \sum_{j=1}^{J} A_{ij} x_j + r_i + s_i$$

- $x = (x_1, \ldots, x_J)^T$ activité radioactive **inconnue** dans chaque voxel j ie l'image à reconstruire
- $y = (y_1, \ldots, y_I)^T$ nombre de coïncidences **observées** pour chaque LOR i
- A_{ij} : probabilité géométrique qu'un photon émis depuis le voxel j soit détecté sur la LOR i
- r_i et s_i modélisent les événements parasites (coïncidences fortuites ou diffusées), souvent estimés au préalable.

Le Problème Inverse : Algorithme MLEM (Maximum Likelihood Expectation Maximization)

Médecine nucléaire : Positron Emission Tomography (PET) et Single-Photon Emission Computed Tomography (SPECT)

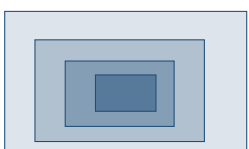
- Modèle de bruit : loi de Poisson sur les comptages, avec faible nombre d'évènements
- Imagerie *fonctionnelle* (activité) plutôt qu'anatomique ; résolution spatiale modeste
- Souvent couplée au CT ou à l'IRM (PET/CT, PET/IRM) : données multimodales recalées



© MAYO FOUNDATION FOR MEDICAL EDUCATION AND RESEARCH. ALL RIGHTS RESERVED.

Histopathologie et lames numérisées (WSI)

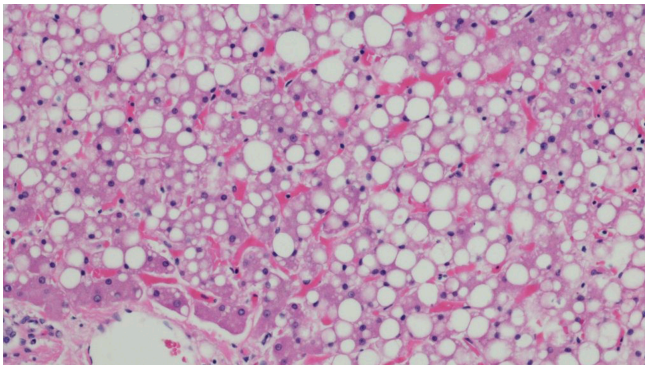
- Tissu coloré (typiquement H&E) puis numérisé à haute résolution
- Une lame entière (*whole-slide image*) est une image de l'ordre du gigapixel, stockée en pyramide multi-résolution
- Variabilité de coloration entre laboratoires, scanners et lots
- Annotations souvent faibles : un seul label par lame ou par patient



niveau 0 : résolution maximale

niveaux suivants : sous-échantillonnés

histopathologie, stéatose NAFLD



source : https://www.universimed.com/at/article/medecine-interne/steatose-hepatique-non-alcoolique-86339

Autres modalités

- **Ophtalmologie** : photographie du fond d'il (2D couleur) ; OCT (coupes *B*-scan de la rétine, 3D)
- **Dermatologie** : photographies et dermoscopie, conditions d'acquisition peu contrôlées
- **Endoscopie, chirurgie** : vidéo, contraintes de temps réel
- **Radiothérapie** : CT de planification, contours d'organes à risque
- **Imagerie préclinique, microscopie** : cellules, tissus, volumes optiques

Chaque modalité apporte sa physique, son bruit, ses artefacts et ses biais d'acquisition.

Récapitulatif des modalités

Modalité	Dimension	Rayonnement	Bruit / artefacts dominants	Valeurs
CT	3D	ionisant	Poisson (quantique), bruit corrélé	calibrées (HU)
IRM	3D / 4D	non ionisant	gaussien complexe, biais de champ	arbitraires
Échographie	2D, 2D+t	non ionisant	speckle, ombres	arbitraires
PET / SPECT	3D	traceur radioactif	Poisson, faible résolution	quantitatives
Histopathologie	2D gigapixel	aucun	variabilité de coloration	RGB

Les ordres de grandeur de résolution, de bruit et de dose dépendent fortement des appareils et des protocoles.

Une image comme fonction

Modèle continu puis discret :

$$x : \Omega \subset \mathbb{R}^d \to \mathbb{R}^C, \qquad d \in \{2, 3\},$$

observé sur une grille Ω_h (pixels, voxels) avec C canaux.

- Tenseur d'entrée de forme (C, H, W), (C, D, H, W), ou avec un axe temporel (C, T, D, H, W)
- Le voxel est un échantillon moyenné (volume partiel), pas un point
- Les voxels ne sont pas toujours isotropes : coupes épaisses dans une direction, résolution fine dans le plan

Question de modélisation

Faut-il traiter un volume en 3D, en coupes 2D, en 2.5D (coupes voisines comme canaux) ? Le choix dépend de la mémoire, de l'anisotropie et de la tâche.

Dimensions et contraintes mémoire

- **2D** : radiographie, photographie, une coupe
- **3D** : volume CT ou IRM, par exemple $512 \times 512 \times 300$ voxels
- **2D+t, 3D+t** : échographie cardiaque, IRM dynamique, IRM de perfusion
- **Gigapixel** : lames numérisées

Ordres de grandeur

Un volume $512 \times 512 \times 300$ en `float32` occupe environ 300 Mo. Une lame de $10^5 \times 10^5$ pixels RGB occupe environ 30 Go non compressée.

- Conséquences : découpage en *patchs*, lots très petits, entraînement sur sous-volumes, inférence par fenêtre glissante

Données multi-canaux et multi-séquences

- Un examen IRM cérébral typique : T1, T1 avec contraste, T2, FLAIR $\Rightarrow C = 4$ volumes
- Les canaux ne sont pas des couleurs : recalage préalable nécessaire
  Entre l'acquisition de la séquence T1 et de la séquence T2, le patient a pu bouger la tête de quelques millimètres.
  Chaque séquence est acquise avec sa propre matrice (ex : le T1 peut être une matrice 3D de 256 Œ 256 Œ 176 avec des voxels de $1mm^3$, tandis que le FLAIR peut être acquis en coupes épaisses de 2mm).
  Le Recalage Préalable (Registration) : Avant de donner ces images à un réseau de neurones, il faut trouver la transformation rigide ou affine T (rotation + translation) qui maximise une métrique de similarité entre les volumes. Ensuite, on interpole toutes les séquences sur une grille de voxels commune.
- Séquences manquantes : problème fréquent en pratique (robustesse aux modalités manquantes)

- Méthodes de fusion
  - concaténation en entrée : On empile les 4 volumes après recalage pour former un tenseur d'entrée de taille (4, H, W, D). La première couche de convolution 3D du réseau mélange immédiatement les informations des 4 séquences.
  - branches séparées puis fusion tardive : On crée 4 branches d'encodage parallèles et indépendantes (un sous-réseau par séquence). Chaque branche extrait les caractéristiques géométriques propres à sa physique. Les cartes de caractéristiques (feature maps) ne sont fusionnées (par concaténation ou somme) que très tard, juste avant les couches de décision.
  - mécanismes d'attention : On utilise des modules d'attention pour que les caractéristiques issues de la branche T1 viennent "interroger" les caractéristiques de la branche FLAIR. Le réseau apprend mathématiquement à quel endroit de l'image le FLAIR est plus informatif que le T1 pour guider la tâche finale (la segmentation ou la classification).

Très grandes images : le cas des lames numérisées

- Impossible de passer une lame entière dans un réseau : découpage en milliers de patchs
- Un seul label par lame $\Rightarrow$ apprentissage à instances multiples (MIL) :

$$\hat{y} = g\big(\{f_\theta(p_j)\}_{j=1}^{n}\big), \quad g \text{ invariante par permutation}$$

- Choix de g : moyenne, max, attention (agrégation pondérée apprise)
- Trade-off : résolution, contexte spatial, coût de calcul

Données multimodales : image et au-delà

- Image + compte rendu radiologique (texte)
- Image + données cliniques (âge, sexe, biologie) et données omiques (génomique, transcriptomique)
- Image + signaux temporels (ECG, signaux physiologiques)
- Combiner des modalités *hétérogènes* : espaces, dimensions et échelles différents

Défis

Données manquantes non aléatoires, alignement entre modalités, risque de sur-apprentissage lié à la grande dimension des variables omiques par rapport au nombre de patients.

Géométrie d'une image médicale

Une image médicale n'est pas qu'un tableau de nombres : elle vit dans l'espace du patient.

- Matrice affine voxel $\rightarrow$ monde :

$$\begin{pmatrix} x_{\text{physique}} \\ y_{\text{physique}} \\ z_{\text{physique}} \\ 1 \end{pmatrix} = \begin{pmatrix} A_{11} & A_{12} & A_{13} & T_x \\ A_{21} & A_{22} & A_{23} & T_y \\ A_{31} & A_{32} & A_{33} & T_z \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} i \\ j \\ k \\ 1 \end{pmatrix}$$

  La sous-matrice A gère l'orientation et la taille des voxels (spacing). Le vecteur colonne de droite $(T_x, T_y, T_z)^T$ gère la translation (le décalage d'origine).

- Conventions d'orientation (RAS, LPS) : source classique d'erreurs, par exemple une inversion gauche/droite
- Rééchantillonner à un espacement commun est souvent indispensable avant l'apprentissage

Formats de fichiers

DICOM

- Standard hospitalier
- Une image (ou une coupe) par fichier + métadonnées riches : patient, appareil, protocole, séries
- Données identifiantes à anonymiser

NIfTI

- Format de recherche : un volume par fichier
- En-tête compact avec géométrie (affine)
- Pratique pour le deep learning, mais pauvre en métadonnées

Autres : formats propriétaires de lames (SVS, NDPI), TIFF pyramidaux, NRRD. Bibliothèques : `pydicom`, `nibabel`, `SimpleITK`, `MONAI`.

Volumes

Ces fichiers contiennent notament les volumes (données enregistrées pour former les images). Ces volumes sont souvent projetés en différentes coupes.

- Coupe axiale : On fixe l'axe Z (la hauteur/supériorité) et on regarde la grille XY (Gauche-Droite / Droite-Gauche vs Avant-Arrière).
- Coupe coronale : On fixe l'axe Y (l'avant-arrière / Antérieur) et on regarde la grille XZ (Gauche-Droite vs Bas-Haut).
- Coupe sagittale : On fixe l'axe X (la gauche-droite / Right) et on regarde la grille YZ (Avant-Arrière vs Bas-Haut).

Prétraitement : normalisation d'intensités

- **CT** : fenêtrage (par exemple fenêtre poumon, os, tissus mous), puis normalisation affine
- **IRM** : valeurs arbitraires $\Rightarrow$ standardisation par volume (sur le masque du corps/cerveau), percentiles, correction du biais de champ (N4)
- **Histologie** : normalisation de la coloration, augmentations de couleur

Attention

Calculer les statistiques de normalisation *avant* la séparation train/test peut introduire une fuite d'information. Les paramètres doivent être estimés sur l'ensemble d'apprentissage uniquement.

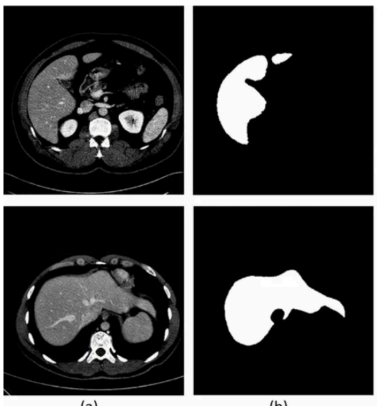
Recalage et rééchantillonnage

- **Recalage** : trouver $\varphi : \Omega \to \mathbb{R}^d$ telle que $M \circ \varphi \approx F$ (image mobile M sur image fixe F)
- Rigide, affine, déformable (difféomorphismes)
- Utilisé pour aligner les séquences, comparer des patients, définir des atlas
- Interpolation : plus proche voisin pour les labels, (tri)linéaire ou B-splines pour les intensités

Piège classique

Interpoler un masque de segmentation avec une interpolation linéaire crée des valeurs non entières. Les labels se rééchantillonnent par plus proche voisin.

Masques de segmentation (foie)



(a) CT images, (b) Masques

Classification et diagnostic

$$f_\theta : \mathcal{X} \to \Delta^{K-1}, \qquad \hat{y} = \arg\max_k f_\theta(x)_k$$

- Niveau image, examen, patient ou lame
- Exemples : présence d'une pathologie, grade, stade de rétinopathie, malin/bénin
- Une sortie probabiliste n'est pas nécessairement calibrée : $f_\theta(x)_k = 0{,}9$ ne signifie pas que l'on a raison dans 90 % des cas (CM5)
- Métriques : sensibilité, spécificité, AUC, valeurs prédictives (dépendent de la prévalence)

Détection et segmentation

- **Segmentation** : prédiction dense $s_\theta : \Omega_h \to \{0, \dots, K\}$ (un label par voxel)
- **Détection** : prédire des boîtes (ou des points) et un score pour chaque lésion
- Segmentation sémantique vs d'instances : séparer des lésions contiguës

Spécificités

Structures très petites devant le volume (déséquilibre voxel-à-voxel de plusieurs ordres de grandeur), frontières floues, topologie à respecter (connexité, nombre de composantes). Détaillé au CM2.

Reconstruction et problèmes inverses

$$y = \mathcal{A}x + \varepsilon$$

- x : image inconnue ; $\mathcal{A}$: opérateur direct (Radon, Fourier sous-échantillonné, ...) ; ε : bruit
- Problème mal posé ou mal conditionné : régularisation $\min_x \frac{1}{2}\|\mathcal{A}x - y\|^2 + \lambda\mathcal{R}(x)$
- Apprentissage : réseaux déroulés, a priori appris, modèles génératifs
- Risque : *hallucinations* plausibles mais fausses, instabilité

Traité en détail au CM3.

Pronostic, survie et génération

Pronostic et survie

- Données censurées : (T_i, δ_i)
- Risque instantané $h(t \mid x)$
- Perte de vraisemblance partielle de Cox, ou modèles discrets
- Métriques : indice de concordance

Génération et synthèse

- Modéliser $p(x)$ ou $p(x \mid c)$: GAN, VAE, diffusion
- Synthèse inter-modalités (IRM $\rightarrow$ CT)
- Augmentation de données, données synthétiques
- Risque : artefacts crédibles mais faux

Difficulté 1 : peu de données annotées

- Les annotations nécessitent des experts : coûteuses, lentes, parfois indisponibles
- Jeux de données typiques : quelques dizaines à quelques milliers d'examens, loin des corpus d'images naturelles
- Peu de patients pour de nombreuses variables $\Rightarrow$ sur-apprentissage
- Pistes (CM4) : transfert, auto-supervision, annotations faibles, augmentation, données synthétiques

Remarque

L'unité statistique est le patient, pas l'image ni la coupe : mille coupes d'un même patient ne valent pas mille observations indépendantes.

Difficulté 2 : annotations bruitées et variabilité inter-experts

- Même pour un expert, la frontière d'une lésion est souvent subjective
- Désaccord *inter-experts* et *intra-expert* non négligeable
- Où est la ń vérité terrain ż ? Annotations de plusieurs experts, fusion (STAPLE, vote majoritaire) ou conservation de la distribution des annotations
- Un modèle ne peut pas faire mieux que le bruit d'annotation sur les métriques usuelles, et l'on peut sur-apprendre ce bruit

Lien avec les incertitudes

Cette variabilité est une incertitude *aléatoire* que le modèle devrait représenter plutôt que d'ignorer (CM5).

Difficulté 3 : déséquilibre et haute dimension

- **Déséquilibre de classes** : pathologie rare (faible prévalence), lésions minuscules devant le volume
- Conséquences : précision globale trompeuse, gradient dominé par la classe majoritaire
- Remèdes : pondération, échantillonnage, fonctions de coût adaptées (Dice, focal), mais aussi métriques adaptées à la prévalence
- **Haute dimension** : entrées de 10^7 voxels ou plus, mémoire GPU limitée
- Compromis entre résolution, champ de vue et taille de lot

Difficulté 4 : décalage de domaine

Entraînement sur $P_{\text{source}}(x, y)$, déploiement sur $P_{\text{cible}}(x, y)$ avec $P_{\text{cible}} \neq P_{\text{source}}$.

- Sources : constructeurs, scanners, protocoles, reconstruction, coloration, populations, hôpitaux
- *Covariate shift* : $P(x)$ change mais $P(y \mid x)$ reste stable (cas idéal)
- *Label shift*, changement de prévalence, changement de concept
- Un modèle excellent sur son centre peut se dégrader fortement sur un autre

Pratique

Seule une *validation externe* (autre centre, autre appareil) donne une idée de la performance réelle.

Difficulté 5 : raccourcis et biais

- Le modèle apprend ce qui prédit le label dans les données, pas nécessairement ce qui est cliniquement pertinent
- Exemples documentés : prédiction du site d'acquisition, marqueurs ou annotations incrustés sur l'image, type d'appareil corrélé à la prévalence
- Biais de sélection : patients étudiés non représentatifs de la population cible
- Biais d'équité : performances différentes selon l'âge, le sexe, l'origine

Réflexe de validation

Tester des variables de confusion connues (site, appareil), vérifier que les performances sont stables par sous-groupe, inspecter les cas d'erreur.

Difficulté 6 : évaluation et fuite de données

- Séparer train/validation/test par patient (jamais par image ou par coupe)
- Examens multiples du même patient, lésions bilatérales : tout doit rester du même côté
- Normalisations, sélection d'hyperparamètres et d'architectures : uniquement sur l'apprentissage et la validation
- Petits jeux de test : intervalles de confiance larges (bootstrap, validation croisée imbriquée)
- Métriques : le choix de la métrique doit refléter la question clinique

Conséquence

Une performance ń excellente ż dans la littérature est parfois due à une fuite de données. Mesurer correctement est une compétence à part entière.

Pourquoi l'incertitude ? (aperçu du CM5)

- En médecine, une prédiction sans mesure de confiance est de peu d'utilité pour la décision
- Deux sources :
  - **aléatoire** : liée aux données (bruit, frontières floues, désaccord d'experts), irréductible
  - **épistémique** : liée au modèle et au manque de données, réductible avec plus de données
- Usages : signaler les cas à relire par un expert, détecter des entrées hors distribution, calibrer le risque

Exemple de formulation

Sortie probabiliste $p_\theta(y \mid x)$; incertitude prédictive $\mathrm{H}[p(y \mid x)]$ décomposable en partie aléatoire et épistémique (information mutuelle).

Cadre éthique et réglementaire

- **Données de santé** : RGPD, consentement, anonymisation (suppression des métadonnées DICOM identifiantes, *défacement* des IRM cérébrales)
- **Dispositif médical** : un logiciel d'aide au diagnostic relève de la réglementation (marquage CE, règlement européen sur les dispositifs médicaux), avec exigences de validation clinique
- **Responsabilité** : le modèle assiste, le clinicien décide
- Transparence, traçabilité, documentation des jeux de données et des modèles

Ces aspects conditionnent le passage d'un prototype de recherche à une utilisation clinique.

Ce qu'il faut retenir

1. Chaque modalité a sa physique, son bruit et ses artefacts : le modèle d'acquisition guide le choix de modèle
2. Les données sont des fonctions sur l'espace du patient : géométrie, spacing, orientation comptent
3. Les tâches se formalisent comme classification, prédiction dense, problème inverse, recalage, survie, génération
4. Les difficultés propres : peu d'annotations, bruit d'annotation, déséquilibre, décalage de domaine, raccourcis, fuite de données
5. Une prédiction utile en clinique est une prédiction accompagnée d'une mesure de confiance

TP1 : manipuler des données d'imagerie

Objectifs

- Lire des fichiers DICOM et NIfTI (`pydicom`, `nibabel`, `SimpleITK`), inspecter métadonnées et géométrie
- Visualiser des coupes (axiale, coronale, sagittale), vérifier l'orientation
- Normaliser les intensités (fenêtrage CT, z-score IRM) et comparer les histogrammes entre centres
- Rééchantillonner à un espacement commun (plus proche voisin pour les labels)
- Mettre en place une séparation train/test *par patient*

Outils : Python, `MONAI`, `matplotlib`. Jeux de données publics de taille réduite.

Références I

- G. Litjens et al., *A survey on deep learning in medical image analysis*, Medical Image Analysis, 2017.
- O. Ronneberger, P. Fischer, T. Brox, *U-Net : convolutional networks for biomedical image segmentation*, MICCAI, 2015.
- F. Isensee et al., *nnU-Net : a self-configuring method for deep learning-based biomedical image segmentation*, Nature Methods, 2021.
- J. Zbontar et al., *fastMRI : an open dataset and benchmarks for accelerated MRI*, 2018.
- V. Antun et al., *On instabilities of deep learning in image reconstruction and the potential costs of AI*, PNAS, 2020.
- J. R. Zech et al., *Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs*, PLOS Medicine, 2018.
- A. Kendall, Y. Gal, *What uncertainties do we need in Bayesian deep learning for computer vision ?*, NeurIPS, 2017.
- L. Maier-Hein et al., *Metrics reloaded : recommendations for image analysis validation*, Nature Methods, 2024.
- M. J. Cardoso et al., *MONAI : an open-source framework for deep learning in healthcare*, 2022.

Prochaine séance

CM2 – Segmentation et détection

- Du CNN de classification à la prédiction dense : U-Net et variantes, nnU-Net
- Fonctions de coût (Dice, cross-entropie pondérée, focal, Tversky)
- Métriques d'évaluation et leurs pièges
- Détection de lésions

Questions ?