Apprentissage profond en imagerie médicale

CM2 – Segmentation et détection

Master de mathématiques

IRMAR – Université de Rennes

Rappel et programme de la séance

Acquis du CM1 : modalités, types de données, géométrie, difficultés (peu d'annotations, déséquilibre, décalage de domaine, fuite de données).

Plan

Le problème de segmentation

Étant donnée une image $x : \Omega_h \to \mathbb{R}^C$, prédire un label par voxel :

$$s : \Omega_h \to \{0, 1, \ldots, K\}, \qquad \text{ou, de façon probabiliste,} \quad p_\theta(x) : \Omega_h \to \Delta^K.$$

- **Sémantique** : un label de classe par voxel (organe, lésion, fond)
- **Instance** : distinguer plusieurs objets de même classe (plusieurs lésions, plusieurs noyaux cellulaires)
- **Panoptique** : combinaison des deux

Applications cliniques

Volumétrie d'organes et de lésions, suivi de tumeurs, planification de radiothérapie (organes à risque), chirurgie guidée, extraction de caractéristiques quantitatives (radiomique).

Pourquoi un CNN de classification ne suffit pas

- Un CNN de classification réduit la résolution spatiale (convolutions, pooling, *stride*) puis agrège : la sortie est un vecteur, et non une carte
- On veut une sortie de même taille spatiale que l'entrée
- Compromis fondamental :
  - *contexte* : grand champ réceptif pour comprendre "où l'on est" (quel organe, quelle structure)
  - *localisation* : résolution fine pour tracer des frontières précises
- L'architecture doit combiner les deux types d'information

Idée directrice

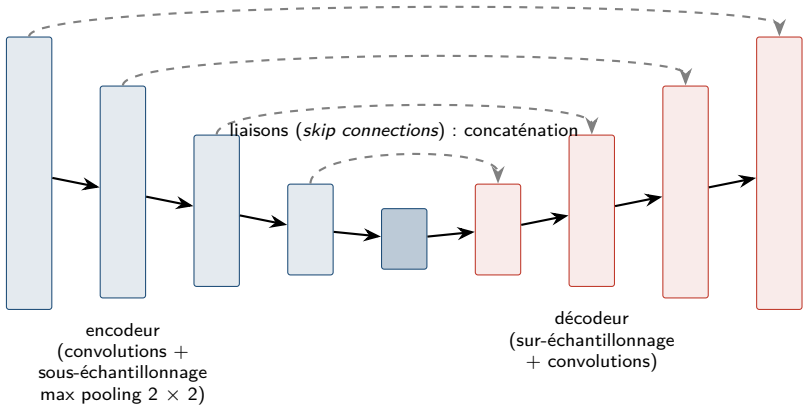
Un encodeur qui capte le contexte à basse résolution, un décodeur qui rétablit la résolution, et des liaisons qui transportent les détails fins de l'encodeur vers le décodeur.

Réseaux entièrement convolutifs (FCN)

- Remplacer les couches entièrement connectées (ie couches MLP) par des convolutions 1×1 : le réseau accepte des entrées de taille arbitraire
- Sortie à basse résolution, puis sur-échantillonnage jusqu'à la taille de l'entrée :
  - interpolation (bilinéaire, trilinéaire)
  - convolution transposée apprise [1]
- FCN (Long, Shelhamer, Darrell, 2015) : fusion de cartes de différentes profondeurs (idée de *skip connections*)

1. La convolution transposée (ou "déconvolution") est la méthode la plus courante et la plus puissante, car ses filtres sont appris par le réseau pendant l'entraînement. La convolution transposée insère des zéros entre les pixels de la carte de caractéristiques, puis applique un filtre glissant. Ainsi elle permet de doubler la résolution spatiale tout en réduisant le nombre de canaux. Le réseau apprend lui-même comment "remplir" les vides de manière intelligente pour reconstruire les contours précis.

U-Net : architecture



- À chaque niveau : blocs conv–norm–activation ; encodeur : divisions de la résolution par 2, doublement du nombre de canaux
- Décodeur : sur-échantillonnage, concaténation avec la carte de l'encodeur de même résolution, convolutions

U-Net : pourquoi cela fonctionne

- **Champ réceptif** : après L niveaux de sous-échantillonnage par 2, une convolution 3×3 voit une région de taille de l'ordre de 2^L fois celle du niveau initial
- Les liaisons transportent des **détails fins** (frontières, textures) directement vers le décodeur : le goulot d'étranglement n'a plus à tout mémoriser
- La concaténation laisse le décodeur *choisir* comment combiner contexte et détail (contrairement à une addition)
- Très efficace avec peu de données (quelques dizaines d'images annotées) grâce à l'augmentation de données

Perspective de mathématicien

Un U-Net peut se lire comme une approche multi-échelle (type pyramide, ondelettes) où les représentations de différentes résolutions sont apprises et mélangées. Des travaux le rapprochent d'un schéma multigrille.

Variantes d'architecture

Évolutions convolutives

- **3D U-Net**, **V-Net** : convolutions 3D, volumes natifs
- **U-Net++** : liaisons denses imbriquées
- **Attention U-Net** : portes d'attention sur les liaisons
- **Residual U-Net** : blocs résiduels

Avec transformers

- **TransUNet** : encodeur hybride CNN + transformer
- **UNETR**, **Swin UNETR** : encodeur transformer, décodeur convolutif
- Coût : attention quadratique en nombre de tokens, besoin de plus de données ou de préentraînement

Constat empirique important

Sur des benchmarks bien conduits, un U-Net convolutif bien configuré et entraîné reste très compétitif face aux variantes plus récentes. Le soin apporté au pipeline compte souvent plus que l'architecture.

Plan

Difficulté : le fond domine

Soit ρ la fraction de voxels de premier plan (ie la classe d'intérêt : organe, lésion). Un réseau qui prédit la même probabilité ρ partout, sans regarder l'image, est déjà "bon" au sens usuel :

- **Exactitude** (taux de voxels bien classés) : $1-\rho$, soit 99 % pour $\rho = 1\,\%$
- **Entropie croisée** : minimale pour $p \equiv \rho$, de valeur

  $$H(\rho) = -\rho \log \rho - (1-\rho)\log(1-\rho) \approx 0{,}056 \text{ (nat)}$$

  pour $\rho = 1\,\%$, alors que la perte du réseau parfait vaut 0

- Ordres de grandeur : rate $\approx 0{,}3\,\%$ d'un scanner abdominal, lésions tumorales $< 0{,}1\,\%$
- Le gain à attendre d'une vraie segmentation est *minuscule* devant la perte de départ : le signal utile est noyé
- Au début de l'entraînement, le réseau apprend d'abord à "tout mettre à 0"
- Avec des patchs tirés uniformément, beaucoup ne contiennent *aucun* voxel de premier plan

Quels remèdes quand le fond domine

Deux remèdes, qui se combinent

Sur les données d'entrainement : échantillonner les patchs en sur-représentant le premier plan (entraînement par patchs).

Sur la fonction de perte : choisir une fonction objectif insensible au nombre de vrais négatifs (coefficient de similarié de Dice, fonctions de perte pertes pondérées, fonction de perte Tversky).

Entropie croisée (CE)

Pour des probabilités $p_{i,k}$ et des labels one-hot $y_{i,k}$ sur les voxels $i = 1, \dots, N$:

$$\mathcal{L}_{\mathrm{CE}} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{k=0}^{K} y_{i,k} \log p_{i,k}.$$

- Fonction *décomposable* : somme de contributions par voxel, bien adaptée à l'optimisation stochastique
- Calibrée (propre au sens des règles de score) : l'espérance de la CE est minimisée par $q_k = \mathbb{P}(y = k \mid x)$ (inégalité de Gibbs) : les sorties du réseau s'interprètent comme des probabilités
- Problème : si la structure d'intérêt occupe 1 % des voxels, la perte est dominée par le fond ; prédire "fond partout" donne une perte faible

fonction de perte pondérées

Variante pondérée

$$\mathcal{L}_{\mathrm{wCE}} = -\frac{1}{N} \sum_i \sum_k w_k \, y_{i,k} \log p_{i,k}$$

avec w_k décroissant avec la fréquence de la classe k.

- Remédie au déséquilibre, mais déforme les probabilités.
  Le réseau estime la probabilité conditionnelle d'un problème où les classes ont été re-pondérées, c'est-à-dire où les priors de classe sont devenus $\propto w_k \pi_k$ avec π_k les priors initiauxxs.
- Le minimiseur devient $q_k \propto w_k \, \mathbb{P}(y = k \mid x)$: on estime les probabilités dun problème re-pondéré (décalage de prior), corrigeable par $\eta_k \propto q_k / w_k$
- Rq : le sur-échantillonnage du premier plan dans les patchs agit de la même façon : il change la proportion de premier plan vue à lentraînement. Les probabilités sorties sont alors elles aussi à corriger, avec le même type de formule (rapport des priors).

Coefficient de similarité de Dice et IoU (définition)

Pour une prédiction binaire P et une référence G (ensembles de voxels) :

$$\mathrm{Dice}(P,G) = \frac{2|P \cap G|}{|P| + |G|} = \frac{2\,TP}{2\,TP + FP + FN}, \qquad \mathrm{IoU}(P,G) = \frac{|P \cap G|}{|P \cup G|} = \frac{TP}{TP + FP + FN}.$$

- Le coefficient de similarité de Dice est exactement le score F_1 de la classification voxel à voxel
- Relation : $\mathrm{IoU} = \dfrac{\mathrm{Dice}}{2 - \mathrm{Dice}}$ (fonction croissante : les deux classent les modèles de la même façon sur un cas, mais pas nécessairement après moyennage sur plusieurs cas)
- *Insensibles* au grand nombre de vrais négatifs : adaptées aux structures petites

Fonction de perte ?

Ce sont des fonctions *globales* de la prédiction qu'on pourrait utiliser comme fonction de perte, mais elles ne sont pas décomposables en somme sur les voxels, et ni différentiables si l'on binarise

$$\hat{y}_i = \mathbf{1}\{p_i > 0{,}5\}, \qquad \mathrm{Dice} = \frac{2\sum_i \hat{y}_i y_i}{\sum_i \hat{y}_i + \sum_i y_i}.$$

.

La fonction de perte de Dice lissée

On relaxe la binarisation : $p_i \in [0,1]$ probabilité de premier plan (ie de la classe d'intérêt), $y_i \in \{0,1\}$.

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2\sum_i p_i g_i + \varepsilon}{\sum_i p_i + \sum_i y_i + \varepsilon}.$$

avec $I = \sum_i p_i y_i$ et $U = \sum_i p_i + \sum_i y_i$, le gradient s'écrit

$$\frac{\partial \mathcal{L}_{\text{Dice}}}{\partial p_j} = -\frac{2\,(y_j U - I)}{U^2} \qquad (\varepsilon \to 0).$$

- Pour un voxel de premier plan ($y_j = 1$) : gradient négatif, pousse p_j vers 1 ; pour un voxel de fond ($y_j = 0$) : gradient $2I/U^2 \geq 0$, pousse p_j vers 0
- Le gradient dépend de *toute l'image* via I et U : couplage global entre voxels
- Si $I \approx 0$ (début d'entraînement) ou si le masque est vide ($U \approx 0$), le gradient du Dice est nul sur le fond et très grand sur peu de voxels, voire mal défini (0/0) : on ajoute une constante de lissage ε au numérateur et au dénominateur et l'on combine avec l'entropie croisée, dont le gradient $p_i - y_i$ reste borné.

Fonction de perte de Dice en pratique : choix de calcul

- **Par lot** (somme sur tout le lot) ou **par image** (puis moyenne) : le comportement diffère pour les cas vides ou très petits
- **Multi-classes** : moyenne des coefficients de Dice par classe (chaque classe pèse autant), éventuellement en excluant le fond
- **Cas vide** ($G = \emptyset$) : le Dice vaut ε/ε ou $0/0$; la convention et le ε changent le signal d'apprentissage
- **Combinaison usuelle** : $\mathcal{L} = \alpha \mathcal{L}_{\mathrm{CE}} + (1-\alpha)\mathcal{L}_{\mathrm{Dice}}$
  - CE : gradients bien conditionnés, probabilités mieux calibrées
  - Dice : insensibilité au déséquilibre

Inconvénient connu

Les modèles entraînés avec une fonction de perte de Dice sont souvent *sur-confiants* : probabilités proches de 0 ou 1, mal calibrées. Gênant pour l'estimation d'incertitude (CM5).

Autres fonctions de pertes

- **Fonction de perte de Tversky** : généralise le Dice avec des poids α, β sur FP et FN :

$$\mathcal{T}_{\alpha,\beta} = \frac{TP}{TP + \alpha\, FP + \beta\, FN}$$

  ($\alpha = \beta = \frac{1}{2}$ redonne le Dice). Choisir $\beta > \alpha$ pour pénaliser davantage les faux négatifs (lésions manquées).
- **Fonction de perte focale** : $-\sum_i (1 - p_{i,y_i})^\gamma \log p_{i,y_i}$; réduit le poids des voxels faciles, utile en détection et pour de très forts déséquilibres
- **Extension de Lovász** : substitut convexe de la perte de Jaccard, optimisation directe de l'IoU via l'extension de Lovász d'une fonction sous-modulaire
- **Fonction de pertes de frontière / de distance** : prise en compte de la distance aux contours (carte de distance signée)
- **Fonction de pertes topologiques** (clDice) : préservent la connexité des structures tubulaires (vaisseaux)

Choisir sa fonction de perte : une grille de lecture

Situation	Perte conseillée	Raison
Structure volumineuse, peu de déséquilibre	CE (ou CE + Dice)	stable, calibrée
Petite structure, fort déséquilibre	Dice + CE, Tversky	robuste au fond dominant
Faux négatifs coûteux (lésions)	Tversky ($\beta > \alpha$), focale	sensibilité privilégiée
Structures fines et connexes (vaisseaux)	Dice + clDice	contrainte topologique
Besoin de probabilités calibrées	CE (+ calibration a posteriori)	Dice sur-confiant
Référence par défaut	Dice + CE	nnU-Net

Rappel

La fonction de perte doit refléter la question clinique, pas seulement une métrique de challenge.

Plan

Entraînement par patchs

- Un volume complet ne tient pas en mémoire : entraînement sur des **patchs** (par exemple 128^3 voxels)
- **Échantillonnage des patchs** : uniforme (dominé par le fond) ou avec sur-échantillonnage du premier plan (par exemple, une fraction fixe des patchs centrée sur un voxel de la classe d'intérêt)
- Lots de taille très petite (parfois 2) : la normalisation par lot devient instable $\Rightarrow$ *instance norm*, *group norm*
- Augmentations *spatiales* (rotations, mise à l'échelle, déformations élastiques, miroirs) et *d'intensité* (bruit, flou, gamma, contraste)

Principe

Les augmentations doivent rester *plausibles médicalement* : un miroir gauche/droite peut être invalide pour un organe asymétrique (foie, coeur).

Supervision profonde et post-traitement

- **Supervision profonde** (*deep supervision*) : ajouter des têtes de prédiction auxiliaires aux niveaux intermédiaires du décodeur, avec une perte à chaque résolution (sur des masques sous-échantillonnés) :

$$\mathcal{L} = \sum_{\ell} \alpha_\ell \, \mathcal{L}\big(p^{(\ell)}, \, g^{(\ell)}\big)$$

  Améliore la propagation des gradients et accélère l'entraînement

- **Post-traitement** : conserver la plus grande composante connexe (organe unique), remplir les trous, supprimer les très petites composantes isolées

Attention

Le post-traitement encode un *a priori* anatomique : à valider, car il peut aussi supprimer de vraies petites lésions.

Plan

Inférence par fenêtre glissante

- Dans l'ensemble de test, on prédit sur l'ensemble du volume en parcourant des patchs qui se recouvrent (typiquement 50 %)
- Les prédictions sont moyennées dans les zones de recouvrement, avec une pondération qui favorise le centre du patch (par exemple une gaussienne) car les bords sont moins fiables (peu de contexte)
- **Augmentation au test** (*test-time augmentation*) : L'augmentation au test (test-time augmentation, TTA) consiste à prédire plusieurs fois sur des versions transformées du même volume, puis à moyenner les prédictions. Ceci permet de réduire la variance.

$$\hat{p}(v) = \frac{\sum_j w_j(v)\, p^{(j)}(v)}{\sum_j w_j(v)},$$

où $p^{(j)}$ est la prédiction du patch j et $w_j(v)$ un poids décroissant avec la distance de v au centre du patch.

2D, 2.5D ou 3D ?

	Avantages	Inconvénients
2D (coupe par coupe)	léger en mémoire, bien adapté aux coupes très épaisses, bénéficie du préentraînement 2D	ignore le contexte entre coupes, incohérences inter-coupes
2.5D (coupes voisines en canaux)	contexte partiel peu coûteux	fenêtre axiale fixe et limitée
3D (patchs 3D)	contexte volumique complet, cohérence spatiale	mémoire GPU, lots très petits, plus de paramètres

- Le choix dépend de l'anisotropie des données (cf. CM1), de la mémoire et de la taille des structures
- Les approches mixtes (cascades : basse résolution puis haute résolution) sont courantes

Plan

Trois familles de métriques

- **Recouvrement** (*overlap*) : Dice, IoU, sensibilité, précision
- **Distance entre contours** : distance de Hausdorff, distance moyenne de surface
- **Surface avec tolérance** : Dice de surface normalisé (NSD)
- **Volume** : erreur relative de volume, biais de Bland–Altman (importante cliniquement : mesure d'un volume tumoral)

Aucune métrique ne capture tout

Deux segmentations de même coefficient de Dice peuvent avoir des défauts très différents : une frontière légèrement décalée partout, ou un bon recouvrement avec une petite composante aberrante lointaine. Les métriques doivent être choisies selon l'usage clinique.

Distance de Hausdorff et variantes

Pour deux surfaces A (prédiction) et B (référence), avec $d(a, B) = \min_{b \in B} \|a - b\|$:

$$d_H(A, B) = \max \left\{ \sup_{a \in A} d(a, B),\ \sup_{b \in B} d(b, A) \right\}.$$

- Mesure l'erreur la plus grande : très sensible aux valeurs aberrantes (un seul voxel égaré)
- **HD95** : on remplace le sup par le 95e percentile des distances, plus robuste
- **Distance moyenne de surface** (ASSD) : moyenne symétrique des distances, moins sensible aux aberrations
- **NSD** : proportion de points de surface à distance $\leq \tau$ de l'autre surface ; τ choisie selon la tolérance clinique

Les distances sont à calculer en millimètres (avec l'espacement des voxels) et non en voxels.

Pièges des métriques de segmentation

1. **Structures vides** : si $G = \emptyset$ et $P = \emptyset$, coefficient de Dice indéfini ; convention explicite requise (parfois 1, parfois exclu)
2. **Moyenne par cas ou groupée** : le coefficient de Dice moyen par patient et le coefficient de Dice calculé sur l'ensemble des voxels regroupés pondèrent différemment les petits cas
3. **Dépendance à la taille** : un décalage d'un voxel détruit le coefficient de Dice d'une petite lésion mais change à peine celui d'un gros organe
4. **Résolution** : mêmes métriques non comparables entre résolutions différentes
5. **Référence imparfaite** : la variabilité inter-experts borne ce qui est atteignable (coefficient de Dice entre experts < 1)
6. **Statistiques** : moyennes sans dispersion ; petits jeux de test ; tests non appariés

Bonne pratique

Rapporter la distribution (boîtes à moustaches, quantiles) par cas, la métrique de recouvrement *et* une métrique de contour, et comparer au niveau de désaccord inter-experts. Voir *Metrics Reloaded* pour une démarche guidée.

Évaluation au niveau lésion

Au-delà du voxel : la question clinique est souvent "a-t-on *trouvé* la lésion ?".

- Appariement lésions prédites / lésions de référence (par recouvrement minimal, par distance entre centres)
- Comptages : lésions détectées (TP), manquées (FN), fausses détections (FP)
- **Sensibilité par lésion** et **faux positifs par examen**
- **Courbe FROC** : sensibilité en fonction du nombre moyen de faux positifs par examen, quand on fait varier le seuil de score

Remarque

Un modèle peut avoir un bon coefficient de Dice voxel-à-voxel (grosses lésions bien segmentées) tout en manquant plusieurs petites lésions : les deux niveaux d'évaluation sont complémentaires.

nnU-Net : un pipeline qui s'auto-configure

Idée : automatiser les décisions de conception qui comptent plus que l'architecture.

1. *Empreinte du jeu de données* : espacement médian, formes, statistiques d'intensité
2. *Règles fixes* déduites de l'empreinte : espacement cible, taille de patch, topologie du réseau (nombre de niveaux), normalisation
3. *Choix empiriques* : validation croisée parmi 2D, 3D pleine résolution, cascade ; assemblage et post-traitement

Ingrédients stables

- U-Net convolutif standard
- Perte somme Dice + entropie croisée
- Supervision profonde
- SGD avec momentum, décroissance polynomiale du pas
- Sur-échantillonnage du premier plan
- Augmentations riches

Leçon : une base de référence solide, sans ingénierie spécifique à chaque tâche, bat de nombreuses méthodes plus élaborées. À utiliser comme *baseline* avant toute contribution.

Plan

Le problème de détection

Prédire un ensemble $\{(b_j, c_j, s_j)\}_j$: boîte englobante b_j, classe c_j, score $s_j \in [0, 1]$.

- Boîtes 2D (x, y, w, h) ou 3D (x, y, z, w, h, d)
- Mesure de recouvrement boîte-à-boîte : $\text{IoU}(b, b') = |b \cap b'|/|b \cup b'|$
- Une prédiction est correcte si $\text{IoU} \geq \tau$ avec une boîte de référence non déjà appariée

Spécificités médicales

Objets de tailles très variables (nodules de quelques millimètres à masses de plusieurs centimètres) ; nombre d'objets inconnu, souvent nul ; très peu de positifs dans les images ; coût asymétrique FN/FP.

Détecteurs en deux étapes et en une étape

Deux étapes (Faster R-CNN)

1. Un réseau de propositions de régions (RPN) génère des candidats à partir d'ancres
2. Un second réseau classe chaque candidat et affine la boîte

Précis, plus lent. Mask R-CNN ajoute une branche de masque (segmentation d'instances).

Une étape (YOLO, RetinaNet)

- Prédiction directe de boîtes et classes sur une grille de positions
- Rapide, bien adapté au temps réel (endoscopie, échographie)
- RetinaNet : perte focale pour gérer le déséquilibre fond/objet

- **Ancres** : boîtes de référence de plusieurs tailles et formes, centrées en chaque position
- Fonction de coût : classification (CE ou focale) + régression de boîte (lissée L_1, IoU généralisée)

Suppression des non-maxima (NMS)

Le détecteur produit plusieurs boîtes quasi superposées pour un même objet. NMS les fusionne :

1. Trier les boîtes par score décroissant
2. Garder la première ; supprimer toutes celles dont l'IoU avec elle dépasse un seuil
3. Répéter avec la boîte restante la mieux classée

Limites

Seuil délicat : trop bas, on supprime des objets proches (lésions adjacentes) ; trop haut, on garde des doublons. Des variantes douces (Soft-NMS) atténuent les scores au lieu de les éliminer.

Pas de NMS dans les approches par *prédiction directe d'ensemble* (DETR et dérivés, par appariement hongrois entre prédictions et références).

Détection par cartes de chaleur et points d'intérêt

- Alternative aux boîtes : régresser une carte de chaleur dont les maxima locaux indiquent les objets (centres de lésions, noyaux, repères anatomiques)
- Cible : somme de gaussiennes centrées sur les positions de référence :

$$h(x) = \max_j \exp\left(- \frac{\|x - c_j\|^2}{2\sigma^2} \right)$$

- Perte : erreur quadratique ou focale sur la carte ; détection par recherche de maxima locaux au-dessus d'un seuil
- Utilisé pour la localisation de repères anatomiques, la détection de cellules, le comptage

Lien avec la segmentation

La détection par carte de chaleur est une segmentation avec une cible *molle* : on réutilise un U-Net, le choix de σ règle le compromis précision de localisation / facilité d'apprentissage.

Détection d'anomalies (aperçu)

- Quand les pathologies sont variées ou rares, difficile d'annoter toutes les classes : on apprend la distribution du ń normal ż et on détecte l'écart
- Approches : auto-encodeurs, modèles génératifs, erreur de reconstruction ; modèles de diffusion
- Score d'anomalie par voxel $\Rightarrow$ carte de détection

Limites

Une grande variabilité normale (anatomique, d'acquisition) produit de nombreux faux positifs ; difficile d'obtenir des garanties. Lien avec la détection hors-distribution traitée en CM5.

Plan

Segmentation d'instances

- **Problème** : lésions ou cellules adjacentes, qu'une segmentation sémantique fusionne en une seule composante
- **Approches**
  - Mask R-CNN : détecter puis segmenter chaque boîte
  - Prédire en plus une carte de distance au bord ou un champ de vecteurs vers le centre, puis séparer par *watershed* ou regroupement
  - Approches par prédiction de forme (étoile-convexe : StarDist) pour les noyaux cellulaires
- **Évaluation** : appariement d'instances, qualité panoptique

Applications

Comptage de noyaux (histopathologie), décompte de lésions métastatiques, suivi longitudinal des lésions individuelles.

Topologie et contraintes anatomiques

- Une segmentation pixelwise ne garantit pas la cohérence topologique : trous, fragments isolés, vaisseaux interrompus
- Moyens d'incorporer des a priori :
  - post-traitement (composante connexe)
  - perte topologique (clDice, perte d'homologie persistante)
  - contraintes de forme (modèles statistiques, auto-encodeurs de formes)
  - représentations implicites : régresser une *fonction distance signée* plutôt qu'un masque binaire

Mathématiques concernées

Homologie persistante, fonctions distance, courbes de niveau et méthodes de surfaces implicites (*level sets*) : outils naturels pour exprimer et imposer des propriétés géométriques et topologiques.

Plan

Ce qu'il faut retenir

1. Segmenter = prédire un label par voxel : encodeur–décodeur + liaisons (U-Net) combinent contexte et localisation
2. En 3D, l'entraînement par patchs, l'inférence par fenêtre glissante et la supervision profonde sont des ingrédients de base ; nnU-Net est la référence
3. Les fonctions de coût de recouvrement (Dice, Tversky) compensent le déséquilibre, mais ne sont pas calibrées et diffèrent de la décision optimale
4. Les métriques doivent être choisies selon la question clinique : recouvrement + contour + niveau lésion, avec distribution par cas
5. La détection relève d'autres outils (ancres, NMS, cartes de chaleur, FROC)

TP2 : segmentation d'organe avec un U-Net

Données : une tâche du Medical Segmentation Decathlon (par exemple rate ou cur), prétraitée comme au TP1.

1. Construire le pipeline MONAI : chargement, rééchantillonnage, normalisation, patchs avec sur-échantillonnage du premier plan, augmentations
2. Entraîner un **U-Net 3D** (MONAI `UNet` ou `DynUNet`) avec trois pertes : CE, Dice, Dice + CE
3. Inférence par fenêtre glissante (`sliding_window_inference`), post-traitement (plus grande composante connexe)
4. Évaluer : Dice, HD95, volume ; distribution par patient
5. Comparer les pertes : courbes d'apprentissage, métriques, histogramme de confiance (probabilités proches de 0/1 ou non ?)
6. Analyse d'erreurs : cas où le modèle échoue, effet de la taille de la structure

Matériel : GPU recommandé (Colab possible) ; version réduite (sous-ensemble, résolution plus grossière) pour tenir en séance.

Références I

- J. Long, E. Shelhamer, T. Darrell, *Fully convolutional networks for semantic segmentation*, CVPR, 2015.
- O. Ronneberger, P. Fischer, T. Brox, *U-Net : convolutional networks for biomedical image segmentation*, MICCAI, 2015.
- Ö. Çiçek et al., *3D U-Net : learning dense volumetric segmentation from sparse annotation*, MICCAI, 2016.
- F. Milletari, N. Navab, S.-A. Ahmadi, *V-Net : fully convolutional neural networks for volumetric medical image segmentation*, 3DV, 2016.
- F. Isensee et al., *nnU-Net : a self-configuring method for deep learning-based biomedical image segmentation*, Nature Methods, 2021.
- S. S. M. Salehi, D. Erdogmus, A. Gholipour, *Tversky loss function for image segmentation using 3D fully convolutional deep networks*, 2017.
- T.-Y. Lin et al., *Focal loss for dense object detection*, ICCV, 2017.
- M. Berman, A. R. Triki, M. B. Blaschko, *The Lovász-softmax loss*, CVPR, 2018.
- S. Shit et al., *clDice – a novel topology-preserving loss function for tubular structure segmentation*, CVPR, 2021.
- S. Ren et al., *Faster R-CNN : towards real-time object detection with region proposal networks*, NeurIPS, 2015.
- J. Redmon et al., *You only look once : unified, real-time object detection*, CVPR, 2016.
- K. He et al., *Mask R-CNN*, ICCV, 2017.

Références II

- A. Hatamizadeh et al., *Swin UNETR : Swin transformers for semantic segmentation of brain tumors in MRI images*, 2022.
- J. Chen et al., *TransUNet : transformers make strong encoders for medical image segmentation*, 2021.
- Z. C. Lipton, C. Elkan, B. Narayanaswamy, *Thresholding classifiers to maximize F1 score*, 2014.
- L. Maier-Hein et al., *Metrics reloaded : recommendations for image analysis validation*, Nature Methods, 2024.
- M. Antonelli et al., *The Medical Segmentation Decathlon*, Nature Communications, 2022.

Prochaine séance

CM3 – Problèmes inverses et reconstruction

- Formalisation : $y = \mathcal{A}x + \varepsilon$, mal-posé, régularisation variationnelle (TV, parcimonie)
- IRM accélérée, compressed sensing
- Réseaux déroulés, méthodes Plug-and-Play, modèles de diffusion
- Stabilité et hallucinations

Questions ?