# Apprentissage profond en imagerie médicale

## CM2 – Segmentation et détection

Master de mathématiques

IRMAR – Université de Rennes 1

# Rappel et programme de la séance

**Acquis du CM1** : modalités, types de données, géométrie, difficultés (peu d'annotations, déséquilibre, décalage de domaine, fuite de données).

1. Du CNN de classification à la prédiction dense
2. Segmentation 3D en pratique
3. Fonctions de coût
4. Métriques d'évaluation et pièges
5. Détection
6. Segmentation d'instances et topologie
7. Synthèse et TP

# Le problème de segmentation

Étant donnée une image $x : \Omega_h \to \mathbb{R}^C$, prédire un label par voxel :

$$s : \Omega_h \to \{0, 1, \ldots, K\}, \qquad \text{ou, de façon probabiliste,} \quad p_\theta(x) : \Omega_h \to \Delta^K.$$

- **Sémantique** : un label de classe par voxel (organe, lésion, fond)
- **Instance** : distinguer plusieurs objets de même classe (plusieurs lésions, plusieurs noyaux cellulaires)
- **Panoptique** : combinaison des deux

## Applications cliniques

Volumétrie d'organes et de lésions, suivi de tumeurs, planification de radiothérapie (organes à risque), chirurgie guidée, extraction de caractéristiques quantitatives (radiomique).

# Pourquoi un CNN de classification ne suffit pas

- Un CNN de classification réduit la résolution spatiale (convolutions, pooling, *stride*) puis agrège : la sortie est un vecteur, plus une carte
- On veut une sortie de même taille spatiale que l'entrée
- Compromis fondamental :
  - *contexte* : grand champ réceptif pour comprendre « où l'on est » (quel organe, quelle structure)
  - *localisation* : fine résolution pour tracer des frontières précises
- L'architecture doit combiner les deux types d'information

**Idée directrice**

Un encodeur qui capte le contexte à basse résolution, un décodeur qui rétablit la résolution, et des liaisons qui transportent les détails fins de l'encodeur vers le décodeur.

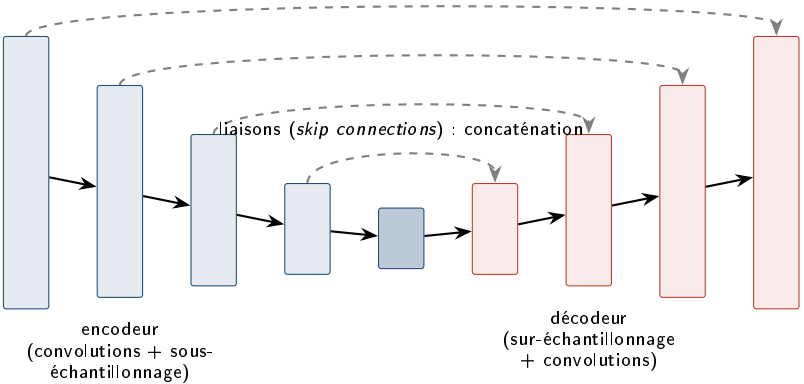
# Réseaux entièrement convolutifs (FCN)

- Remplacer les couches entièrement connectées par des convolutions $1 \times 1$ : le réseau accepte des entrées de taille arbitraire
- Sortie à basse résolution, puis sur-échantillonnage jusqu'à la taille de l'entrée :
  - interpolation (bilinéaire, trilinéaire)
  - convolution transposée apprise
- FCN (Long, Shelhamer, Darrell, 2015) : fusion de cartes de différentes profondeurs (idée de *skip connections*)

**Remarque sur les convolutions transposées**

Elles produisent facilement des artefacts en damier lorsque la taille du noyau n'est pas multiple du pas. Une interpolation suivie d'une convolution classique est une alternative courante.

# U-Net : architecture




- À chaque niveau : blocs conv–norm–activation ; encodeur : divisions de la résolution par 2, doublement du nombre de canaux
- Décodeur : sur-échantillonnage, concaténation avec la carte de l'encodeur de même résolution, convolutions

# U-Net : pourquoi cela fonctionne

- **Champ réceptif** : après $L$ niveaux de sous-échantillonnage par 2, une convolution $3 \times 3$ voit une région de taille de l'ordre de $2^L$ fois celle du niveau initial
- Les liaisons transportent des **détails fins** (frontières, textures) directement vers le décodeur : le goulot d'étranglement n'a plus à tout mémoriser
- La concaténation laisse le décodeur *choisir* comment combiner contexte et détail (contrairement à une addition)
- Très efficace avec peu de données (quelques dizaines d'images annotées) grâce à l'augmentation de données

## Perspective de mathématicien

Un U-Net peut se lire comme une approche multi-échelle (type pyramide, ondelettes) où les représentations de différentes résolutions sont apprises et mélangées. Des travaux le rapprochent d'un schéma multigrille.

# Variantes d'architecture

**Évolutions convolutives**

- **3D U-Net**, **V-Net** : convolutions 3D, volumes natifs
- **U-Net++** : liaisons denses imbriquées
- **Attention U-Net** : portes d'attention sur les liaisons
- **Residual U-Net** : blocs résiduels

**Avec transformers**

- **TransUNet** : encodeur hybride CNN + transformer
- **UNETR**, **Swin UNETR** : encodeur transformer, décodeur convolutif
- Coût : attention quadratique en nombre de tokens, besoin de plus de données ou de préentraînement

**Constat empirique important**

Sur des benchmarks bien conduits, un U-Net convolutif bien configuré et entraîné reste très compétitif face aux variantes plus récentes. Le soin apporté au pipeline compte souvent plus que l'architecture.

# 2D, 2.5D ou 3D ?

| | Avantages | Inconvénients |
|---|---|---|
| **2D** (coupe par coupe) | léger en mémoire, bien adapté aux coupes très épaisses, bénéficie du préentraînement 2D | ignore le contexte entre coupes, incohérences inter-coupes |
| **2.5D** (coupes voisines en canaux) | contexte partiel peu coûteux | fenêtre axiale fixe et limitée |
| **3D** (patchs 3D) | contexte volumique complet, cohérence spatiale | mémoire GPU, lots très petits, plus de paramètres |

- Le choix dépend de l'anisotropie des données (cf. CM1), de la mémoire et de la taille des structures
- Les approches mixtes (cascades : basse résolution puis haute résolution) sont courantes

# Entraînement par patchs

- Un volume complet ne tient pas en mémoire : entraînement sur des **patchs** (par exemple $128^3$ voxels)
- **Échantillonnage des patchs** : uniforme (dominé par le fond) ou avec sur-échantillonnage du premier plan (par exemple, une fraction fixe des patchs centrée sur un voxel de la classe d'intérêt)
- Lots de taille très petite (parfois 2) : la normalisation par lot devient instable $\Rightarrow$ *instance norm*, *group norm*
- Augmentations *spatiales* (rotations, mise à l'échelle, déformations élastiques, miroirs) et *d'intensité* (bruit, flou, gamma, contraste)

**Principe**

Les augmentations doivent rester *plausibles médicalement* : un miroir gauche/droite peut être invalide pour un organe asymétrique (foie, cœur).

# Inférence par fenêtre glissante

- Au test, on prédit sur l'ensemble du volume en parcourant des patchs qui se recouvrent (typiquement 50 %)
- Les prédictions sont moyennées dans les zones de recouvrement, avec une pondération qui favorise le centre du patch (par exemple une gaussienne) car les bords sont moins fiables (peu de contexte)
- **Augmentation au test** (*test-time augmentation*) : moyenne des prédictions sur des versions symétrisées de l'entrée (miroirs), pour réduire la variance

$$\hat{p}(v) = \frac{\sum_j w_j(v)\, p^{(j)}(v)}{\sum_j w_j(v)},$$

où $p^{(j)}$ est la prédiction du patch $j$ et $w_j(v)$ un poids décroissant avec la distance de $v$ au bord du patch.

# Supervision profonde et post-traitement

- **Supervision profonde** (*deep supervision*) : ajouter des têtes de prédiction auxiliaires aux niveaux intermédiaires du décodeur, avec une perte à chaque résolution (sur des masques sous-échantillonnés) :

$$\mathcal{L} = \sum_{\ell} \alpha_\ell \, \mathcal{L}\big(p^{(\ell)}, \, g^{(\ell)}\big)$$

- Améliore la propagation des gradients et accélère l'entraînement
- **Post-traitement** : conserver la plus grande composante connexe (organe unique), remplir les trous, supprimer les très petites composantes isolées

**Attention**

Le post-traitement encode un *a priori* anatomique : à valider, car il peut aussi supprimer de vraies petites lésions.

# nnU-Net : un pipeline qui s'auto-configure

**Idée** : automatiser les décisions de conception qui comptent plus que l'architecture.

1. *Empreinte du jeu de données* : espacement médian, formes, statistiques d'intensité
2. *Règles fixes* déduites de l'empreinte : espacement cible, taille de patch, topologie du réseau (nombre de niveaux), normalisation
3. *Choix empiriques* : validation croisée parmi 2D, 3D pleine résolution, cascade ; assemblage et post-traitement

**Ingrédients stables**

- U-Net convolutif standard
- Perte somme Dice + entropie croisée
- Supervision profonde
- SGD avec momentum, décroissance polynomiale du pas
- Sur-échantillonnage du premier plan
- Augmentations riches

Leçon : une base de référence solide, sans ingénierie spécifique à chaque tâche, bat de nombreuses méthodes plus élaborées. À utiliser comme *baseline* avant toute contribution.

# Entropie croisée et déséquilibre

Pour des probabilités $p_{i,k}$ et des labels one-hot $g_{i,k}$ sur les voxels $i = 1, \dots, N$ :

$$\mathcal{L}_{\mathrm{CE}} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{k=0}^{K} g_{i,k} \log p_{i,k}.$$

- Fonction *décomposable* : somme de contributions par voxel, bien adaptée à l'optimisation stochastique
- Calibrée (propre au sens des règles de score) : minimisée par les vraies probabilités conditionnelles
- Problème : si la structure d'intérêt occupe 1 % des voxels, la perte est dominée par le fond ; prédire « fond partout » donne une perte faible

## Variante pondérée

$\mathcal{L}_{\mathrm{wCE}} = -\frac{1}{N} \sum_i \sum_k w_k \, g_{i,k} \log p_{i,k}$ avec $w_k$ décroissant avec la fréquence de la classe $k$. Remédie au déséquilibre, mais déforme les probabilités.

# Dice et IoU : les métriques

Pour une prédiction binaire $P$ et une référence $G$ (ensembles de voxels) :

$$\mathrm{Dice}(P,G) = \frac{2|P \cap G|}{|P| + |G|} = \frac{2\,TP}{2\,TP + FP + FN}, \qquad \mathrm{IoU}(P,G) = \frac{|P \cap G|}{|P \cup G|} = \frac{TP}{TP + FP + FN}.$$

- Le Dice est exactement le score $F_1$ de la classification voxel à voxel
- Relation : $\mathrm{IoU} = \dfrac{\mathrm{Dice}}{2 - \mathrm{Dice}}$ (fonction croissante : les deux classent les modèles de la même façon sur un cas, mais pas nécessairement après moyennage sur plusieurs cas)
- *Insensibles* au grand nombre de vrais négatifs : adaptées aux structures petites

**Mais**

Ce sont des fonctions *globales* de la prédiction, non décomposables en somme sur les voxels, et non différentiables si l'on binarise.

# La perte de Dice douce

On relaxe la binarisation : $p_i \in [0,1]$ probabilité de premier plan, $g_i \in \{0,1\}$.

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2\sum_i p_i g_i + \varepsilon}{\sum_i p_i + \sum_i g_i + \varepsilon}.$$

Avec $I = \sum_i p_i g_i$ et $U = \sum_i p_i + \sum_i g_i$, le gradient s'écrit

$$\frac{\partial \mathcal{L}_{\text{Dice}}}{\partial p_j} = -\frac{2\,(g_j U - I)}{U^2} \qquad (\varepsilon \to 0).$$

- Pour un voxel de premier plan ($g_j = 1$) : gradient négatif, pousse $p_j$ vers 1 ; pour un voxel de fond ($g_j = 0$) : gradient $2I/U^2 \geq 0$, pousse $p_j$ vers 0
- Le gradient dépend de *toute l'image* via $I$ et $U$ : couplage global entre voxels
- Si $I \approx 0$ au début de l'entraînement, les gradients sont instables : on ajoute $\varepsilon$, et l'on combine avec l'entropie croisée

# Dice en pratique : choix de calcul

- **Par lot** (somme sur tout le lot) ou **par image** (puis moyenne) : le comportement diffère pour les cas vides ou très petits
- **Multi-classes** : moyenne des Dice par classe (chaque classe pèse autant), éventuellement en excluant le fond
- **Cas vide** ($G = \emptyset$) : le Dice vaut $\varepsilon/\varepsilon$ ou $0/0$ ; la convention et le $\varepsilon$ changent le signal d'apprentissage
- **Combinaison usuelle** : $\mathcal{L} = \mathcal{L}_{\mathrm{CE}} + \mathcal{L}_{\mathrm{Dice}}$
  - CE : gradients bien conditionnés, probabilités mieux calibrées
  - Dice : insensibilité au déséquilibre

**Inconvénient connu**

Les modèles entraînés avec une perte de Dice sont souvent *sur-confiants* : probabilités proches de 0 ou 1, mal calibrées. Gênant pour l'estimation d'incertitude (CM5).

# Pourquoi le Dice, du point de vue de la décision ?

Quelle prédiction binaire maximise le Dice *espéré* ?

- Pour l'erreur 0–1 par voxel, la règle de Bayes seuille la probabilité à $1/2$
- Pour le $F_1$, le seuil optimal est inférieur à $1/2$ : à l'optimum, il vaut la moitié du $F_1$ optimal atteignable

$$\text{seuil optimal} \;=\; \tfrac{1}{2}\, F_1^\star$$

(résultat classique sur la maximisation du $F_1$ ; rigoureux dans un cadre asymptotique de classification).

## Conséquences

- Seuiller à 0,5 des probabilités bien calibrées n'est pas optimal pour le Dice
- Optimiser une perte *décomposable* ne produit pas le prédicteur optimal pour une métrique *globale* : d'où les pertes de substitution (Dice, Lovász)

# Autres pertes

- **Perte de Tversky** : généralise le Dice avec des poids $\alpha, \beta$ sur FP et FN :

$$\mathcal{T}_{\alpha,\beta} = \frac{TP}{TP + \alpha\, FP + \beta\, FN}$$

  ($\alpha = \beta = \frac{1}{2}$ redonne le Dice). Choisir $\beta > \alpha$ pour pénaliser davantage les faux négatifs (lésions manquées).
- **Perte focale** : $-\sum_i (1 - p_{i,y_i})^\gamma \log p_{i,y_i}$ ; réduit le poids des voxels faciles, utile en détection et pour de très forts déséquilibres
- **Extension de Lovász** : substitut convexe de la perte de Jaccard, optimisation directe de l'IoU via l'extension de Lovász d'une fonction sous-modulaire
- **Pertes de frontière / de distance** : prise en compte de la distance aux contours (carte de distance signée)
- **Pertes topologiques** (clDice) : préservent la connexité des structures tubulaires (vaisseaux)

# Choisir sa perte : une grille de lecture

| Situation | Perte conseillée | Raison |
|---|---|---|
| Structure volumineuse, peu de déséquilibre | CE (ou CE + Dice) | stable, calibrée |
| Petite structure, fort déséquilibre | Dice + CE, Tversky | robuste au fond dominant |
| Faux négatifs coûteux (lésions) | Tversky ($\beta > \alpha$), focale | sensibilité privilégiée |
| Structures fines et connexes (vaisseaux) | Dice + clDice | contrainte topologique |
| Besoin de probabilités calibrées | CE (+ calibration a posteriori) | Dice sur-confiant |
| Référence par défaut | Dice + CE | nnU-Net |

**Rappel**

La fonction de coût doit refléter la question clinique, pas seulement une métrique de challenge.

# Trois familles de métriques

- **Recouvrement** (*overlap*) : Dice, IoU, sensibilité, précision
- **Distance entre contours** : distance de Hausdorff, distance moyenne de surface
- **Surface avec tolérance** : Dice de surface normalisé (NSD)
- **Volume** : erreur relative de volume, biais de Bland–Altman (importante cliniquement : mesure d'un volume tumoral)

**Aucune métrique ne capture tout**

Deux segmentations de même Dice peuvent avoir des défauts très différents : une frontière légèrement décalée partout, ou un bon recouvrement avec une petite composante aberrante lointaine. Les métriques doivent être choisies selon l'usage clinique.

# Distance de Hausdorff et variantes

Pour deux surfaces $A$ (prédiction) et $B$ (référence), avec $d(a, B) = \min_{b \in B} \|a - b\|$ :

$$d_H(A, B) = \max \left\{ \sup_{a \in A} d(a, B),\ \sup_{b \in B} d(b, A) \right\}.$$

- Mesure l'erreur la plus grande : très sensible aux valeurs aberrantes (un seul voxel égaré)
- **HD95** : on remplace le sup par le $95^{\text{e}}$ percentile des distances, plus robuste
- **Distance moyenne de surface** (ASSD) : moyenne symétrique des distances, moins sensible aux aberrations
- **NSD** : proportion de points de surface à distance $\leq \tau$ de l'autre surface ; $\tau$ choisie selon la tolérance clinique

Les distances sont à calculer en millimètres (avec l'espacement des voxels) et non en voxels.

# Pièges des métriques de segmentation

1. **Structures vides** : si $G = \emptyset$ et $P = \emptyset$, Dice indéfini ; convention explicite requise (parfois 1, parfois exclu)
2. **Moyenne par cas ou groupée** : le Dice moyen par patient et le Dice calculé sur l'ensemble des voxels regroupés pèsent différemment les petits cas
3. **Dépendance à la taille** : un décalage d'un voxel détruit le Dice d'une petite lésion mais change à peine celui d'un gros organe
4. **Résolution** : mêmes métriques non comparables entre résolutions différentes
5. **Référence imparfaite** : la variabilité inter-experts borne ce qui est atteignable (Dice entre experts $< 1$)
6. **Statistiques** : moyennes sans dispersion ; petits jeux de test ; tests non appariés

## Bonne pratique

Rapporter la distribution (boîtes à moustaches, quantiles) par cas, la métrique de recouvrement *et* une métrique de contour, et comparer au niveau de désaccord inter-experts. Voir *Metrics Reloaded* pour une démarche guidée.

# Évaluation au niveau lésion

Au-delà du voxel : la question clinique est souvent « a-t-on *trouvé* la lésion ? ».

- Appariement lésions prédites / lésions de référence (par recouvrement minimal, par distance entre centres)
- Comptages : lésions détectées (TP), manquées (FN), fausses détections (FP)
- **Sensibilité par lésion** et **faux positifs par examen**
- **Courbe FROC** : sensibilité en fonction du nombre moyen de faux positifs par examen, quand on fait varier le seuil de score

**Remarque**

Un modèle peut avoir un bon Dice voxel-à-voxel (grosses lésions bien segmentées) tout en manquant plusieurs petites lésions : les deux niveaux d'évaluation sont complémentaires.

# Le problème de détection

Prédire un ensemble $\{(b_j, c_j, s_j)\}_j$ : boîte englobante $b_j$, classe $c_j$, score $s_j \in [0,1]$.

- Boîtes 2D $(x, y, w, h)$ ou 3D $(x, y, z, w, h, d)$
- Mesure de recouvrement boîte-à-boîte : $\mathrm{IoU}(b, b') = |b \cap b'|/|b \cup b'|$
- Une prédiction est correcte si $\mathrm{IoU} \geq \tau$ avec une boîte de référence non déjà appariée

## Spécificités médicales

Objets de tailles très variables (nodules de quelques millimètres à masses de plusieurs centimètres) ; nombre d'objets inconnu, souvent nul ; très peu de positifs dans les images ; coût asymétrique FN/FP.

# Détecteurs en deux étapes et en une étape

**Deux étapes (Faster R-CNN)**

1. Un réseau de propositions de régions (RPN) génère des candidats à partir d'ancres
2. Un second réseau classe chaque candidat et affine la boîte

Précis, plus lent. Mask R-CNN ajoute une branche de masque (segmentation d'instances).

**Une étape (YOLO, RetinaNet)**

- Prédiction directe de boîtes et classes sur une grille de positions
- Rapide, bien adapté au temps réel (endoscopie, échographie)
- RetinaNet : perte focale pour gérer le déséquilibre fond/objet

- **Ancres** : boîtes de référence de plusieurs tailles et formes, centrées en chaque position
- Fonction de coût : classification (CE ou focale) + régression de boîte (lissée $L_1$, IoU généralisée)

# Suppression des non-maxima (NMS)

Le détecteur produit plusieurs boîtes quasi superposées pour un même objet. NMS les fusionne :

1. Trier les boîtes par score décroissant
2. Garder la première ; supprimer toutes celles dont l'IoU avec elle dépasse un seuil
3. Répéter avec la boîte restante la mieux classée

**Limites**

Seuil délicat : trop bas, on supprime des objets proches (lésions adjacentes) ; trop haut, on garde des doublons. Des variantes douces (Soft-NMS) atténuent les scores au lieu de les éliminer.

Pas de NMS dans les approches par *prédiction directe d'ensemble* (DETR et dérivés, par appariement hongrois entre prédictions et références).

# Détection par cartes de chaleur et points d'intérêt

- Alternative aux boîtes : régresser une carte de chaleur dont les maxima locaux indiquent les objets (centres de lésions, noyaux, repères anatomiques)
- Cible : somme de gaussiennes centrées sur les positions de référence :

$$h(x) = \max_j \exp\left(-\frac{\|x - c_j\|^2}{2\sigma^2}\right)$$

- Perte : erreur quadratique ou focale sur la carte ; détection par recherche de maxima locaux au-dessus d'un seuil
- Utilisé pour la localisation de repères anatomiques, la détection de cellules, le comptage

## Lien avec la segmentation

La détection par carte de chaleur est une segmentation avec une cible *molle* : on réutilise un U-Net, le choix de $\sigma$ règle le compromis précision de localisation / facilité d'apprentissage.

# Détection d'anomalies (aperçu)

- Quand les pathologies sont variées ou rares, difficile d'annoter toutes les classes : on apprend la distribution du « normal » et on détecte l'écart
- Approches : auto-encodeurs, modèles génératifs, erreur de reconstruction ; modèles de diffusion
- Score d'anomalie par voxel $\Rightarrow$ carte de détection

**Limites**

Une grande variabilité normale (anatomique, d'acquisition) produit de nombreux faux positifs ; difficile d'obtenir des garanties. Lien avec la détection hors-distribution traitée en CM5.

# Segmentation d'instances

- **Problème** : lésions ou cellules adjacentes, qu'une segmentation sémantique fusionne en une seule composante
- **Approches**
  - Mask R-CNN : détecter puis segmenter chaque boîte
  - Prédire en plus une carte de distance au bord ou un champ de vecteurs vers le centre, puis séparer par *watershed* ou regroupement
  - Approches par prédiction de forme (étoile-convexe : StarDist) pour les noyaux cellulaires
- **Évaluation** : appariement d'instances, qualité panoptique

## Applications

Comptage de noyaux (histopathologie), décompte de lésions métastatiques, suivi longitudinal des lésions individuelles.

# Topologie et contraintes anatomiques

- Une segmentation pixelwise ne garantit pas la cohérence topologique : trous, fragments isolés, vaisseaux interrompus
- Moyens d'incorporer des a priori :
  - post-traitement (composante connexe)
  - perte topologique (clDice, perte d'homologie persistante)
  - contraintes de forme (modèles statistiques, auto-encodeurs de formes)
  - représentations implicites : régresser une *fonction distance signée* plutôt qu'un masque binaire

## Mathématiques concernées

Homologie persistante, fonctions distance, courbes de niveau et méthodes de surfaces implicites (*level sets*) : outils naturels pour exprimer et imposer des propriétés géométriques et topologiques.

# Ce qu'il faut retenir

1. Segmenter = prédire un label par voxel : encodeur–décodeur + liaisons (U-Net) combinent contexte et localisation
2. En 3D, l'entraînement par patchs, l'inférence par fenêtre glissante et la supervision profonde sont des ingrédients de base ; nnU-Net est la référence
3. Les fonctions de coût de recouvrement (Dice, Tversky) compensent le déséquilibre, mais ne sont pas calibrées et diffèrent de la décision optimale
4. Les métriques doivent être choisies selon la question clinique : recouvrement + contour + niveau lésion, avec distribution par cas
5. La détection relève d'autres outils (ancres, NMS, cartes de chaleur, FROC)

# TP2 : segmentation d'organe avec un U-Net

**Données** : une tâche du Medical Segmentation Decathlon (par exemple rate ou cœur), prétraitée comme au TP1.

1. Construire le pipeline MONAI : chargement, rééchantillonnage, normalisation, patchs avec sur-échantillonnage du premier plan, augmentations
2. Entraîner un **U-Net 3D** (MONAI `UNet` ou `DynUNet`) avec trois pertes : CE, Dice, Dice + CE
3. Inférence par fenêtre glissante (`sliding_window_inference`), post-traitement (plus grande composante connexe)
4. Évaluer : Dice, HD95, volume ; distribution par patient
5. Comparer les pertes : courbes d'apprentissage, métriques, histogramme de confiance (probabilités proches de 0/1 ou non ?)
6. Analyse d'erreurs : cas où le modèle échoue, effet de la taille de la structure

*Matériel :* GPU recommandé (Colab possible) ; version réduite (sous-ensemble, résolution plus grossière) pour tenir en séance.

# Références I


- J. Long, E. Shelhamer, T. Darrell, *Fully convolutional networks for semantic segmentation*, CVPR, 2015.
- O. Ronneberger, P. Fischer, T. Brox, *U-Net : convolutional networks for biomedical image segmentation*, MICCAI, 2015.
- Ö. Çiçek et al., *3D U-Net : learning dense volumetric segmentation from sparse annotation*, MICCAI, 2016.
- F. Milletari, N. Navab, S.-A. Ahmadi, *V-Net : fully convolutional neural networks for volumetric medical image segmentation*, 3DV, 2016.
- F. Isensee et al., *nnU-Net : a self-configuring method for deep learning-based biomedical image segmentation*, Nature Methods, 2021.
- S. S. M. Salehi, D. Erdogmus, A. Gholipour, *Tversky loss function for image segmentation using 3D fully convolutional deep networks*, 2017.
- T.-Y. Lin et al., *Focal loss for dense object detection*, ICCV, 2017.
- M. Berman, A. R. Triki, M. B. Blaschko, *The Lovász-softmax loss*, CVPR, 2018.
- S. Shit et al., *clDice – a novel topology-preserving loss function for tubular structure segmentation*, CVPR, 2021.
- S. Ren et al., *Faster R-CNN : towards real-time object detection with region proposal networks*, NeurIPS, 2015.
- J. Redmon et al., *You only look once : unified, real-time object detection*, CVPR, 2016.
- K. He et al., *Mask R-CNN*, ICCV, 2017.

# Références II


- A. Hatamizadeh et al., *Swin UNETR : Swin transformers for semantic segmentation of brain tumors in MRI images*, 2022.
- J. Chen et al., *TransUNet : transformers make strong encoders for medical image segmentation*, 2021.
- Z. C. Lipton, C. Elkan, B. Narayanaswamy, *Thresholding classifiers to maximize F1 score*, 2014.
- L. Maier-Hein et al., *Metrics reloaded : recommendations for image analysis validation*, Nature Methods, 2024.
- M. Antonelli et al., *The Medical Segmentation Decathlon*, Nature Communications, 2022.

# Prochaine séance

## CM3 – Problèmes inverses et reconstruction

- Formalisation : $y = \mathcal{A}x + \varepsilon$, mal-posé, régularisation variationnelle (TV, parcimonie)
- IRM accélérée, compressed sensing
- Réseaux déroulés, méthodes Plug-and-Play, modèles de diffusion
- Stabilité et hallucinations

Questions ?