

APPRENTISSAGE PROFOND EN IMAGERIE MÉDICALE
PLAN DE COURS - M2 SNS -

Public Cible : Étudiants en Master ou Doctorat avec une solide connaissance des CNN pour la vision par ordinateur (architectures de type ResNet, DenseNet, formation par rétropropagation, etc.).

Objectif du cours : Fournir aux étudiants les compétences nécessaires pour adapter et développer des modèles d'apprentissage profond performants et fiables pour des tâches d'analyse d'images médicales, en se concentrant sur les défis spécifiques au domaine tels que la rareté des données, la quantification des incertitudes et l'interprétabilité des résultats.

A voir :

- interpretabilite LIME, SHAP
- Federative learning : éfis techniques (hétérogénéité des données, communication) et des solutions pour collaborer de manière sécurisée
- articles sur "Fairness and Bias in Medical AI" ou "Ethical considerations for AI in healthcare". Ces ressources sensibiliseraient les étudiants aux risques de créer des modèles qui pourraient exacerber les inégalités en santé.

Chapitre 1

Données en Imagerie Médicale

L'imagerie joue un rôle central dans le processus des soins de santé. L'imagerie est cruciale non seulement pour les soins de santé, mais aussi pour la communication et l'éducation médicales, ainsi que pour la recherche. En fait, une grande partie de nos progrès récents, en particulier dans le domaine du diagnostic, peut être attribuée à la disponibilité de techniques d'imagerie de plus en plus sophistiquées qui non seulement montrent la structure du corps avec des détails incroyables, mais aussi la fonction des tissus à l'intérieur du corps.




FIGURE 1.1 – Source : [Rubin et al., 2021] The major topics in biomedical imaging informatics include image acquisition, image content representation, management/storage of images, image processing, and image interpretation/computer reasoning (Figure 9.1). Image acquisition is the process of generating images from the modality and converting them to digital form if they are not intrinsically digital

L'imagerie médicale joue un rôle significatif dans diverses applications cliniques, notamment pour la détection précoce, le suivi, le diagnostic et l'évaluation du traitement de nombreuses conditions médicales. Son utilisation pour le diagnostic est en constante augmentation, venant compléter l'examen clinique et d'autres types d'investigations.

Née il y a un peu plus d'un siècle, l'imagerie médicale a évolué grâce aux grandes découvertes de la physique (rayons X, radioactivité, propriétés magnétiques) et s'appuie sur les avancées en médecine, chimie, mathématiques et informatique. Les progrès récents dans ce domaine sont si importants que de nombreuses spécialités médicales qui dépendent fortement de l'interprétation des images, comme la radiologie, la pathologie et l'ophtalmologie, ont vu un essor de la recherche en intelligence artificielle (IA).

Au-delà de la simple observation de la structure d'un organe, il est maintenant possible de le voir fonctionner grâce à des images fixes ou animées. Les techniques d'imagerie permettent de distinguer les informations anatomiques/structurelles (taille et forme des organes) des informations fonctionnelles (composition ou fonction des tissus). Par exemple, l'IRM peut être utilisée pour l'étude anatomique (structure du cerveau), fonctionnelle (suivi de son fonctionnement) et de diffusion (connaissance de l'organisation tissulaire).

1.1 Qu'attend-on des images ?

En général, il y a deux stratégies différentes dans l'imagerie du corps : (1) délimiter la structure anatomique structure (anatomic/structural imaging), et (2) déterminer la composition des tissus ou leur fonction fonction (functional imaging).

L'imagerie de la structure anatomique du corps a été et continue d'être la principale application de l'imagerie médicale. Son objectif est de délimiter clairement la position, forme, taille, anomalie, etc des organes.

L'imagerie fonctionnelle, qui vise à déterminer la composition ou la fonction des tissus. Il est maintenant possible non seulement d'observer un organe, mais aussi de le voir fonctionner grâce à des images fixes ou animées. Ainsi, la fonction peut être déduite en observant les changements de structure au fil du temps. Ces dernières années, cette capacité à imager la fonction s'est grandement accélérée. Par exemple, l'échographie et l'angiographie sont largement utilisées pour montrer le fonctionnement du cœur.

Un équilibre entre structure et fonction : En réalité, la plupart des modalités d'imagerie fournissent des informations sur la morphologie et la fonction. Il n'existe pas de modalité d'imagerie parfaite ; chacune présente un compromis entre la résolution spatiale, la résolution de contraste et la capacité à représenter la fonction physiologique.

Une application particulièrement importante de l'imagerie fonctionnelle est de comprendre l'activité cognitive du cerveau.

1.2 Panorama des modalités d'imagerie

<https://www.cea.fr/comprendre/Pages/sante-sciences-du-vivant/essentiel-sur-imagerie-m>




FIGURE 1.2 – Source : [Rubin et al., 2021]

aspx

L'imagerie médicale joue un rôle central dans les soins de santé, le diagnostic, le suivi des maladies et la recherche. Il existe une grande variété de techniques, ou modalités, qui diffèrent principalement par la source d'énergie utilisée pour générer les images. Chaque modalité possède des caractéristiques uniques en termes de résolution, de type d'information fournie (anatomique ou fonctionnelle) et d'applications cliniques.

1.2.1 Radiographie (Rayons X)

La radiographie est la modalité d'imagerie la plus courante dans le monde, souvent utilisée pour le dépistage et le diagnostic.

Principe : Cette technique de projection utilise des rayons X, une forme de rayonnement ionisant. Les rayons X ont des longueurs d'onde plus courtes que la lumière visible, ce qui leur permet de traverser la plupart des tissus mous du corps humain. Cependant, les tissus plus denses comme les os, qui contiennent du calcium, absorbent ou diffusent davantage ces rayons. Un détecteur ou un film placé de l'autre côté du patient capture les rayons X restants, créant une image négative où les zones exposées à plus de lumière (tissus mous comme les poumons) apparaissent plus sombres, et les os apparaissent plus clairs. Des agents de contraste, comme des produits iodés, peuvent être utilisés pour rehausser le contraste de certaines structures.

Caractéristiques : La radiographie offre une très haute résolution spatiale. Cependant, comme il s'agit d'une projection, elle entraîne une superposition de toutes les structures traversées par le faisceau, ce qui peut créer des ambiguïtés de localisation. Sa résolution de contraste est relativement faible par rapport à d'autres modalités, et elle fournit des informations fonctionnelles limitées. **Applications :** Elle est couramment utilisée pour la détection de fractures osseuses, de problèmes dentaires, de pneumonies, de tuberculose

et de certains types de tumeurs. La fluoroscopie, une variante, permet une visualisation en temps réel. Tomodensitométrie (TDM ou CT - Computed Tomography)

1.2.2 Tomodensitométrie (Rayons X)

La TDM, également appelée scanner, est une méthode d'imagerie qui utilise aussi les rayons X pour produire des images en coupe du corps.

Principe : Un faisceau de rayons X étroit tourne autour du patient, et de multiples clichés sont pris sous différents angles. Des algorithmes informatiques de reconstruction estiment alors la densité absolue en chaque point (voxel) du volume exploré, éliminant le problème de superposition de la radiographie conventionnelle. L'empilement de ces coupes transversales permet de générer une représentation tridimensionnelle (3D) qui est beaucoup plus informative qu'une radiographie classique.

Caractéristiques : La résolution spatiale de la TDM est inférieure à celle de la radiographie, mais sa résolution de contraste est bien supérieure, permettant une meilleure distinction des tissus mous. Elle a une grande capacité de détection et peut révéler de petites lésions.

Applications : La TDM est un outil de diagnostic populaire pour identifier des tumeurs ou des lésions dans l'abdomen, localiser des blessures à la tête, et diagnostiquer des fractures osseuses complexes. Elle est fréquemment utilisée pour l'identification de nodules pulmonaires.

1.2.3 Imagerie par Résonance Magnétique (IRM - MRI)

L'IRM n'utilise pas de rayonnements ionisants mais un champ magnétique et des ondes de radiofréquence pour créer des images détaillées.

Principe : L'IRM force les protons du corps à s'aligner avec un champ magnétique puissant. Une impulsion de radiofréquence perturbe cet alignement. Lorsque l'impulsion est arrêtée, les protons libèrent de l'énergie en se réalignant, et cette énergie varie selon les types de tissus (basé sur les temps de relaxation T1 et T2). Cette variation permet de différencier les différentes régions du corps.

Caractéristiques : L'IRM offre à la fois une haute résolution spatiale et des informations fonctionnelles détaillées sur la composition des tissus. Elle est particulièrement efficace pour l'imagerie des tissus mous et non osseux (cerveau, moelle épinière, nerfs, muscles), où elle est souvent supérieure à la TDM.

Applications : C'est la modalité de choix pour des tâches telles que la détection de tumeurs cérébrales ou l'identification de lésions tissulaires. Des variantes comme l'angiographie par résonance magnétique (ARM) permettent de visualiser le flux sanguin. L'IRM permet non seulement d'étudier la morphologie des organes (IRM anatomique), mais aussi de suivre le fonctionnement du cerveau (IRM fonctionnelle) et de connaître l'organisation des tissus, comme les fibres neuronales (IRM de diffusion)

1.2.4 Tomographie par Émission de Positrons (TEP - PET)

La TEP est une technique d'imagerie de médecine nucléaire principalement axée sur l'information fonctionnelle.

Principe : Un traceur radioactif est chimiquement lié à une molécule biologiquement active (comme un analogue du glucose) et injecté au patient. Ce composé s'accumule dans les tissus métaboliquement actifs (par exemple, les tumeurs) et émet des rayonnements (positrons). Ces rayonnements sont détectés par un scanner qui crée une image montrant la concentration du traceur dans le corps.

Caractéristiques : La TEP fournit des informations fonctionnelles de haute qualité, visualisant l'activité moléculaire au niveau des tissus. Cependant, sa résolution spatiale est faible. Pour pallier ce défaut, elle est souvent combinée à un scanner TDM dans une machine hybride (TEP/TDM), qui fusionne l'information fonctionnelle de la TEP avec la localisation anatomique précise de la TDM.

Applications : La TEP est largement utilisée en oncologie pour le diagnostic, la stadification et le suivi de la réponse au traitement des cancers.

1.2.5 Mammographie (MG)

La mammographie est une technique de radiographie à faible dose spécifiquement conçue pour l'imagerie du sein.

Principe : Elle utilise des rayons X pour visualiser la structure interne du sein. C'est l'outil le plus fiable et le plus courant pour la détection précoce du cancer du sein.

Caractéristiques : Le défi principal en mammographie est la détection de tumeurs qui ne représentent qu'une petite partie de l'image. Des systèmes de classification standardisés comme le BI-RADS (Breast Imaging Reporting and Data System) sont utilisés pour décrire les observations.

Applications : Dépistage et diagnostic du cancer du sein, notamment par la détection de masses ou de microcalcifications.

1.2.6 Échographie (Ultrasound)

L'échographie utilise des ondes sonores à haute fréquence pour créer des images des structures corporelles.

Principe : Une sonde émet des impulsions sonores qui traversent le corps. Lorsque ces ondes rencontrent des interfaces entre différents types de tissus (avec des impédances acoustiques différentes), une partie est réfléchiée sous forme d'écho. La sonde capte ces échos, et un ordinateur les utilise pour construire une image en temps réel. Le temps de retour de l'écho détermine la profondeur de la structure, et l'amplitude de l'écho sa luminosité sur l'image.

Caractéristiques : L'échographie n'utilise pas de rayonnement ionisant. Elle fournit des informations fonctionnelles, notamment sur la composition des tissus et le flux sanguin (via les méthodes Doppler). Sa résolution spatiale est généralement plus faible que celle d'autres modalités. Elle permet une imagerie en temps réel (cineloops).

Applications : Visualisation du mouvement du cœur, étude du flux sanguin dans les vaisseaux, imagerie fœtale, etc.

1.2.7 Images d'histopathologie

L'histopathologie est l'étude de tissus au microscope pour identifier des maladies. **Principe** : Des échantillons de tissus sont prélevés, fixés sur des lames de verre, puis colorés (par exemple, avec de l'hémaroxyline et de l'éosine, H&E) pour mettre en évidence des structures spécifiques comme les noyaux cellulaires. La pathologie numérique (ou digitale) implique la numérisation de ces lames à très haute résolution pour créer des images de lames entières (WSI - Whole Slide Images).

Caractéristiques : Ces images sont massives (plusieurs gigaoctets) et permettent une analyse détaillée au niveau cellulaire. Les méthodes d'apprentissage profond (Deep Learning) sont de plus en plus utilisées pour analyser ces images, notamment pour la détection de noyaux, la segmentation de cellules ou la classification de tissus.

Applications : Diagnostic et classification des cancers (rein, poumon, sein, etc.), évaluation du grade tumoral.

1.3 Nature des données

Les images sont des données non structurées. Bien qu'un ordinateur puisse facilement stocker et récupérer les données visuelles brutes (les pixels), il ne peut pas accéder directement à leur contenu sémantique ou "contenu de connaissance" (reconnaître l'anatomie, les anomalies, etc.). De même, les rapports de radiologie, rédigés en texte libre par exemple, sont également non structurés et difficiles à exploiter par des systèmes informatiques. Le développement d'ontologies et de terminologies contrôlées est une approche fondamentale pour rendre ce contenu de connaissance explicite et accessible aux machines.

Dimensions des images : Les données peuvent être des images 2D ou des volumes 3D.
◦ Les images 2D, comme les radiographies ou les images de microscopie, sont représentées par une matrice bidimensionnelle de pixels (éléments d'image).
◦ Les volumes 3D, typiques de l'IRM, de la TDM ou de la TEP, sont représentés par une matrice tridimensionnelle de voxels (éléments de volume). Un volume 3D peut être vu comme un empilement d'images 2D (coupes).

Type de valeurs : La plupart des images médicales sont en niveaux de gris (grayscale). Chaque pixel ou voxel a une valeur numérique représentant une intensité (par exemple, l'atténuation des rayons X en TDM). Pour la TDM, ces valeurs (unités Hounsfield) couvrent une large plage, et les opérateurs utilisent une technique de "fenêtrage" pour ajuster le contraste et la luminosité afin de visualiser des tissus d'intérêt.

Autres caractéristiques des données :

Isotropie : Les voxels sont dits isotropes s'ils ont les mêmes dimensions dans toutes les directions (x, y, z). Si ce n'est pas le cas (par exemple, l'épaisseur de coupe est plus grande que la résolution dans le plan), ils sont anisotropes, ce qui peut compliquer les reconstructions dans des plans arbitraires.

Métadonnées : Chaque fichier d'image médicale contient des métadonnées essentielles stockées dans son en-tête, telles que le nom du patient, la date de l'examen, la modalité utilisée, l'épaisseur de coupe, etc.. Le standard DICOM (Digital Imaging and Communications in Medicine) est largement utilisé pour normaliser le format de ces fichiers et la communication entre les appareils d'imagerie.

Données multi-dimensionnelles et temporelles : Les données peuvent avoir plus de trois dimensions. Par exemple, une IRM peut inclure plusieurs séquences (T1, T2), créant un "vecteur de caractéristiques" pour chaque voxel. De même, les vidéos (comme en échographie cardiaque) ajoutent une dimension temporelle.

1.4 Spécificités des données médicales

Voir uncertainties in Dojat's paper

1. Grande dimension
2. La rareté des données étiquetées et le coût de l'annotation par des experts.
3. La variabilité des données : bruit intrinsèque (artefacts, faible rapport signal/bruit) et variabilité inter-annotateurs [Lambert et al., 2024].
Variabilité inter-patient pour certains organes (ex vessie)
4. Le décalage de distribution (domain shift) entre les hôpitaux, les machines et les populations de patients.
5. La nécessité d'une IA digne de confiance pour une adoption clinique, au-delà de la performance pure.

1.4.1 Qualité des images

La qualité et la valeur diagnostique d'une image médicale sont principalement évaluées selon trois caractéristiques fondamentales. Aucune modalité d'imagerie n'est parfaite ; chacune représente un compromis entre ces différents aspects.

Résolution Spatiale - C'est une mesure de la **netteté de l'image**, c'est-à-dire la capacité de la modalité à distinguer des points très proches sur l'objet imagé. Pour une image numérique, elle est généralement liée au nombre de pixels par unité de surface.

- La **radiographie** offre une très haute résolution spatiale.
- L'**IRM** a également une haute résolution spatiale.
- À l'inverse, l'**échographie** et l'**imagerie de médecine nucléaire** (TEP, TEMP) ont une faible résolution spatiale en raison d'un flux de photons ou d'ondes plus faible.

Résolution de Contraste Elle mesure la capacité à distinguer de **faibles différences d'intensité** entre différentes régions de l'image. Pour les images numériques, elle est liée au nombre de bits par pixel. Une bonne résolution de contraste est essentielle pour différencier les tissus mous.

- La **Tomodensitométrie (TDM)** et l'**IRM** ont une résolution de contraste supérieure à celle de la radiographie conventionnelle.
- Des **agents de contraste** (produits iodés en TDM, gadolinium en IRM) sont souvent utilisés pour rehausser artificiellement le contraste de certaines structures.

Résolution Temporelle - Il s'agit du **temps nécessaire pour créer une image**. Une haute résolution temporelle est cruciale pour les applications en temps réel, comme

l'imagerie du cœur battant, qui nécessite au moins 30 images par seconde pour éviter le flou. L'échographie est un bon exemple de modalité avec une haute résolution temporelle.

Bruit dans les images - Chaque modalité d'imagerie possède des **sources physiques de bruit** caractéristiques :

Modalité	Principales sources de bruit
CT (Tomodensitométrie)	Statistiques des photons (bruit quantique), bruit électronique des détecteurs
IRM (Imagerie par Résonance Magnétique)	Bruit thermique dans les bobines de réception, inhomogénéités du champ magnétique, artefacts de mouvement
Échographie	Bruit de <i>speckle</i> dû à l'interférence des échos diffusés
PET / SPECT	Statistiques de comptage des photons (bruit de Poisson), événements aléatoires ou diffusés
Optique / Microscopie	Bruit de photons (<i>shot noise</i>), fluorescence de fond, bruit du détecteur

TABLE 1.1 – Principales sources physiques de bruit selon la modalité d'imagerie médicale.

Les bruits suivent typiquement les distributions suivantes.

- Poisson (photon-limited modalités like CT, PET),
- Gaussienne (thermal/electronic noise, MRI).

Lorsque les images sont utilisées pour l'intelligence artificielle ou pour l'extraction de biomarqueurs quantitatifs, le modèle de bruit est souvent explicitement intégré à l'analyse : Les modèles statistiques peuvent supposer un bruit hétéroscédastique (dont la variance dépend du signal). Les modèles bayésiens ou probabilistes tiennent compte de l'incertitude sur l'intensité des pixels. Dans les ensembles d'apprentissage, l'ajout de bruit synthétique (data augmentation) permet d'améliorer la robustesse des modèles.

1.4.2 Variabilité des données

Les sources de variabilité et d'erreurs en imagerie médicale sont multiples et complexes. Elles proviennent à la fois du processus physique d'acquisition, des caractéristiques des patients, des méthodes d'annotation et de la manière dont les ensembles de données sont constitués. La prise en compte de ces facteurs est essentielle pour développer des solutions d'IA qui soient non seulement performantes mais aussi fiables et dignes de confiance en pratique clinique.

Variabilité liée aux Images d'Entrée

Cette catégorie concerne les erreurs et variations inhérentes au processus de capture des données et aux caractéristiques physiques des images. Elle correspond en grande partie

à ce que l'on nomme l'incertitude aléatoire (aleatoric uncertainty), qui décrit le bruit et les effets aléatoires intrinsèques aux données

Bruit et Artefacts Techniques Bruit intrinsèque au processus d'acquisition : Les images médicales peuvent présenter un faible rapport signal/bruit, des artefacts (dus aux mouvements du patient, aux implants métalliques, etc.) ou un effet de volume partiel, où un seul voxel peut contenir plusieurs types de tissus, rendant les frontières floues.

Incohérences de qualité : Les données peuvent varier en termes de résolution et de contraste, en raison des procédures cliniques utilisées. Un exemple concret est un signal d'auscultation cardiaque qui peut être corrompu par du bruit lors de sa capture.

Décalage de Domaine (Domain Shift) lié aux Protocoles et Équipements C'est l'une des sources de variabilité les plus importantes. Les modèles d'IA ont souvent du mal à généraliser leurs performances lorsqu'ils sont confrontés à des données provenant d'un environnement différent de celui de l'entraînement.

Différences d'équipements et d'institutions : Il existe une variation significative entre les images acquises dans différents hôpitaux ou avec différentes machines. Les ensembles de données sont souvent composés de sous-ensembles provenant de différents appareils (par exemple, stéthoscopes Welch Allyn Meditron, 3M Littmann) et de différents environnements de capture (laboratoire vs hôpital), ce qui crée des distributions de données distinctes.

Protocoles d'acquisition non standardisés : L'absence de standardisation dans la manière dont les images sont acquises est une limitation majeure en analyse d'images médicales.

Caractéristiques Spécifiques aux Patients Des dissimilitudes importantes existent entre les données de patients différents en fonction de leurs caractéristiques démographiques, de leur âge, de leur sexe, etc.. Par exemple, des différences substantielles ont été identifiées dans les données d'EEG au repos d'enfants provenant de différentes régions géographiques.

Variations liées au Flux de Travail Clinique La manière dont les images sont manipulées peut introduire des erreurs. Par exemple, l'utilisation de photos de radiographies prises avec un smartphone introduit des artefacts qui ne sont pas présents dans les images numériques originales. Ces artefacts incluent des angles de vue modifiés, des conditions d'éclairage variables, des reflets (glare), des effets de moiré, des rotations, des translations et du flou.

1.4.3 Variabilité et Erreurs dans les Annotations (Vérité Terrain)

Cette variabilité affecte directement la qualité des étiquettes utilisées pour entraîner et évaluer les modèles d'IA supervisés. Elle est également une composante de l'incertitude aléatoire.

Variabilité Inter-Annotateurs C'est un phénomène courant où plusieurs experts humains (radiologues, pathologistes) peuvent être en désaccord sur l'interprétation ou la délimitation d'une même image.

Un exemple typique est la segmentation de la prostate sur des images IRM, où l'incertitude est particulièrement observée aux frontières de l'organe en raison des divergences entre les annotations de différents experts.

Divergence entre les Rapports Textuels et les Labels d'Images Les étiquettes pour de grands ensembles de données sont souvent extraites automatiquement de rapports radiologiques textuels. Cependant, il existe un désaccord significatif entre les labels issus des rapports et ceux attribués par des radiologues regardant directement les images.

Les raisons de cette divergence incluent :

1. L'accès à l'historique clinique par le radiologue qui rédige le rapport, ce qui peut biaiser son interprétation, alors que celui qui annote l'image ne dispose pas de ce contexte.
2. L'utilisation de différentes sections du rapport (par exemple, la section "Impression" vs "Constatations") qui peuvent ne pas contenir les mêmes informations.
3. Les hiérarchies d'étiquettes, où un radiologue peut mentionner une pathologie spécifique (enfant) sans mentionner la catégorie plus générale (parent).
4. Le bruit inhérent à la tâche d'étiquetage, incluant des erreurs humaines ou des seuils de diagnostic différents entre experts.

1.4.4 Variabilité liée à la Constitution des Ensembles de Données

Enfin, la manière dont les ensembles de données sont créés et structurés est une source majeure de variabilité et de biais potentiels.

Rareté des Données et Déséquilibre des Classes La rareté des données est une limitation majeure, en particulier pour les modèles d'apprentissage profond qui nécessitent de grands volumes de données annotées.

Les ensembles de données médicaux sont souvent très déséquilibrés, avec beaucoup plus d'échantillons "normaux" que "anormaux", ce qui peut biaiser l'entraînement du modèle vers la classe majoritaire.

Manque de Diversité et "Sur-Curation" des Données De nombreux jeux de données publics sont "hautement organisés" (highly curated), collectés dans des environnements contrôlés et des cadres restreints. Par conséquent, ils ne capturent pas la distribution et la diversité réelles des données cliniques. Un modèle entraîné sur des données trop "propres" peut échouer lorsqu'il est confronté à la complexité et au bruit du monde réel.

Les modèles peuvent aussi être confrontés à des cas non vus ou des maladies rares qui n'étaient pas présentes dans l'ensemble d'entraînement, ce qui constitue une autre forme de décalage de distribution.

Chapitre 2

Tâches et Architectures Clés en Apprentissage Profond Médical

Ce module présente les applications fondamentales de l'apprentissage profond (DL) dans ce domaine.

2.1 Les grandes tâches de l'analyse d'images médicales

1. Classification : Détecter la présence ou l'absence d'une pathologie.
2. Détection : Localiser des anomalies (ex : nodules pulmonaires) (voir table [2.2](#)).
3. Segmentation : Délimiter précisément des organes ou des tumeurs.

2.1.1 Classification

L'objectif de la classification est d'attribuer une ou plusieurs étiquettes à une image entière. Il s'agit de répondre à la question : "De quoi s'agit-il sur cette image?". Le modèle est entraîné pour détecter la présence ou l'absence d'une maladie ou pour classer l'image dans une catégorie prédéfinie (par exemple, normale ou pathologique).

Exemples

- détecter la présence de pneumonie sur une radiographie pulmonaire.
- classer des lésions cutanées comme bénignes ou malignes.
- Identifier le type de cancer du poumon (par exemple, adénocarcinome ou carcinome épidermoïde) à partir d'une image d'histopathologie.
- Classer la densité mammaire sur une mammographie.

La sortie d'un algorithme de classification est donc globale, au niveau de l'image. Le modèle produit un vecteur de probabilités pour l'ensemble des classes possibles (par exemple, $[P(\text{Normal}), P(\text{Pneumonie}), P(\text{Épanchement pleural})]$). La décision finale est une étiquette unique ou un ensemble d'étiquettes pour toute l'image.

Pour résoudre des problèmes de classification d'images médicales par des outils d'apprentissage profond, les architectures standards de classification d'images sont couramment

utilisées. Elles se terminent généralement par des couches entièrement connectées qui réduisent les cartes de caractéristiques spatiales à un vecteur de probabilités de classe : AlexNet, GoogLeNet, VGG-16, ResNet, DenseNet.

2.1.2 Segmentation

L'objectif de la segmentation est de partitionner une image en différentes régions sémantiques, c'est-à-dire de délimiter précisément des objets d'intérêt. Il s'agit de répondre à la question : "Où se trouvent exactement les structures d'intérêt sur cette image?". La tâche consiste à assigner une classe à chaque pixel (ou voxel en 3D) de l'image.

Exemples :

- Délimiter les contours d'une tumeur cérébrale sur une IRM.
- Segmenter le foie et les tumeurs hépatiques à partir de volumes CT.
- Identifier et délimiter les noyaux cellulaires sur des images d'histopathologie.
- Segmenter les reins et les tumeurs rénales sur des images CT.

La sortie d'un algorithme de segmentation est une carte de segmentation (ou un "masque") qui a les mêmes dimensions que l'image d'entrée. Chaque pixel de cette carte est coloré ou étiqueté selon la classe à laquelle il appartient (par exemple, pixel de fond, pixel de tumeur, pixel d'organe sain). L'analyse se fait donc au niveau du pixel, offrant une localisation précise.

En apprentissage profond, les architectures de segmentation sont souvent de type encodeur-décodeur pour préserver l'information spatiale. L'encodeur comprime l'image en une représentation de bas niveau, et le décodeur reconstruit une carte de segmentation à partir de cette représentation. U-Net est l'architecture la plus emblématique et la plus utilisée pour la segmentation d'images biomédicales. Ses variantes comme H-DenseUNet ou 3D U-Net sont également très populaires.

2.1.3 Détection d'anomalies

Détection d'Anomalies Supervisée Classification Binaire (*R-CNN (Region-based CNN) Faster CNN : mammographie, nodule pulmonaires*), Approche par Détection d'Objets (*Clu RNN, mRFCN (poumon), RetinaNet (détection d'ulcères dans les images d'endoscopie)*)

Apprentissage multitâches : Par exemple, une tâche secondaire d'identification du patient peut être couplée à la tâche primaire de détection d'anomalies pour mieux gérer les variations inter-sujets. Un autre exemple est l'apprentissage conjoint de la détection d'images suspectes et de la segmentation des régions d'intérêt dans ces images.

Détection d'Anomalies non Supervisée : Auto-Encodeurs (Sparse AE, denoising AE, variational AE), GAN, RNN.

La détection d'anomalies est très souvent abordée comme un problème non supervisé. Dans ce cas, le modèle est entraîné uniquement sur des données considérées comme "normales". Il apprend ainsi la distribution des données normales, et tout ce qui s'écarte de

TABLE 2.1 – Tableau récapitulatif des différences entre Classification et Segmentation

Caractéristique	Classification	Segmentation
Objectif principal	Attribuer une ou plusieurs étiquettes à l'image entière .	Partitionner une image en délimitant des régions d'intérêt pixel par pixel .
Nature de la sortie	Une étiquette de classe ou un vecteur de probabilités (ex : "Pneumonie").	Une carte de segmentation ou un masque de la même taille que l'image d'entrée.
Échelle d'analyse	Globale (au niveau de l'image).	Locale (au niveau du pixel ou du voxel).
Question posée	"Qu'est-ce que cette image représente ?" ou "Y a-t-il une pathologie ?"	"Où se trouvent précisément les différentes structures ?"
Architectures typiques	CNN classiques (ex : ResNet, DenseNet, VGG).	Encodeur-Décodeur , principalement U-Net et ses variantes.

cette distribution est signalé comme une anomalie. Des architectures comme les Auto-Encodeurs (AE) ou les Réseaux Génératifs Antagonistes (GANs) sont typiques de cette approche. L'avantage est qu'il n'est pas nécessaire de disposer d'exemples étiquetés pour chaque type d'anomalie possible [Fernando et al., 2021].

Des AE basés sur des GRU pour la détection de maladies respiratoires, des CNN-AE pour l'analyse d'EEG, et des 3D-CNN-AE pour l'analyse de scanners CT volumiques ont été proposés.

Un GAN est entraîné pour générer des images "normales" réalistes. Pour la détection d'anomalies, lorsqu'une image anormale est présentée au modèle, celui-ci ne parvient pas à la mapper correctement dans l'espace latent et à la reconstruire, révélant ainsi une anomalie. Exemple : Le framework AnoGAN a été utilisé pour la détection d'anomalies dans des images de tomographie par cohérence optique (OCT). Un autre exemple est une méthode basée sur les GAN pour la prédiction de crises d'épilepsie, où le discriminateur est ensuite adapté pour la classification normal/anormal.

2.2 Quelques architectures de référence

1. Pour la classification : Réseaux de neurones convolutifs (CNN) de type ResNet et DenseNet.
2. Pour la segmentation : L'architecture U-Net et ses variantes, un standard pour la segmentation biomédicale.
3. Pour la détection d'anomalies

TABLE 2.2 – Tableau comparatif entre la Classification et la Détection d'Anomalies

Caractéristique	Classification	Détection d'Anomalies
Objectif Principal	Attribuer une étiquette parmi un ensemble de classes connues .	Identifier les données inhabituelles ou hors-distribution par rapport à une norme.
Données d'Entraînement	Principalement supervisée , avec des étiquettes pour chaque classe.	Souvent non supervisée , entraînée uniquement sur des données "normales".
Type de Problème	Apprend à discriminer entre plusieurs classes spécifiques.	Apprend à modéliser la normalité et à détecter les déviations.
Gestion des Classes	Opère dans un " monde fermé " : ne reconnaît que les classes vues à l'entraînement.	Opère dans un " monde ouvert " : conçu pour identifier les données nouvelles ou non vues.
Cas Particulier	N/A	Peut être formulée comme une classification binaire supervisée (normal vs anormal), surtout en médecine.

2.2.1 UNet pour la segmentation d'images


La segmentation d'images consiste à détecter un objet ou des frontières dans une image. Par exemple, il peut s'agir de délimiter un organe.

En pratique, on cherche un masque de même taille que l'image analysée qui différencie la zone d'intérêt des autres parties de l'image.

L'architecture UNet a permis une avancée significative dans les problèmes de segmentation d'image [Ronneberger et al., 2015]. L'architecture UNet est basée sur des couches de convolutions qui sont organisées selon une structure particulière. En effet, UNet combine une partie contractante et une partie expansive voir Fig. 2.1.


- La **partie contractante** réduit la dimension de l'image tout en capturant les caractéristiques importantes. Elle agit ainsi comme une projection (non linéaire) dans un espace de dimension plus faible que la taille de l'image de départ. Elle superpose des étapes de convolution et de pooling. Par exemple, la figure 2.3 montre une structure à 5 blocs (décrite plus précisément dans la source indiquées dans la légende de la figure). À chaque niveau, la taille spatiale diminue tandis que le nombre de canaux de caractéristiques augmente, ce qui permet au modèle de capturer des motifs de plus haut niveau.

ce que ça
aussi à
ecter des
malies ?



The U-Net architecture.

FIGURE 2.1 – Source <https://medium.com/@alejandro.itoaramendia/decoding-the-u-net-a-complete-guide-810b1c6d56d8>



The contracting path of the U-Net.

FIGURE 2.2 – Source <https://medium.com/@alejandro.itoaramendia/decoding-the-u-net-a-complete-guide-810b1c6d56d8>

Le premier bloc prend en entrée une image en niveaux de gris (1 channel).

-] Au niveau du goulot d'étranglement (Bottleneck), la partie centrale du réseau, on obtient l'image la plus réduite. Elle contient une version compacte mais très informative de l'image, qui capture les principales caractéristiques.
- Le décodeur commence à reconstruire la taille originale de l'image par suréchantillonnage. On combine des étapes de déconvolution. À chaque niveau, les caractéristiques de la partie gauche sont combinées avec celles de la partie droite correspondantes grâce aux connexions de saut, afin de conserver les détails spatiaux fins. Dans le premier bloc de la partie expansive (bloc 5), une convolution 3×3 est appliquée (unpadded, la dimension est conservée). Puis une déconvolution 2×2 permet de upsampling the spatial dimensions twofold and et diminuer le nombre de chanel d'un facteur 2.

Dans le second bloc (bloc 4), on utilise des connexions directes et on concatène les données du bloc 4 de la partie contractante à celles obtenues par la partie expansive. On double ainsi le nombre de chanel. Note that this concatenation must be cropped to match the expanding path's dimensions. On applique ensuite une convolution 3×3 qui divise par deux le nombre de chanel, suivie d'une up-convolution 2×2 pour upsampling the spatial dimensions twofold and et diminuer le nombre de chanel d'un facteur 2.

Ainsi de suite.

Finalement, dans le dernier bloc, on a 128 chanel après avoir concaténé les données. Une convolution 3×3 (unpadded) est appliquée et le nombre de chanel est divisé par 2. Finalement, une couche de convolution 3×3 , suivie d'une fonction d'activation sigmoid (pour la classification binaire) est utilisée pour réduire le nombre de chanel au nombre de classes désiré. Dans les applications médicales, on a souvent 2 classes.

La déconvolution est illustrée sur la figure 2.4. En pratique on multiplie le filtre par chaque pixel de l'image à déconvoluée et on somme ces opérations.

Les connexions de saut aident à préserver la précision spatiale en transférant les caractéristiques détaillées des couches précédentes. Elles sont particulièrement utiles lorsque le modèle doit distinguer les frontières dans des tâches de segmentation.

La structure d'UNet ressemble à celle d'un encodeur-décodeur, spécialisée (inspirée des autoencodeurs), mais ce n'est pas un autoencodeur classique, car : il ne reconstruit pas nécessairement l'image d'entrée ; son décodeur prédit un masque de segmentation (ou une sortie similaire) plutôt qu'une copie exacte de l'entrée. Contrairement à un autoencodeur classique, U-Net ajoute des connexions directes entre les couches correspondantes de l'encodeur et du décodeur. Ces connexions transmettent les informations spatiales fines perdues lors du sous-échantillonnage, ce qui est crucial pour des tâches comme la segmentation d'images.

Remarques

1. La structure d'UNet ressemble à celle d'un encodeur-décodeur, spécialisée (inspirée des autoencodeurs), mais ce n'est pas un autoencodeur classique, car : il ne reconstruit pas nécessairement l'image d'entrée ; son décodeur prédit un masque de segmentation (ou une sortie similaire) plutôt qu'une copie exacte de l'entrée. Contrairement à un autoencodeur classique, U-Net ajoute des connexions directes entre les couches correspondantes

ire les opé-
on, re-
ndre las
ventions
lice...




FIGURE 2.3 – Source <https://medium.com/@alejandro.itoaramendia/decoding-the-u-net-a-complete-guide-810b1c6d56d8>




FIGURE 2.4 – Source <https://medium.com/@alejandro.itoaramendia/decoding-the-u-net-a-complete-guide-810b1c6d56d8>

de l'encodeur et du décodeur. Ces connexions transmettent les informations spatiales fines perdues lors du sous-échantillonnage, ce qui est crucial pour des tâches comme la segmentation d'images.

2. Attention dans les architecture UNet est un mecanisme qui permet de traiter des organes dont la forme et la taille peut varier.

2.2.2 Yolo la segmentation d'images

YOLO (You Only Look Once) est utilisé pour les images médicales, notamment dans la recherche et certaines applications cliniques. C'est un modèle de détection d'objets, ce qui correspond bien à des tâches comme repérer une tumeur, un polype, un nodule ou une cellule. Il est rapide, donc utile pour des applications en temps réel (ex. endoscopie, chirurgie assistée). Il fournit à la fois une localisation (boîtes englobantes) et une classification de la région d'intérêt.


L'architecture **YOLO** (*You Only Look Once*) est un modèle de détection d'objets en temps réel basé sur un réseau de neurones convolutionnel unique. Contrairement aux méthodes classiques à deux étapes (comme R-CNN) qui séparent la proposition de régions et la classification, YOLO **traite la détection comme un problème de régression unique**. L'image est divisée en une grille et, pour chaque cellule, le réseau prédit simultanément les **coordonnées des boîtes englobantes**, la **confiance de détection** et les **probabilités de classe**. Cette conception permet une **vitesse d'inférence élevée** tout en maintenant une bonne précision, ce qui rend YOLO particulièrement adapté aux applications nécessitant une analyse en temps réel.

Exemples d'applications

- Radiologie : détection de nodules pulmonaires sur radios thoraciques ou coupes CT.
- Pathologie : identification de cellules cancéreuses sur des lames histopathologiques.
- Gastroentérologie : détection de polypes sur vidéos de coloscopie en temps réel.
- Dermatologie : détection de lésions cutanées.
- Mammographie : repérage de masses ou microcalcifications.

Les limites de YOLO sont les suivantes. YOLO ne fait pas de segmentation détaillée au pixel près ; pour cela on préfère des modèles comme U-Net ou Mask R-CNN. Les ensembles de données médicales sont souvent petits et requièrent du transfert learning (pré-entraînement sur ImageNet puis fine-tuning sur données médicales).

Bien que **YOLO** et **U-Net** puissent tous deux prédire des classes, leurs objectifs diffèrent fondamentalement. YOLO est conçu pour la **détection d'objets** : il localise et classe plusieurs objets dans une image en prédisant, pour chaque cellule d'une grille, les *coordonnées des boîtes englobantes*, une *confiance de détection* et des *probabilités de classe*. En revanche, U-Net est un réseau de **segmentation sémantique** : il prédit une *classe pour chaque pixel* de l'image, sans générer de boîte englobante. Son architecture en *encodeur-décodeur* avec des connexions de saut permet de préserver la précision spatiale nécessaire à la segmentation fine des structures anatomiques.



YOLOv12 Architecture

FIGURE 2.5 – Architecture de YOLOv12. Source <https://fr.so-development.org/a-simple-yolov12-tutorial-from-beginners-to-experts/>

2.2.3 Fonction de perte

La segmentation peut être interprétée comme une tâche de classification supervisée. Une fonction de perte classique des la *cross entropy loss function*

$$L_c = - \sum_{i=1}^N y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)$$

pour une variable binaire Y définie dans $\{0, 1\}$.

La **perte de Dice (Dice Loss)** est une fonction de perte spécialisée principalement utilisée dans les tâches de segmentation d'images, en particulier dans l'analyse d'images médicales et les applications de vision par ordinateur. Elle est dérivée du coefficient de Dice (également connu sous le nom de F1-score ou coefficient de Sørensen–Dice), qui mesure le chevauchement entre deux échantillons. Dans le cas de 2 classes telles que $y \in \{0, 1\}$, la fonction s'écrit

$$\text{DiceLoss} = 1 - \frac{2 \sum_{i=1}^n y_i \hat{y}_i + |\epsilon|}{\sum_{i=1}^n y_i + \sum_{i=1}^n \hat{y}_i + \epsilon}$$

2.2.4 Travaux pratiques

Mettre en oeuvre et comparer Unet, Attention UNET et Yolo pour la segmentation d'image sur un des deux jeux de données disponibles sur kaggle :

- détecter des cellules sanguines
<https://www.kaggle.com/code/alaagaberh/blood-cell-detection-using-yolov12>
- Image segmentation for ultrasound image, breast cancer
<https://www.kaggle.com/code/utkarshsaxenadn/breast-cancer-image-segmentation-att>

Questions

1. Choisir un jeu de données, expliciter la question posée et choisir un algorithme.
2. Visualiser quelques images du jeu de données.
3. Déterminer la démarche et les scores qui seront utilisés pour évaluer la performance de l'algorithme et la comparer à celle d'autres algorithmes.
4. Mettre en oeuvre l'algorithme.
5. Calculer, représenter les scores de performance. On pourra par exemple montrer un tableau récapitulatif.
6. Montrer le résultat de prédiction obtenu pour quelques images du jeu de données certaines bien prédites et d'autres mal prédites.
7. Discuter les résultats et conclure.

Chapitre 3

Construire une IA de Confiance : Quantification de l'Incertitude

Cette partie est entièrement dédiée à la quantification de l'incertitude (UQ), un concept clé pour gérer les erreurs de mesure et la fiabilité des modèles.

Il existe différentes sources d'incertitude (voir Figure 3.1).

- Incertitude aléatoire : liée au bruit et à la variabilité intrinsèque des données. C'est la manifestation directe des erreurs de mesure, des artefacts et de la variabilité inter-annotateurs.
L'incertitude aléatoire rend la classification difficile, voire parfois impossible, en raison de l'absence de caractéristiques distinctives.
- Incertitude épistémique : liée aux limites du modèle, souvent due à un ensemble d'entraînement limité. C'est la conséquence directe des petits échantillons.

Ce chapitre est très largement inspiré du mémoire de Lorenzo Mondo [?] et du papier de review [Gawlikowski et al., 2023].

3.1 Cadre bayésien

Pour prendre en compte les incertitudes, une approche classique consiste à travailler dans le cadre de modèles bayésiens.

Imaginons que nous disposions d'un jeu de données, que nous pouvons appeler notre jeu d'entraînement, bien que nous puissions le nommer comme nous le souhaitons. Ce jeu de données est constitué d'un ensemble d'entrées X , telles que des images de chats, de chiens, ou des scans médicaux. Nous disposons de n de ces points de données, $x_1, x_2, \dots, x_n$, que nous regrouperons sous le nom de X .

Chacun de ces points de données possède une étiquette correspondante, qui peut représenter la classe (par exemple, chat ou chien) ou une valeur numérique (comme 0, 1, 2, ...). Ainsi, nous avons des étiquettes correspondantes $y_1, y_2, \dots, y_n$ pour chaque point d'entrée, que nous regrouperons sous le nom de Y .

Dans la modélisation bayésienne, l'incertitude du modèle est formalisée comme une distribution de probabilité sur les paramètres du modèle ω , tandis que l'incertitude des données




FIGURE 3.1 – Visualisation des incertitudes liées aux données, aux modèles et aux distributions

est formalisée comme une distribution de probabilité sur les sorties du modèle y^* , étant donné un modèle paramétré f_ω .

La distribution sur une prédiction y^* , appelée *distribution prédictive*, est alors donnée par :

$$p(y^* | x^*, X, Y) = \int \underbrace{p(y^* | x^*, \omega)}_{\text{données}} \underbrace{p(\omega | X, Y)}_{\text{modèle}} d\omega$$

En utilisant le cadre bayésien formellement décrit dans l'équation ci-dessus, l'objectif est de fournir au système un nouveau point de données, appelé x^* , et d'obtenir une prédiction y^* . Le terme $p(\omega | X, Y)$ est appelée **distribution postérieure** sur les paramètres du modèle et décrit l'incertitude sur les paramètres du modèle étant donné un jeu de données d'entraînement X, Y .

Essentiellement, nous souhaitons connaître la sortie la plus probable y^* étant donné l'entrée x^* et le type de données d'entraînement que le modèle a observé. Dans l'approche bayésienne, plutôt que de viser une prédiction ponctuelle, nous cherchons une distribution pour notre sortie au lieu d'une seule valeur.

En se référant à l'équation, notre objectif est de dériver la distribution de probabilité figurant sur le côté gauche de l'équation, représentant la distribution de probabilité de y^* , étant donné notre entrée x^* et l'ensemble des données d'entraînement X et Y .




Fig. 2 The illustration shows the different steps of a neural network pipeline, based on the earth observation example of land cover classification (here settlement and forest) based on optical images. The different factors that affect the predictive uncertainty are highlighted in the boxes. Factor I is shown as changing environments by cloud-covered trees, and different types and colors of trees. Factor II is shown by insufficient measurements, that can not directly be used to separate between settlement and forest and by label noise. In practice, the resolution of such images can be low and which would also be part of Factor II. Factor III and Factor IV represent the uncertainties caused by the network structure and the stochastic training process, respectively. Factor V in contrast is represented by feeding the trained network with unknown types of images, namely cows and pigs

FIGURE 3.2 – Image from [Gawlikowski et al., 2023]

Cette distribution nous indique, de manière “*souple*” (*soft*), quelles valeurs de y^* sont les plus probables, étant donné nos données d’entraînement et la nouvelle entrée. Plutôt que de fournir une prédiction “*dure*” (*hard*) unique, cette approche probabiliste nous donne une mesure de notre **confiance** dans les différentes prédictions possibles pour y^* .

Idéalement, si cette distribution est très **pointue** (crête), cela signifie que notre incertitude est faible, car nous sommes confiants dans la prédiction. Inversement, si la distribution est très **plate**, cela suggère un haut degré d’incertitude, ce qui signifie que y^* pourrait potentiellement prendre une large gamme de valeurs, sans qu’une valeur particulière se détache comme particulièrement probable.

C’est cette distribution qui nous intéresse. Typiquement, dans la littérature, pour capturer cette distribution, nous la considérons comme l’intégrale de la fonction de vraisemblance multipliée par la distribution *postérieure*. Mais que signifie cela exactement ?

Dans l’équation, ω représente les **poids** que le modèle cherche à apprendre pendant l’entraînement. Dans les architectures classiques de deep learning, ces poids sont des valeurs fixes que nous essayons d’apprendre. Cependant, dans la perspective bayésienne, nous cherchons à apprendre une **distribution** pour nos poids.

C’est ce que nous appelons la *distribution postérieure* — la distribution sur les paramètres qui décrit au mieux la correspondance entre l’entrée x et la sortie y . Par conséquent, le second terme à l’intérieur de l’intégrale dans l’équation représente notre **distribution postérieure sur les poids**.

Le premier terme, connu sous le nom de **fonction de vraisemblance** (*likelihood function*), représente la distribution de probabilité de y^* étant donné l’entrée x^* et les poids ω , mais il n’est pas conditionné sur les données d’entraînement.

La distribution finale que nous cherchons à obtenir, soit $p(y^* | x^*, X, Y)$, n’est rien d’autre qu’une **moyenne pondérée** de notre fonction de vraisemblance, la distribution postérieure fournissant les poids.

- La **fonction de vraisemblance** encapsule ce que nous avons défini comme l’*incertitude des données* (*data uncertainty*).
- La **fonction postérieure** représente ce que l’on peut appeler l’*incertitude de connaissance* (*knowledge uncertainty*).

Ce cadre théorique nous aide à comprendre, de manière formelle, l’origine de l’incertitude des données et de l’incertitude de connaissance. Cependant, ces deux types d’incertitude sont généralement **intraitables** — dans de nombreux scénarios réels, il est impossible d’obtenir des expressions exactes pour elles. Par conséquent, ce que l’on fait souvent consiste à **approximer** ces distributions de différentes manières afin d’essayer de quantifier ces incertitudes.

3.2 Calibration

Définition de la calibration

All machine learning models are bound to make wrong predictions. One would like the confidence of a model's predictions to be proportional to the probability of making a correct prediction.

Pour un échantillon de test x_i , le modèle prédit la classe $\hat{y}_i$ avec une probabilité $\hat{p}_i$. Le modèle est bien calibré si, on a : $P(\hat{y} = y \mid \hat{p}) = \hat{p}$.

Les modèles de deep learning ont tendance à être trop confiants : ils surestiment la probabilité p . L'utilisation des probabilités Softmax comme estimations d'incertitude est basée sur l'hypothèse que le réseau de neurones est bien calibré. Ces probabilités peuvent servir de référence simple (souvent non calibrée) pour la comparaison avec des approches plus sophistiquées.

Exemple

Considérons une tâche de classification unidimensionnelle. Supposons qu'un nombre égal d'échantillons provienne de deux distributions $p_0 = \mathcal{N}(-1, 1)$ et $p_1 = \mathcal{N}(1, 1)$, et que la tâche consiste à déterminer si un échantillon x provient de la distribution p_0 ou de p_1 . Naturellement, on peut proposer la fonction suivante :

$$c(x) = \begin{cases} 0, & \text{si } x \leq 0, \\ 1, & \text{sinon,} \end{cases}$$

comme classificateur atteignant une précision maximale.

Dans ce problème, on s'attend à ce que l'incertitude de la classification soit élevée à proximité de la frontière de décision en $x = 0$. Comme les densités des deux distributions sont connues, la probabilité de classification peut être calculée analytiquement comme suit :


$$P(x \in C_1) = \frac{p_1(x)}{p_0(x) + p_1(x)}.$$

Un classificateur entraîné sur ce problème ne placerait pas la frontière de décision exactement en $x = 0$, mais seulement à proximité, en raison de l'arrêt précoce de l'apprentissage (early stopping). Par conséquent, un ensemble de tels modèles approchent l'incertitude qu'à proximité de $x = 0$, mais n'estiment pas la qualité de la classification (Fig. 3.2).

Il existe différentes approches pour calibrer les prédictions : calibration post-hoc (après l'entraînement) et calibration ad-hoc (pendant l'entraînement).

3.3 Mesure de l'erreur de calibration

Plusieurs méthodes ont été proposées pour **quantifier le degré de (mauvaise) calibration** des réseaux de neurones. Parmi les métriques les plus couramment utilisées, on trouve les suivantes [Mondo, 2024].



Erreur de calibration espérée (ECE, *Expected Calibration Error*). L'ECE est un *résumé scalaire* de la différence entre la **confiance** et la **précision** sur l'ensemble des prédictions. Elle est calculée en divisant les prédictions en M intervalles (*bins*) selon leurs scores de confiance, puis en appliquant la formule suivante :

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|$$

où B_m est l'ensemble des échantillons appartenant à l'intervalle m , $\text{acc}(B_m)$ représente la précision moyenne dans cet intervalle, $\text{conf}(B_m)$ la confiance moyenne, et n le nombre total d'échantillons.

Un modèle bien calibré devrait satisfaire la condition suivante dans chaque intervalle :

$$\text{acc}(B_m) \approx \text{conf}(B_m)$$

Diagramme de fiabilité (*Reliability Diagram*). Le diagramme de fiabilité est une représentation graphique de la calibration. Comme illustré à la Figure 3.3, il trace $\text{acc}(B_m)$ en fonction de $\text{conf}(B_m)$ pour chaque intervalle (*bin*). Une calibration parfaite correspond à la **ligne diagonale**, où la confiance coïncide avec la précision empirique. Des barres au dessus de la diagonales indiquent un défaut de confiance tandis que des barres en dessous de la diagonales indiquent un excès de confiance

Score de Brier (*Brier Score*). Le *Brier Score* est une autre métrique largement utilisée pour évaluer la qualité des prédictions probabilistes, en particulier dans les tâches de classification binaire, et peut être étendu aux sorties de segmentation voxel par voxel. Il mesure la **différence quadratique moyenne** entre la probabilité prédite et le résultat réel. Pour une seule prédiction, il est défini comme suit :

$$\text{Brier Score} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2$$

où $\hat{p}_i \in [0, 1]$ est la probabilité prédite pour le $i^{\text{ème}}$ échantillon (par exemple, la sortie du *softmax* pour un voxel), et $y_i \in \{0, 1\}$ est l'étiquette réelle (*ground truth*).




FIGURE 3.3 – *Diagramme de fiabilité illustrant la calibration d'un modèle.* La ligne en pointillés représente la **calibration parfaite**, où la confiance correspond à la précision. Les barres situées **au-dessus** de la diagonale indiquent une **sous-confiance** (*underconfidence*), tandis que celles situées **en dessous** indiquent une **surconfiance** (*overconfidence*).

Un *Brier Score* plus faible indique des prédictions à la fois mieux calibrées et plus précises, car il reflète non seulement si la prédiction est correcte, mais aussi à quel point la confiance prédite est proche du résultat réel. Contrairement à l'ECE, qui se concentre sur les écarts de calibration entre intervalles de confiance, le *Brier Score* fournit une mesure plus globale combinant à la fois la **calibration** et la **précision** en une seule valeur.

Par exemple, un modèle parfaitement calibré qui prédit toujours une probabilité de 0.5 sur un jeu de données équilibré aura une **faible ECE**, mais un **Brier Score relativement élevé**, en raison d'un manque de *résolution*. À l'inverse, un modèle bien calibré et à haute résolution présentera des valeurs faibles pour les deux métriques.

Dans le contexte de la segmentation, le *Brier Score* complète l'ECE en ajoutant une sensibilité à la fois aux prédictions incorrectes trop confiantes et aux **prédictions correctes trop peu confiantes**. Alors que l'ECE agrège les écarts de calibration par intervalles (*bins*), le *Brier Score* pénalise chaque voxel mal calibré proportionnellement au carré de son erreur, ce qui le rend particulièrement utile pour une analyse fine des performances.

Log-vraisemblance négative (*Negative Log-Likelihood*, NLL). Bien qu'à l'origine conçue comme fonction de perte pour l'entraînement des modèles probabilistes, la *NLL* sert également de métrique sensible à la calibration. Une valeur élevée de NLL indique que les distributions de probabilités prédites reflètent mal la distribution réelle des résultats. Contrairement à l'ECE, elle pénalise beaucoup plus fortement les prédictions erronées trop confiantes.

3.4 Quantifier l’incertitude

- Méthode déterministes basée sur une seule prédiction (une seule passe avant).
- Deep Ensembles : Agréger les prédictions de plusieurs modèles entraînés indépendamment pour quantifier l’incertitude. Connus pour leur robustesse et la qualité de leurs estimations d’incertitude.
- Monte Carlo Dropout (MC Dropout) : Approcher l’inférence bayésienne en activant le dropout lors de l’inférence. C’est la méthode la plus populaire en imagerie médicale (plus d’un tiers des implémentations).
- Test-Time Augmentation (TTA) : Générer plusieurs prédictions en appliquant des transformations à l’image d’entrée au moment du test.

3.4.1 Deep Ensemble for Uncertainty Estimation

Une des approches les plus efficaces et conceptuellement simples pour l’estimation de l’incertitude en deep learning est l’utilisation des Deep Ensembles. Cette méthode repose sur l’entraînement de plusieurs instances d’un modèle de réseau neuronal — chacune initialisée avec des **graines aléatoires** différentes et éventuellement exposée à des mélanges de données différents — de sorte que leurs prédictions forment un ensemble diversifié d’hypothèses sur la sortie.

Lors de l’inférence, la prédiction finale est typiquement calculée en agrégeant les sorties (par exemple, par moyenne), et la dispersion entre ces sorties est utilisée comme une estimation de l’*incertitude épistémique*.

Définition et justification. Un **ensemble** en apprentissage automatique est un ensemble de modèles dont les sorties sont combinées pour produire une prédiction finale. Dans le contexte du deep learning, un **Deep Ensemble** désigne un ensemble de réseaux neuronaux $f_{\theta_1}, \dots, f_{\theta_M}$ entraînés indépendamment sur la même tâche, mais initialisés avec des paramètres différents.

Cette stratégie repose sur l’observation que, en raison de leurs paysages de perte non convexes, les réseaux neuronaux peuvent converger vers différents minima locaux. En capturant ces variations, les ensembles peuvent représenter implicitement **plusieurs modes de la distribution postérieure sur les fonctions**, ce qui en fait des outils puissants pour modéliser l’*incertitude du modèle (incertitude épistémique)*.

Formellement, étant donné une entrée x , la distribution prédictive de l’ensemble est donnée par :

$$p(y \mid x, D) \approx \frac{1}{M} \sum_{m=1}^M p(y \mid x, \theta_m),$$

où D est le jeu de données d’entraînement, et θ_m sont les paramètres du $m^{\text{ème}}$ modèle de l’ensemble.

La **variabilité** des prédictions entre les modèles — en particulier lorsque les données sont rares ou ambiguës — peut être interprétée comme un reflet de l’*incertitude épistémique*,

car elle montre à quel point les sorties du modèle sont sensibles à ses paramètres.

Avantages et considérations pratiques. L’approche des **Deep Ensembles** présente plusieurs avantages intéressants. Tout d’abord, elle est **conceptuellement simple** et ne nécessite aucune modification de l’architecture du réseau sous-jacent ni de l’objectif d’entraînement. Deuxièmement, Les ensembles fournissent des estimations d’incertitude **robustes et bien calibrées** [?, ?]. De plus, ils améliorent souvent la **performance prédictive** du modèle de base en réduisant le surapprentissage (*overfitting*) et en moyennant les biais des modèles individuels.

Cependant, ces avantages ont un coût **informatique**. L’entraînement et le stockage de M modèles indépendants augmentent la consommation de mémoire et le temps de calcul proportionnellement à M , ce qui peut ne pas être faisable dans tous les contextes de déploiement. Malgré cela, des études récentes ont montré que même des ensembles relativement petits (par exemple $M = 5$) suffisent à obtenir la plupart des bénéfices en termes d’incertitude et de précision [?].

Utilisation en analyse d’images médicales. Les Deep Ensembles ont été adoptés avec succès dans diverses applications d’imagerie médicale, en particulier là où l’**interprétabilité** et la **fiabilité** du modèle sont essentielles. Des tâches telles que la segmentation de tumeurs cérébrales, la délimitation d’organes, et la détection de lésions ont bénéficié de l’estimation d’incertitude basée sur les ensembles [?, ?]. Dans ces contextes, les modèles en ensemble aident à détecter et signaler les prédictions peu fiables, soutenant ainsi l’assurance qualité clinique et la prise de décision.

En résumé, les Deep Ensembles offrent un cadre **hautement pratique** et **empiriquement efficace** pour l’estimation de l’incertitude en deep learning. Leur capacité à capturer l’incertitude épistémique sans nécessiter de modifications complexes de la conception ou du processus d’entraînement des modèles les rend particulièrement précieux dans des domaines à enjeux élevés comme l’analyse d’images médicales. Bien que coûteux en termes de calcul, leurs avantages en termes de **fiabilité**, **robustesse** et **confiance** justifient souvent le coût supplémentaire dans les déploiements de recherche et cliniques.

3.4.2 Monte Carlo Dropout (MC Dropout)

Monte Carlo Dropout (MC Dropout) est une technique largement adoptée pour estimer l’incertitude dans les modèles d’apprentissage profond, particulièrement appréciée pour sa simplicité et sa compatibilité avec les pipelines d’entraînement standards. Introduite initialement par Gal et Ghahramani [?], cette méthode réinterprète le *dropout* — une technique de régularisation couramment utilisée — comme une forme d’inférence bayésienne approchée, permettant ainsi d’estimer l’incertitude du modèle sans modifier l’architecture sous-jacente ni l’objectif d’entraînement.

Définition et justification. Dans l’apprentissage profond conventionnel, le *dropout* est appliqué pendant l’entraînement afin de désactiver aléatoirement un sous-ensemble de neurones dans une couche, réduisant ainsi le surapprentissage et favorisant la robustesse. Typiquement, le *dropout* est désactivé lors de l’inférence, et le réseau complet est utilisé pour produire des prédictions déterministes. Cependant, Gal et Ghahramani ont proposé de maintenir le *dropout* actif pendant l’inférence et d’effectuer plusieurs passes avant (*forward passes*) avec des masques de *dropout* aléatoires différents.

Cela entraîne une distribution de sorties pour chaque échantillon d'entrée, qui peut être interprétée comme des échantillons provenant de la distribution prédictive postérieure d'un modèle bayésien [?].

Formellement, soit x^* une donnée de test et $\hat{f}_{\omega_t}(x^*)$ la sortie du modèle sous le masque de *dropout* t lors de l'inférence. En effectuant T passes avant stochastiques, on obtient un ensemble de prédictions $\{\hat{f}_{\omega_1}(x^*), \dots, \hat{f}_{\omega_T}(x^*)\}$, qui peuvent être utilisées pour calculer la sortie espérée et quantifier l'incertitude prédictive :

$$\mathbb{E}[y^*] \approx \frac{1}{T} \sum_{t=1}^T \hat{f}_{\omega_t}(x^*), \quad (3.1)$$

$$\text{Var}[y^*] \approx \frac{1}{T} \sum_{t=1}^T \hat{f}_{\omega_t}(x^*)^2 - (\mathbb{E}[y^*])^2. \quad (3.2)$$

Ici, la variance sert de proxy pour l'incertitude épistémique, capturant la variabilité induite par l'incertitude sur les paramètres du modèle.

Dans le contexte de la segmentation d'images, le réseau produit des distributions de probabilité voxel-par-voxel sur les différentes classes. Avec le *MC Dropout*, chacune des T passes avant stochastiques génère une carte de prédiction *softmax* distincte. La moyenne voxel-par-voxel de ces prédictions fournit l'estimation finale de la segmentation, tandis que la variance voxel-par-voxel quantifie l'incertitude épistémique.

Soit $p_i^{(t)}$ la probabilité prédite pour le voxel i lors de la t -ième passe avant. La prédiction moyenne est donnée par :

$$\bar{p}_i = \frac{1}{T} \sum_{t=1}^T p_i^{(t)}, \quad (3.3)$$

et l'incertitude associée au voxel i est estimée par :

$$\text{Var}_i = \frac{1}{T} \sum_{t=1}^T \|p_i^{(t)} - \bar{p}_i\|^2. \quad (3.4)$$

Cette variance indique la cohérence des prédictions du modèle entre les différents sous-réseaux induits par le *dropout*. Une variance élevée signale généralement des zones où le modèle présente une incertitude importante, souvent due à un manque d'exposition à des motifs similaires durant l'entraînement.

Avantages et considérations pratiques. Le *MC Dropout* présente de nombreux avantages pratiques. Il est indépendant de l'architecture et ne nécessite aucune modification du processus d'entraînement — seule la procédure d'inférence doit être adaptée afin d'effectuer plusieurs passes stochastiques. Cela rend le *MC Dropout* particulièrement attrayant

dans les contextes où le réentraînement d'un modèle est coûteux ou difficilement réalisable. De plus, il n'introduit qu'une augmentation modérée de la charge de calcul lors de l'inférence, contrôlable via le nombre d'échantillons T [?].

Malgré ces atouts, la méthode présente certaines limites. La qualité des estimations d'incertitude dépend du taux de *dropout* et du nombre de passes effectuées lors de l'inférence. Par ailleurs, en tant qu'approximation variationnelle, le *MC Dropout* peut ne pas capturer fidèlement la véritable distribution a posteriori des poids, ce qui peut entraîner une sous-estimation de l'incertitude, notamment en présence d'entrées hors distribution [?]. De plus, contrairement aux méthodes basées sur les ensembles, toutes les passes avant du *MC Dropout* proviennent d'un même modèle entraîné, ce qui limite potentiellement la diversité des hypothèses échantillonnées.

En conclusion, le *MC Dropout* constitue une méthode pratique et théoriquement fondée pour estimer l'incertitude dans les réseaux de neurones profonds. Sa facilité d'intégration, sa faible surcharge computationnelle et ses bonnes performances empiriques en font une approche de référence dans de nombreuses applications de segmentation d'images médicales sensibles à l'incertitude. Bien qu'il présente certaines limitations, il demeure un outil essentiel pour le développement de systèmes d'intelligence artificielle robustes et interprétables dans le domaine de la santé.

<https://www.geeksforgeeks.org/deep-learning/what-is-monte-carlo-mc-dropout/>
<https://arxiv.org/pdf/2006.11584>

3.4.3 Augmentation au moment du test pour l'estimation de l'incertitude (*Test-Time Augmentation, TTA*).

La *Test-Time Augmentation* (TTA) est une méthode simple mais efficace pour estimer l'incertitude dans les modèles de deep learning. Contrairement aux techniques traditionnelles d'augmentation de données utilisées lors de l'entraînement pour améliorer la généralisation, la TTA est appliquée **au moment de l'inférence**.

L'idée centrale est d'introduire une **variabilité contrôlée** dans l'entrée de test — via un ensemble de transformations réversibles — puis d'analyser la **variabilité des prédictions du modèle** sur ces entrées transformées. Cette approche permet d'estimer l'incertitude sans nécessiter de modifications de l'architecture ni de réentraînement, ce qui la rend particulièrement attractive dans les contextes cliniques et en temps réel.

Définition et justification. Le processus TTA se compose de quatre étapes principales. Tout d'abord, un ensemble d'augmentations déterministes (par exemple, retournement, rotation, mise à l'échelle, injection de bruit) est appliqué à l'image de test, générant N versions augmentées de l'entrée. Le modèle est ensuite utilisé pour prédire une **carte de segmentation** pour chaque entrée augmentée. Ces prédictions sont ensuite **dés-augmentées** — c'est-à-dire transformées pour revenir dans l'espace de l'entrée originale — afin d'aligner toutes les prédictions spatialement. Enfin, les prédictions dés-augmentées sont **agrégées**, et leur variabilité est analysée pour quantifier l'incertitude du modèle.

Formellement, soit x une image d'entrée et $T = \{t_1, \dots, t_N\}$ un ensemble d'augmentations déterministes. Chaque version augmentée est $x_n = t_n(x)$, et la prédiction correspondante

est $y_n = f_\theta(x_n)$. La prédiction est ensuite dés-augmentée comme suit :

$$y_{\text{inv}} = t_n^{-1}(y_n)$$

pour la ramener dans l'espace de l'image originale. L'ensemble $\{y_{\text{inv},1}, \dots, y_{\text{inv},N}\}$ est ensuite utilisé pour l'agrégation et l'estimation de l'incertitude.

Estimation de l'incertitude via la variabilité TTA. Une fois toutes les prédictions dés-augmentées alignées, la sortie du modèle peut être prise comme la **prédiction moyenne** :

$$\bar{p}_i = \frac{1}{N} \sum_{n=1}^N p_i^{(n)},$$

où $p_i^{(n)}$ est la probabilité prédite pour la classe au voxel i à partir de la n -ième entrée augmentée et dés-augmentée.

La variance associée au niveau du voxel est calculée comme suit :

$$\text{Var}_i = \frac{1}{N} \sum_{n=1}^N \|p_i^{(n)} - \bar{p}_i\|^2.$$

Cette variance capture la sensibilité de la sortie du modèle à de légères modifications de l'entrée, mesurant ainsi l'**incertitude aléatoire** (*aleatoric uncertainty*), c'est-à-dire l'incertitude provenant du bruit ou de l'ambiguïté inhérente aux données.

La TTA peut également être combinée avec le *MC Dropout* pour capturer à la fois l'**incertitude épistémique** et l'**incertitude aléatoire**. Dans ce cas, plusieurs passages avant (*forward passes*) stochastiques sont effectués pour chaque entrée augmentée, et la variabilité totale est ensuite décomposée en ses deux composantes.

Avantages et considérations pratiques. La TTA offre plusieurs avantages. Elle est **agnostique au modèle** et ne nécessite pas de réentraînement, ce qui la rend compatible avec n'importe quel modèle pré-entraîné. Elle présente également une **barrière d'implémentation faible**, puisque la plupart des bibliothèques modernes de deep learning fournissent des outils de transformation efficaces. D'un point de vue probabiliste, la TTA fournit une approximation non paramétrique de l'incertitude conditionnée à l'entrée en évaluant la stabilité des sorties du modèle sous de petites perturbations de l'entrée.

Cependant, la TTA introduit un coût computationnel supplémentaire lors de l'inférence, puisqu'il faut effectuer N prédictions pour chaque entrée. Le compromis entre la qualité de l'estimation de l'incertitude et l'efficacité dépend du nombre et du type d'augmentations utilisées. De plus, il convient de veiller à ce que les augmentations soient **réversibles** et **cliniquement valides** — par exemple, un retournement horizontal peut ne pas être acceptable pour des organes anatomiquement asymétriques comme le cœur ou le foie.

En conclusion, la *Test-Time Augmentation* est une méthode **puissante** et **flexible** pour quantifier l'**incertitude aléatoire** dans la segmentation d'images médicales. Sa simplicité, son adaptabilité et sa compatibilité avec les modèles existants en font un outil précieux dans les flux de travail cliniques où la **robustesse** et la **fiabilité** sont primordiales.

3.4.4 Checkpoints Ensemble pour l'estimation de l'incertitude.

La méthode *Checkpoints Ensemble* est une technique récente et très efficace pour estimer l'incertitude dans les modèles de deep learning, particulièrement adaptée aux architectures auto-configurantes comme NNU-NET. Contrairement aux approches bayésiennes traditionnelles, qui nécessitent des modifications de l'architecture ou des ressources computationnelles importantes, cette méthode exploite le comportement naturel du *stochastic gradient descent* (SGD) pour extraire des échantillons postérieurs des poids du réseau pendant l'entraînement.

Fondements conceptuels. Lors de l'entraînement de réseaux neuronaux avec SGD, notamment avec des *learning schedules* non convergents, les poids du modèle fluctuent naturellement autour des optima locaux. Cette fluctuation peut être interprétée comme un échantillonnage stochastique de la distribution postérieure dans l'espace des poids. À partir de cette idée, la technique *Checkpoints Ensemble* propose de sauvegarder périodiquement des **checkpoints du réseau** lors des dernières époques d'entraînement — particulièrement après que le modèle s'est stabilisé — pour approcher des échantillons de la distribution postérieure $p(\omega \mid D)$. En agrégeant les prédictions de ces checkpoints divers, il devient possible de capturer l'incertitude épistémique sans modifier l'architecture ni introduire de bruit d'échantillonnage lors de l'inférence.

Description de la méthode. Soit D le jeu de données d'entraînement, et w_t les poids du réseau à l'époque t . Après une phase initiale de *burn-in* (par exemple, les γT premières époques), le modèle commence l'échantillonnage postérieur en collectant les poids $\{w_t\}_{t=\gamma T}^T$. Ces checkpoints sont ensuite utilisés pour une approximation de Monte Carlo de la distribution prédictive :

$$p(y^* \mid x^*, D) \approx \frac{1}{n} \sum_{i=1}^n p(y^* \mid x^*, w_{t_i}),$$

où n est le nombre de checkpoints sélectionnés, et $p(y^* \mid x^*, w_{t_i})$ est la prédiction du modèle avec les poids w_{t_i} .

Comme chaque checkpoint correspond à une configuration légèrement différente en raison du bruit introduit par le SGD, leur agrégation peut refléter l'incertitude dans les zones où la confiance du modèle est faible.

Échantillonnage postérieur multi-modal. Pour améliorer la diversité postérieure, les auteurs proposent un *schedule* de taux d'apprentissage cyclique, où l'entraînement est divisé en M cycles. Au début de chaque cycle, le taux d'apprentissage est remis à une

valeur élevée, incitant le modèle à sortir des minima précédents et à explorer de nouvelles régions de l’espace des poids. À l’intérieur de chaque cycle, des checkpoints sont collectés après une phase de *warm-up* et utilisés comme modes postérieurs indépendants. L’ensemble ainsi obtenu capture donc à la fois l’incertitude locale et globale en combinant la variabilité *intra-mode* et *inter-mode*.

En résumé, la méthode *Checkpoints Ensemble* combine les forces de l’estimation d’incertitude bayésienne avec la simplicité pratique des pipelines d’entraînement standard. Son applicabilité à NNUNET et l’amélioration des performances sur des données hors domaine en font un outil précieux pour une segmentation fiable en imagerie médicale.

3.5 Calibration

3.5.1 Temperature Scaling

Une méthode de calibration appelée *temperature scaling* (ou *mise à l’échelle par la température*) est une technique simple mais efficace pour recalibrer les probabilités de prédiction (Guo et al., 2017). Le *temperature scaling* est une version à un seul paramètre de la méthode de *Platt Logistic Scaling* (Platt, 1999).

Le *temperature scaling* utilise un unique paramètre scalaire $T > 0$, où T représente la *température*, pour rééchelonner les scores de logit avant d’appliquer la fonction *softmax*, comme illustré dans la figure suivante. Comme la même valeur de T est utilisée pour toutes les classes, la sortie du *softmax* avec mise à l’échelle conserve une relation monotone avec la sortie non mise à l’échelle. Lorsque $T = 1$, on retrouve les probabilités originales issues de la fonction *softmax* standard. Dans le cas de modèles *trop confiants* (overconfident) où $T > 1$, les probabilités recalibrées sont plus faibles que les probabilités originales et sont distribuées de manière plus uniforme entre 0 et 1.

Autrement dit, les logits sont réécrits

$$P(\hat{y}) = \frac{e^{\mathbf{z}/T}}{\sum_k e^{z_k/T}}$$

where $\hat{y}$ est la prédiction, $\mathbf{z}$ est le logit et T est la température. .

La méthode permettant d’obtenir une température optimale T pour un modèle entraîné consiste à **minimiser la log-vraisemblance négative** (*negative log-likelihood*) sur un jeu de validation distinct.

$$L = - \sum_{i=1}^n \log f(x_i)$$

Il est recommandé d’intégrer la méthode de *temperature scaling* comme une partie du processus d’entraînement du modèle : après la fin de l’entraînement, il convient d’extraire la valeur de température T à l’aide du jeu de validation, puis de **rééchelonner les valeurs de logit** en utilisant T dans la fonction *softmax*.

D’après des expériences réalisées sur des tâches de classification de texte utilisant des modèles basés sur BERT, la température T se situe généralement dans une plage comprise entre 1.5 et 3.

La figure 3.5.1 suivante illustre la méthode de *temperature scaling*, qui applique la valeur de température T avant de transmettre le score de logit à la fonction *softmax*.





FIGURE 3.4 – Source : https://geoffpleiss.com/blog/nn_calibration.html

Dans le contexte de la segmentation d'images médicales, la **calibration** s'est imposée comme une étape nécessaire pour accroître la **fiabilité** des systèmes de deep learning. Mehrtash et al. [?] ont étudié les propriétés de calibration des modèles de segmentation en évaluant l'écart entre les cartes de confiance prédites et les performances réelles. Leur travail a analysé de manière systématique comment les modèles entraînés pour la segmentation de la prostate et des tumeurs cérébrales ont tendance à être mal calibrés, en particulier près des contours des objets ou dans les régions de tissus ambigus. En appliquant *temperature scaling* et des méthodes d'ensemble de manière post-hoc aux logits de segmentation, ils ont démontré une **réduction nette de la mauvaise calibration** mesurée par l'ECE, sans détériorer la qualité de segmentation en termes de score de Dice.

Une contribution plus récente et complète est fournie par Rousseau et al. [?], qui ont passé en revue et comparé un ensemble de méthodes de calibration post-hoc pour la segmentation, y compris le *temperature scaling*, le *histogram binning* et la régression isotone.

Contrairement aux études précédentes, ils ont évalué la calibration non seulement au niveau du voxel, mais également pour les prédictions de régions entières, en tenant compte des scénarios cliniques où les volumes de segmentation, plutôt que les étiquettes pixel par pixel, sont utilisés pour le diagnostic ou la planification des traitements.

L'étude a révélé que le *temperature scaling* reste l'une des approches les plus efficaces et robustes, en particulier lorsqu'il est appliqué séparément pour chaque classe dans les tâches de segmentation multi-classes. Les auteurs ont souligné la nécessité de sélectionner des métriques de calibration appropriées en fonction de l'objectif clinique — par exemple, l'estimation de la fiabilité par structure dans la planification de radiothérapie, versus les estimations globales d'incertitude pour le triage.

3.5.2 Evidential Deep Learning (EDL).

L'*Evidential Deep Learning* (EDL) est une approche d'apprentissage profond conçue pour estimer simultanément les **prédictions** et leur **incertitude**, sans recourir à des méthodes d'échantillonnage comme le *Monte Carlo Dropout* ou les *Deep Ensembles*.

Contrairement aux modèles de classification traditionnels qui produisent directement une probabilité via la fonction *softmax*, un modèle EDL prédit les **paramètres d'une distribution de Dirichlet** sur les classes possibles. Cette distribution encode à la fois la probabilité moyenne des classes et le degré de confiance du modèle dans ses propres prédictions.

Ainsi :

- Si le modèle est confiant, la distribution de Dirichlet est **concentrée** autour d'une classe spécifique (faible incertitude).
- Si le modèle est incertain, la distribution est **étalée**, reflétant une forte incertitude (par exemple, pour des données ambiguës ou hors distribution).

L'avantage majeur de l'EDL est qu'il permet une **quantification analytique de l'incertitude** directement à partir d'un seul passage dans le réseau, sans nécessiter d'ensembles de modèles ou de multiples inférences.

Formulation mathématique. Dans le cadre d'une tâche de classification à K classes, le modèle prédit un vecteur de *preuves* (*evidence*) $\mathbf{e} = [e_1, e_2, \dots, e_K]$, où chaque $e_k > 0$. Les paramètres de la distribution de Dirichlet sont ensuite définis comme :

$$\alpha_k = e_k + 1, \quad \forall k \in \{1, \dots, K\}.$$

La distribution de Dirichlet sur les probabilités de classe $\mathbf{p}$ est donnée par :

$$\text{Dir}(\mathbf{p} \mid \boldsymbol{\alpha}) = \frac{1}{B(\boldsymbol{\alpha})} \prod_{k=1}^K p_k^{\alpha_k - 1},$$

où $B(\boldsymbol{\alpha})$ est la fonction de normalisation bêta multivariée.

L'estimation de la probabilité moyenne pour chaque classe est :

$$\hat{p}_k = \frac{\alpha_k}{S}, \quad \text{où } S = \sum_{j=1}^K \alpha_j.$$

Pour entraîner le modèle, une fonction de perte spécifique est utilisée, basée sur la **Negative Log-Likelihood (NLL)** de la Dirichlet, avec une pénalisation supplémentaire sur l'incertitude excessive :

$$\mathcal{L} = \sum_{k=1}^K y_k (\psi(S) - \psi(\alpha_k)) + \lambda \cdot KL(\text{Dir}(\mathbf{p} \mid \boldsymbol{\alpha}) \parallel \text{Dir}(\mathbf{p} \mid \mathbf{1})),$$

où $\psi(\cdot)$ est la fonction digamma, et le second terme correspond à une régularisation Kullback-Leibler (KL) visant à éviter des prédictions artificiellement incertaines.

Ainsi, l'EDL apprend non seulement à classer les échantillons, mais aussi à **exprimer sa confiance** dans chaque prédiction, rendant cette approche particulièrement adaptée aux applications critiques telles que l'imagerie médicale ou les systèmes autonomes.

Lambert et al. [?] ont replacé la **calibration** dans le cadre plus large de l'**intelligence artificielle de confiance** (*trustworthy AI*). Ils ont proposé une revue structurée des techniques de calibration utilisées en apprentissage profond pour l'analyse d'images médicales et ont mis en évidence les liens entre la calibration, l'estimation de l'incertitude et l'applicabilité clinique.

Dans leur étude, ils ont discuté des méthodes basées sur les **distributions de Dirichlet** et l'**Evidential Deep Learning**, qui visent à modéliser la confiance des prédictions de manière plus fidèle. De plus, ils ont observé que les modèles bien calibrés sont plus efficaces lorsqu'ils sont utilisés conjointement avec des pipelines d'estimation d'incertitude, en particulier lorsque les décisions sont déléguées à des experts humains dans les zones de forte incertitude.

L'intégration des métriques de calibration dans l'évaluation des systèmes n'a pas été présentée comme un simple ajout technique, mais comme une **exigence éthique et interprétable**

Chapitre 4

La suite

4.1 Méthodes de Quantification de l'Incertainitude (Partie 2)

Objectifs : Explorer d'autres paradigmes d'UQ, notamment ceux qui ne nécessitent pas d'échantillonnage multiple.

Contenu :

1. Probabilités Softmax et Calibration : Utiliser directement la sortie du modèle, mais en s'assurant que les probabilités sont bien calibrées.
2. Evidential Deep Learning (EDL) : Modéliser explicitement une masse de croyance pour chaque classe ainsi qu'une masse d'incertitude globale.
3. Conformal Prediction : Une approche statistique qui fournit des ensembles de prédiction avec des garanties statistiques de couverture, sans hypothèse sur le modèle.
4. Modèles Génératifs (ex : Probabilistic U-Net) pour modéliser la distribution des segmentations possibles.

Chapitre 5

Évaluation, Robustesse et Déploiement Clinique

Cette dernière partie se concentre sur l'évaluation rigoureuse des modèles et les défis de leur généralisation dans des conditions réelles.

5.1 L'Incertitude Structurée : Du Pixel à la Lésion

Objectifs : Aligner les estimations d'incertitude avec l'attention clinique qui se porte sur des structures (lésions, organes) plutôt que sur des pixels.

Contenu :

1. Agrégation des incertitudes au niveau pixel pour obtenir un score de confiance par lésion ou par cas.
2. Utilisation de l'incertitude pour le contrôle qualité (QC) :
 - QC en entrée : Détection d'images non conformes ou hors-distribution (OOD).
 - QC en sortie : Détection de segmentations de mauvaise qualité.

5.2 Évaluation de la Robustesse face au Décalage de Distribution

Objectifs : Évaluer systématiquement la capacité du modèle à généraliser.

Contenu :

1. Le problème du décalage de distribution (domain shift) est omniprésent en médecine.
2. Types de décalage : nouvelles machines, nouveaux hôpitaux, nouvelles populations de patients.
3. Protocoles d'évaluation OOD : comment tester la réaction du modèle face à des données qu'il n'a jamais vues ?
4. Étude de cas : analyse de la performance de modèles de radiographie pulmonaire sur des photos de radios ou des données d'une institution externe.
5. L'importance d'évaluer la robustesse des estimations d'incertitude elles-mêmes sous un décalage de domaine.

5.3 Généralisation aux Maladies Rares et Imprévues

Objectifs : Comprendre comment les modèles se comportent face à des pathologies pour lesquelles ils n'ont pas été entraînés.

Contenu :

1. Le monde clinique est un "monde ouvert" ; un modèle ne peut pas être entraîné sur toutes les maladies existantes.
2. Étude systématique : Comment un modèle entraîné pour détecter un sous-ensemble de maladies (vues) réagit-il en présence de maladies non vues ?.
3. Constat : les modèles ont tendance à classer les maladies non vues comme "absence de maladie", ce qui peut être dangereux.
4. Stratégies de détection de maladies non vues en utilisant les représentations internes du réseau (ex : avant-dernière couche).
5. Lien entre incertitude et explicabilité (XAI) pour une IA médicale transparente.

TP : Évaluation de la Robustesse du Modèle

Objectifs : Mesurer la dégradation des performances d'un modèle face à un décalage de distribution.

Activités

1. Prendre un modèle entraîné sur un jeu de données (ex : CheXpert).
2. L'évaluer sur un jeu de données externe (ex : ChestX-ray14 de NIH) ou sur des données synthétiquement bruitées/transformées (ex : CheXphoto).
3. Quantifier la baisse de performance (AUC, F1-score).
4. Analyser si les estimations d'incertitude (obtenues via MC Dropout) permettent de détecter les échantillons OOD sur lesquels le modèle échoue.

Chapitre 6

Travaux Pratiques

6.1 Implémentation et Évaluation de l'Incertitude

Objectifs : Mettre en œuvre une méthode d'UQ pour visualiser et quantifier la confiance du modèle.

Activités :

1. Implémenter le MC Dropout sur un modèle CNN de segmentation (ex : U-Net).
2. Pour une image donnée, générer N prédictions et calculer des cartes de variance ou d'entropie pour visualiser l'incertitude au niveau du pixel.
3. Analyse : Mettre en corrélation l'incertitude prédite avec l'erreur de segmentation réelle (ex : Dice score) pour vérifier que les zones les plus incertaines sont bien celles où le modèle se trompe le plus.

6.2 Stratégies d'Apprentissage en Données Limitées

Objectifs : Maîtriser la technique la plus courante pour pallier le manque de données médicales.

Contenu :

1. Le paradigme du pré-entraînement sur ImageNet : bénéfices et limites.
2. Analyse critique : Pourquoi la performance sur ImageNet ne se transfère-t-elle pas toujours bien aux tâches médicales ?.
3. Stratégies de fine-tuning.
4. Efficacité des architectures : Les modèles plus grands sont-ils toujours meilleurs pour les tâches médicales ? Étude de cas sur les familles d'architectures (DenseNet, ResNet).
5. Techniques d'optimisation comme la troncature de modèles pour améliorer l'efficacité sans perte de performance significative.

6.3 Apprentissage Auto-Supervisé (Self-Supervised Learning)

Objectifs : Explorer comment extraire des représentations pertinentes d'images médicales non étiquetées.

Contenu :

1. Principe de l'apprentissage contrastif : maximiser l'accord entre les vues d'une même image et minimiser celui entre des images différentes.
2. Étude de cas : MoCo-CXR. Adaptation de la méthode MoCo aux radiographies pulmonaires.
3. Stratégies d'augmentation de données adaptées aux images médicales (rotations, retournements) au lieu des recadrages ou modifications de couleur.
4. Démonstration que les représentations apprises sont de meilleure qualité, surtout avec très peu de données étiquetées.
5. Utilisation des métadonnées patient pour améliorer la sélection des paires positives et négatives.

TP : Fine-tuning et Apprentissage Auto-Supervisé en Pratique

Mettre en œuvre et comparer les stratégies d'apprentissage en données limitées.

Activités :

- Partie A : Fine-tuner un modèle pré-entraîné sur ImageNet (ex : DenseNet121) sur une petite fraction du jeu de données CheXpert pour une tâche de classification.
- Partie B : Utiliser un modèle pré-entraîné avec une méthode auto-supervisée comme MoCo-CXR et le fine-tuner sur la même petite fraction de données.
- Comparer les courbes d'apprentissage et les performances finales pour quantifier le bénéfice de l'apprentissage auto-supervisé spécifique au domaine.

Bibliographie

- [Fernando et al., 2021] Fernando, T., Gammulle, H., Denman, S., Sridharan, S., and Fookes, C. (2021). Deep learning for medical anomaly detection—a survey. *ACM Computing Surveys (CSUR)*, 54(7) :1–37.
- [Gal and Ghahramani, 2016] Gal, Y. and Ghahramani, Z. (2016). Dropout as a bayesian approximation : Representing model uncertainty in deep learning. In *international conference on machine learning*, pages 1050–1059. PMLR.
- [Gawlikowski et al., 2023] Gawlikowski, J., Tassi, C. R. N., Ali, M., Lee, J., Humt, M., Feng, J., Kruspe, A., Triebel, R., Jung, P., Roscher, R., et al. (2023). A survey of uncertainty in deep neural networks. *Artificial Intelligence Review*, 56(Suppl 1) :1513–1589.
- [Lambert et al., 2024] Lambert, B., Forbes, F., Doyle, S., Dehaene, H., and Dojat, M. (2024). Trustworthy clinical ai solutions : A unified review of uncertainty quantification in deep learning models for medical image analysis. *Artif. Intell. Medicine*, 150 :102830.
- [Lemay et al., 2022] Lemay, A., Hoebel, K., Bridge, C. P., Befano, B., De Sanjosé, S., Egemen, D., Rodriguez, A. C., Schiffman, M., Campbell, J. P., and Kalpathy-Cramer, J. (2022). Improving the repeatability of deep learning models with monte carlo dropout. *NPJ digital medicine*, 5(1) :174.
- [Mondo, 2024] Mondo, L. (2024). Uncertainty estimation in medical image segmentation with deep learning.
- [Ronneberger et al., 2015] Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net : Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention*, pages 234–241. Springer.
- [Rubin et al., 2021] Rubin, D. L., Greenspan, H., and Hoogi, A. (2021). Biomedical imaging informatics. In *Biomedical Informatics : Computer Applications in Health Care and Biomedicine*, pages 299–362. Springer.