

APPRENTISSAGE PROFOND POUR L'IMAGERIE MÉDICALE QUATIFICATION D'INCERTITUDES

V. Monbet

¹ Université de Rennes/UFR Mathématiques

Incertitudes

- ▶ **Incertitude aléatoire** : liée au bruit et à la variabilité intrinsèque des données. C'est la manifestation directe des erreurs de mesure, des artefacts et de la variabilité inter-annotateurs.
L'incertitude aléatoire rend la classification difficile, voire parfois impossible, en raison de l'absence de caractéristiques distinctives.
- ▶ **Incertitude épistémique** : liée aux limites du modèle, souvent due à un ensemble d'entraînement limité. C'est la conséquence directe des petits échantillons.

La prédiction d'un réseau de neurones est sujette à des erreurs dépendantes à la fois du modèle et des données d'entrée. Ainsi, l'**incertitude prédictive** associée à y^* est généralement composée des deux types d'erreurs. Selon l'approche adoptée, une modélisation explicite supplémentaire de l'**incertitude distributionnelle** ([?]) peut être utilisée afin de représenter l'incertitude provoquée par des exemples provenant de régions non couvertes par les données d'entraînement.




Figure – Image from [Gawlikowski et al., 2023]

Cadre bayésien

Pour prendre en compte les incertitudes, une approche classique consiste à travailler dans le cadre de modèles bayésiens.

Jeu de données d'entraînement : n de ces points de données,
 $X = \{x_1, x_2, \dots, x_n\}$ et étiquettes associées $Y = \{y_1, y_2, \dots, y_n\}$

Dans la modélisation bayésienne, l'incertitude du modèle est formalisée comme une distribution de probabilité sur les paramètres du modèle ω , tandis que l'incertitude des données est formalisée comme une distribution de probabilité sur les sorties du modèle y^* , étant donné un modèle paramétré f_ω .

La distribution sur une prédiction y^* , appelée *distribution prédictive*, est alors donnée par :

$$p(y^* | x^*, X, Y) = \int \underbrace{p(y^* | x^*, \omega)}_{\text{données}} \underbrace{p(\omega | X, Y)}_{\text{modèle}} d\omega$$

En pratique, on cherche à estimer $p(y^* | x^*, X, Y)$. Si la densité est très pointue l'incertitude est faible, si elle est plate l'incertitude est forte.

Il est possible de prendre aussi en compte l'incertitude de distribution

$$p(y^* | x^*, X, Y) = \int \int \underbrace{p(y^* | \mu)}_{\text{données}} \underbrace{p(\mu | x^*, \omega)}_{\text{distribution}} \underbrace{p(\omega | X, Y)}_{\text{modèle}} d\omega d\mu$$

L'**incertitude distributionnelle** fait référence à l'incertitude causée par une modification de la distribution des données d'entrée, tandis que l'**incertitude du modèle** désigne l'incertitude résultant du processus de construction et d'entraînement du réseau de neurones profond (DNN).




Fig. 2 The illustration shows the different steps of a neural network pipeline, based on the earth observation example of land cover classification (here settlement and forest) based on optical images. The different factors that affect the predictive uncertainty are highlighted in the boxes. Factor I is shown as changing environments by cloud-covered trees, and different types and colors of trees. Factor II is shown by insufficient measurements, that can not directly be used to separate between settlement and forest and by label noise. In practice, the resolution of such images can be low and which would also be part of Factor II. Factor III and Factor IV represent the uncertainties caused by the network structure and the stochastic training process, respectively. Factor V in contrast is represented by feeding the trained network with unknown types

Calibration

Pour un échantillon de test x_i , le modèle prédit la classe $\hat{y}_i$ avec une probabilité $\hat{p}_i$. Le modèle est bien calibré si, on a : $P(\hat{y} = y \mid \hat{p}) = \hat{p}$.

Les modèles de deep learning ont tendance à être trop confiants : ils surestiment la probabilité p .

							
Pred:	1	1	3	7	7	1	1
Conf:	1	0.8	0.97	1	0.98	0.94	1
							
Pred:	3	8	1	1	8	8	8
Conf:	1	0.62	1	0.84	0.99	1	0.99
							
Pred:	7	7	7	1	5	6	6
Conf:	1	1	0.88	0.86	0.87	0.97	1

Exemple

Considérons une tâche de classification unidimensionnelle. Supposons qu'un nombre égal d'échantillons provienne de deux distributions $p_0 = \mathcal{N}(-1, 1)$ et $p_1 = \mathcal{N}(1, 1)$, et que la tâche consiste à déterminer si un échantillon x provient de la distribution p_0 ou de p_1 .

Naturellement, on peut proposer la fonction suivante :


$$c(x) = \begin{cases} 0, & \text{si } x \leq 0, \\ 1, & \text{sinon,} \end{cases}$$

comme classificateur atteignant une précision maximale.

Dans ce problème, on s'attend à ce que l'incertitude de la classification soit élevée à proximité de la frontière de décision en $x = 0$. Comme les densités des deux distributions sont connues, la probabilité de classification peut être calculée analytiquement comme suit :

$$P(x \in C_1) = \frac{p_1(x)}{p_0(x) + p_1(x)}.$$

Un modèle d'apprentissage va approcher la frontière et l'incertitude à proximité de $x = 0$, mais il n'estimera pas la qualité de la classification



On a besoin de méthodes pour quantifier l'incertitude et calibrer les prédictions.

Mesure de l'erreur de calibration

Plusieurs méthodes ont été proposées pour **quantifier le degré de (mauvaise) calibration** des réseaux de neurones.

- ▶ Erreur de calibration espérée (ECE, *Expected Calibration Error*)
- ▶ Diagramme de fiabilité (*Reliability Diagram*)
- ▶ Score de Brier (*Brier Score*)
- ▶ Log-vraisemblance négative (*Negative Log-Likelihood*, NLL)

Erreur de calibration espérée

L'ECE est un *résumé scalaire* de la différence entre la **confiance** et la **précision** sur l'ensemble des prédictions. Elle est calculée en divisant les prédictions en M intervalles (*bins*) selon leurs scores de confiance, puis en appliquant la formule suivante :

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|$$


où B_m est l'ensemble des échantillons appartenant à l'intervalle m , $\text{acc}(B_m)$ représente la précision moyenne dans cet intervalle, $\text{conf}(B_m)$ la confiance moyenne, et n le nombre total d'échantillons.

Un modèle bien calibré devrait satisfaire la condition suivante dans chaque intervalle :

$$\text{acc}(B_m) \approx \text{conf}(B_m)$$

Diagramme de fiabilité (*Reliability Diagram*)

Le diagramme de fiabilité trace $\text{acc}(B_m)$ en fonction de $\text{conf}(B_m)$ pour chaque intervalle (*bin*).



Score de Brier

Le score de Brier mesure la **différence quadratique moyenne** entre la probabilité prédite et le résultat réel. Pour une seule prédiction, il est défini comme suit :

$$\text{Brier Score} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2$$

où $\hat{p}_i \in [0, 1]$ est la probabilité prédite pour le $i^{\text{ème}}$ échantillon (par exemple, la sortie du *softmax* pour un voxel), et $y_i \in \{0, 1\}$ est l'étiquette réelle (*ground truth*).

Un *Brier Score* plus faible indique des prédictions à la fois mieux calibrées et plus précises, car il reflète non seulement si la prédiction est correcte, mais aussi à quel point la confiance prédite est proche du résultat réel.

Log-vraisemblance négative

La log-vraisemblance négative (*Negative Log-Likelihood*, NLL). Bien qu'à l'origine conçue comme fonction de perte pour l'entraînement des modèles probabilistes, sert également de métrique sensible à la calibration.


Une valeur élevée de NLL indique que les distributions de probabilités prédites reflètent mal la distribution réelle des résultats. Contrairement à l'ECE, elle pénalise beaucoup plus fortement les prédictions erronées trop confiantes.

Quantifier l'incertitude

Il existe différentes approches pour quantifier l'incertitude.

- ▶ Méthode déterministes basée sur une seule prédiction (une seule passe avant).
- ▶ Deep Ensembles : Agréger les prédictions de plusieurs modèles entraînés indépendamment pour quantifier l'incertitude. Connus pour leur robustesse et la qualité de leurs estimations d'incertitude.
- ▶ Monte Carlo Dropout (MC Dropout) : Approcher l'inférence bayésienne en activant le dropout lors de l'inférence. C'est la méthode la plus populaire en imagerie médicale (plus d'un tiers des implémentations).
- ▶ Test-Time Augmentation (TTA) : Générer plusieurs prédictions en appliquant des transformations à l'image d'entrée au moment du test.

Quantifier l'incertitude



Approche déterministe

Ici on suppose qu'un seul modèle est entraîné et qu'une seule passe avant est opérée pour obtenir une prédiction.

Deux approches sont possibles

- ▶ Un seul réseau de neurone est modélisé et il est entraîné pour prédire les incertitudes : l'idée est de prédire les paramètres d'une distribution sur les prédictions, plutôt qu'une estimation ponctuelle directe du maximum a posteriori. Souvent, la fonction de perte de ces réseaux prend en compte la divergence espérée entre la distribution réelle et la distribution prédite.
- ▶ Un seul réseau est entraîné et on ajoute un post traitement pour estimer l'incertitude. Typiquement, les logits sont corrigés par une transformation.

Deep Ensembles

Cette méthode repose sur l'entraînement de plusieurs instances d'un modèle de réseau neuronal — chacune initialisée avec des graines aléatoires différentes et éventuellement exposée à des mélanges de données différents — de sorte que leurs prédictions forment un ensemble diversifié d'hypothèses sur la sortie.

La prédiction finale est typiquement calculée en agrégeant les sorties (par exemple, par moyenne), et la dispersion entre ces sorties est utilisée comme une estimation de l'*incertitude épistémique*.

- ✓ Facile à mettre en oeuvre et relativement fiable.
- ✗ Coûteux en temps de calcul.

Monte Carlo Dropout

L'idée est de maintenir le *dropout* actif pendant l'inférence et d'effectuer plusieurs passes avant (*forward passes*) avec des masques de *dropout* aléatoires différents.

soit x^* une donnée de test et $\hat{f}_{\omega_t}(x^*)$ la sortie du modèle sous le masque de *dropout* t lors de l'inférence. En effectuant T passes avant stochastiques, on obtient un ensemble de prédictions

Soit $p_i^{(t)}$ la probabilité prédite pour le voxel i lors de la t -ième passe avant. La prédiction moyenne pour le voxel i est donnée par :

$$\bar{p}_i = \frac{1}{T} \sum_{t=1}^T p_i^{(t)}, \quad (1)$$

et l'incertitude associée au voxel i est estimée par :

$$\text{Var}_i = \frac{1}{T} \sum_{t=1}^T \|p_i^{(t)} - \bar{p}_i\|^2. \quad (2)$$

- ✓ L'entraînement n'est pas modifié, seul les phases de prédictions sont répétées
- ✗ L'estimation de l'incertitude dépend du taux de dropout et du nombre de passes avant. Elle a tendance à être sous estimée.

Check point ensembles

Cette méthode exploite le comportement naturel du *stochastic gradient descent* (SGD) pour extraire des échantillons postérieurs des poids du réseau pendant l'entraînement.

Soit D le jeu de données d'entraînement, et w_t les poids du réseau à l'époque t . Après une phase initiale de *burn-in* (par exemple, les γT premières époques), le modèle commence l'échantillonnage postérieur en collectant les poids $\{w_t\}_{t=\gamma T}^T$. Ces checkpoints sont ensuite utilisés pour une approximation de Monte Carlo de la distribution prédictive :

$$p(y^* | x^*, D) \approx \frac{1}{n} \sum_{i=1}^n p(y^* | x^*, w_{t_i}),$$

où n est le nombre de checkpoints sélectionnés, et $p(y^* | x^*, w_{t_i})$ est la prédiction du modèle avec les poids w_{t_i} .

Particulièrement adapté aux architectures auto-configurantes comme NNU-NET.

Test-time Augmentation

L'idée est d'introduire une variabilité dans l'entrée de test — via un ensemble de transformations réversibles (augmentation de données)— puis d'analyser la variabilité des prédictions du modèle sur ces entrées transformées.

Un ensemble d'augmentations déterministes est appliqué à l'image de test, générant N versions augmentées de l'entrée. Le modèle est ensuite utilisé pour prédire une carte de segmentation pour chaque entrée augmentée. Ces prédictions sont ensuite transformées pour revenir dans l'espace de l'entrée originale afin d'aligner toutes les prédictions spatialement.

$$\bar{p}_i = \frac{1}{N} \sum_{n=1}^N p_i^{(n)}, \quad (3)$$

et l'incertitude associée au voxel i est estimée par :

$$\text{Var}_i = \frac{1}{N} \sum_{n=1}^N \|p_i^{(n)} - \bar{p}_i\|^2. \quad (4)$$

- ✓ La TTA ne nécessite pas de ré-entraînement
- ✗ Il faut considérer des transformations réversibles (inversibles) et cliniquement valides.

Calibration

Différentes méthodes sont proposées dans la littérature pour calibrer les prédictions.


$$P(\hat{y} = y \mid \hat{p}) = \hat{p}$$

Temperature scaling

Le *temperature scaling* utilise un unique paramètre scalaire $T > 0$, où T représente la *température*, pour réécherlonner les scores de logit avant d'appliquer la fonction *softmax*.

$$P(\hat{y}) = \frac{e^{\mathbf{z}/T}}{\sum_k e^{\mathbf{z}_k/T}}$$


where $\hat{y}$ est la prédiction, $\mathbf{z}$ est le logit et T est la température.




- ✓ Le *temperature scaling* est efficace et robuste, en particulier lorsqu'il est appliqué séparément pour chaque classe dans les tâches de segmentation multi-classes.

Temperature scaling

Exemple



An uncalibrated neural network, before temperature scaling. The reliability diagram indicates miscalibration.



Neural network after temperature scaling. The reliability diagram indicates a well-calibrated network.

Figure – Source : https://geoffpleiss.com/blog/nn_calibration.html

D'autres transformations plus complexes et impliquant plus de paramètres existent (Platt, Dirichlet, ...).

Evidential Deep Learning

L'*Evidential Deep Learning* (EDL) permet d'estimer simultanément les **prédictions** et leur **incertitude**, sans recourir à des méthodes d'échantillonnage comme le *Monte Carlo Dropout* ou les *Deep Ensembles*.

Un modèle EDL prédit les **paramètres d'une distribution de Dirichlet** sur les classes possibles. Cette distribution encode à la fois la probabilité moyenne des classes et le degré de confiance du modèle dans ses propres prédictions.




Figure – Distributions de Dirichlet, source : [Gawlikowski et al., 2023]

Dans le cadre d'une tâche de classification à K classes, le modèle prédit un vecteur de *preuves* (evidence) $\mathbf{e} = [e_1, e_2, \dots, e_K]$, où chaque $e_k > 0$. Les paramètres de la distribution de Dirichlet sont ensuite définis comme :

$$\alpha_k = e_k + 1, \quad \forall k \in \{1, \dots, K\}.$$

La distribution de Dirichlet sur les probabilités de classe $\mathbf{p}$ est donnée par :

$$\text{Dir}(\mathbf{p} \mid \boldsymbol{\alpha}) = \frac{1}{B(\boldsymbol{\alpha})} \prod_{k=1}^K p_k^{\alpha_k - 1},$$

où $B(\boldsymbol{\alpha})$ est la fonction de normalisation bêta multivariée.

L'estimation de la probabilité moyenne pour chaque classe est :

$$\hat{p}_k = \frac{\alpha_k}{S}, \quad \text{où } S = \sum_{j=1}^K \alpha_j.$$

Pour entraîner le modèle, une fonction de perte spécifique est utilisée, basée sur la **Negative Log-Likelihood (NLL)** de la Dirichlet, avec une pénalisation supplémentaire sur l'incertitude excessive :

$$\mathcal{L} = \sum_{k=1}^K y_k (\psi(S) - \psi(\alpha_k)) + \lambda \cdot KL(\text{Dir}(\mathbf{p} \mid \boldsymbol{\alpha}) \parallel \text{Dir}(\mathbf{p} \mid \mathbf{1})),$$

où $\psi(\cdot)$ est la fonction digamma, et le second terme correspond à une régularisation Kullback-Leibler (KL) visant à éviter des prédictions artificiellement incertaines.

Visualisation de l'incertitude

La visualisation efficace de l'incertitude dans la segmentation d'images médicales est essentielle pour l'intégration clinique des systèmes d'apprentissage profond : cartes de chaleur d'incertitude

La carte de confiance (*confidence map*) est généralement construite en extrayant, pour chaque voxel, la valeur maximale du *softmax* parmi les classes possibles :

$$\text{Confidence}(x_i) = \max_k p_{i,k} \quad (5)$$

où $p_{i,k}$ représente la probabilité prédite pour la classe k au voxel x_i .

Pour mieux représenter la distribution prédictive, on calcule souvent l'entropie de la sortie *softmax* :

$$\text{Entropy}(x_i) = - \sum_{k=1}^K p_{i,k} \log p_{i,k} \quad (6)$$

où $p_{i,k}$ désigne la probabilité prédite pour la classe k au voxel x_i .

Cartes d'entropie




Figure – Source : Alexandro Mondo [[Mondo, 2024](#)]

Cartes d'entropie




Figure – Source : Alexandro Mondo [Mondo, 2024]

Références

-  Gawlikowski, J., Tassi, C. R. N., Ali, M., Lee, J., Humt, M., Feng, J., Kruspe, A., Triebel, R., Jung, P., Roscher, R., et al. (2023).
A survey of uncertainty in deep neural networks.
Artificial Intelligence Review, 56(Suppl 1) :1513–1589.
-  Mondo, L. (2024).
Uncertainty estimation in medical image segmentation with deep learning.